

# Знакомство с классификацией на примере логистической регрессии

НИКИТА

# Сегодня в программе

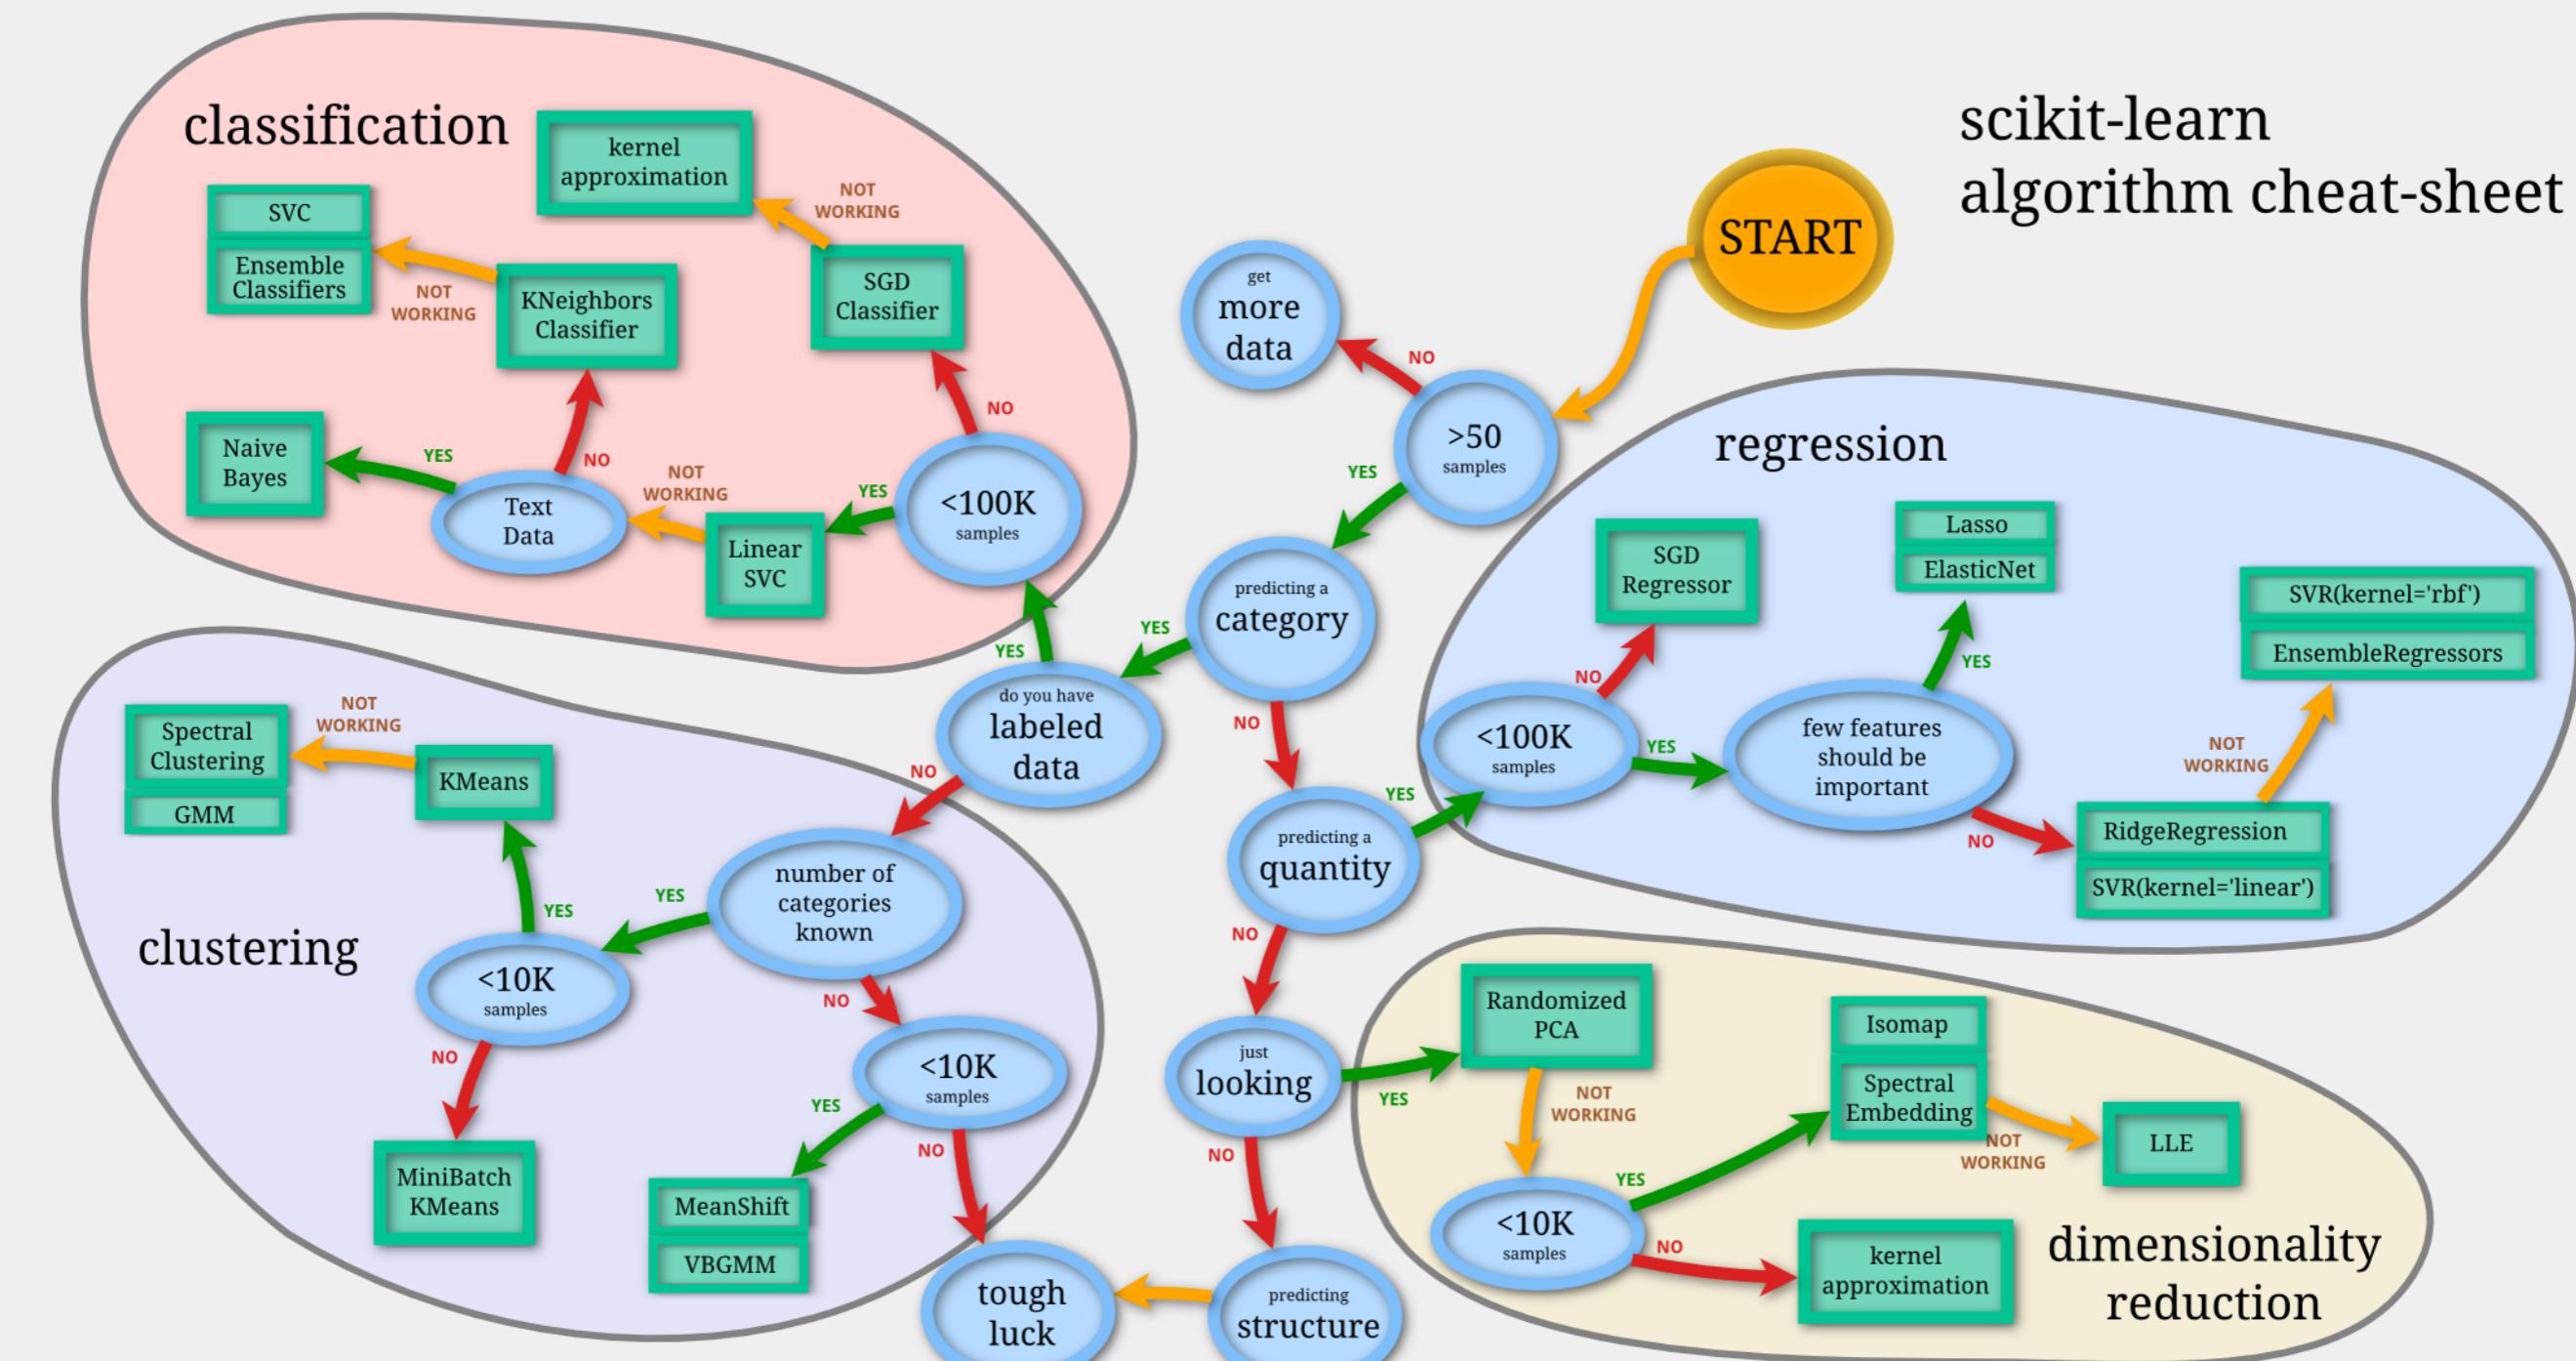
- Задачи машинного обучения
- Регрессия
- Классификация

# Сегодня в программе

- Задачи машинного обучения
- Регрессия
  - Линейная регрессия
    - МНК оценки
    - Псевдообратная матрица
    - Градиентный спуск
    - Стохастический градиентный спуск
  - Как оценить качество регрессии
- Классификация
  - От непрерывного к дискретному
  - Все дело в функции потерь
  - Как оценить качество классификации?

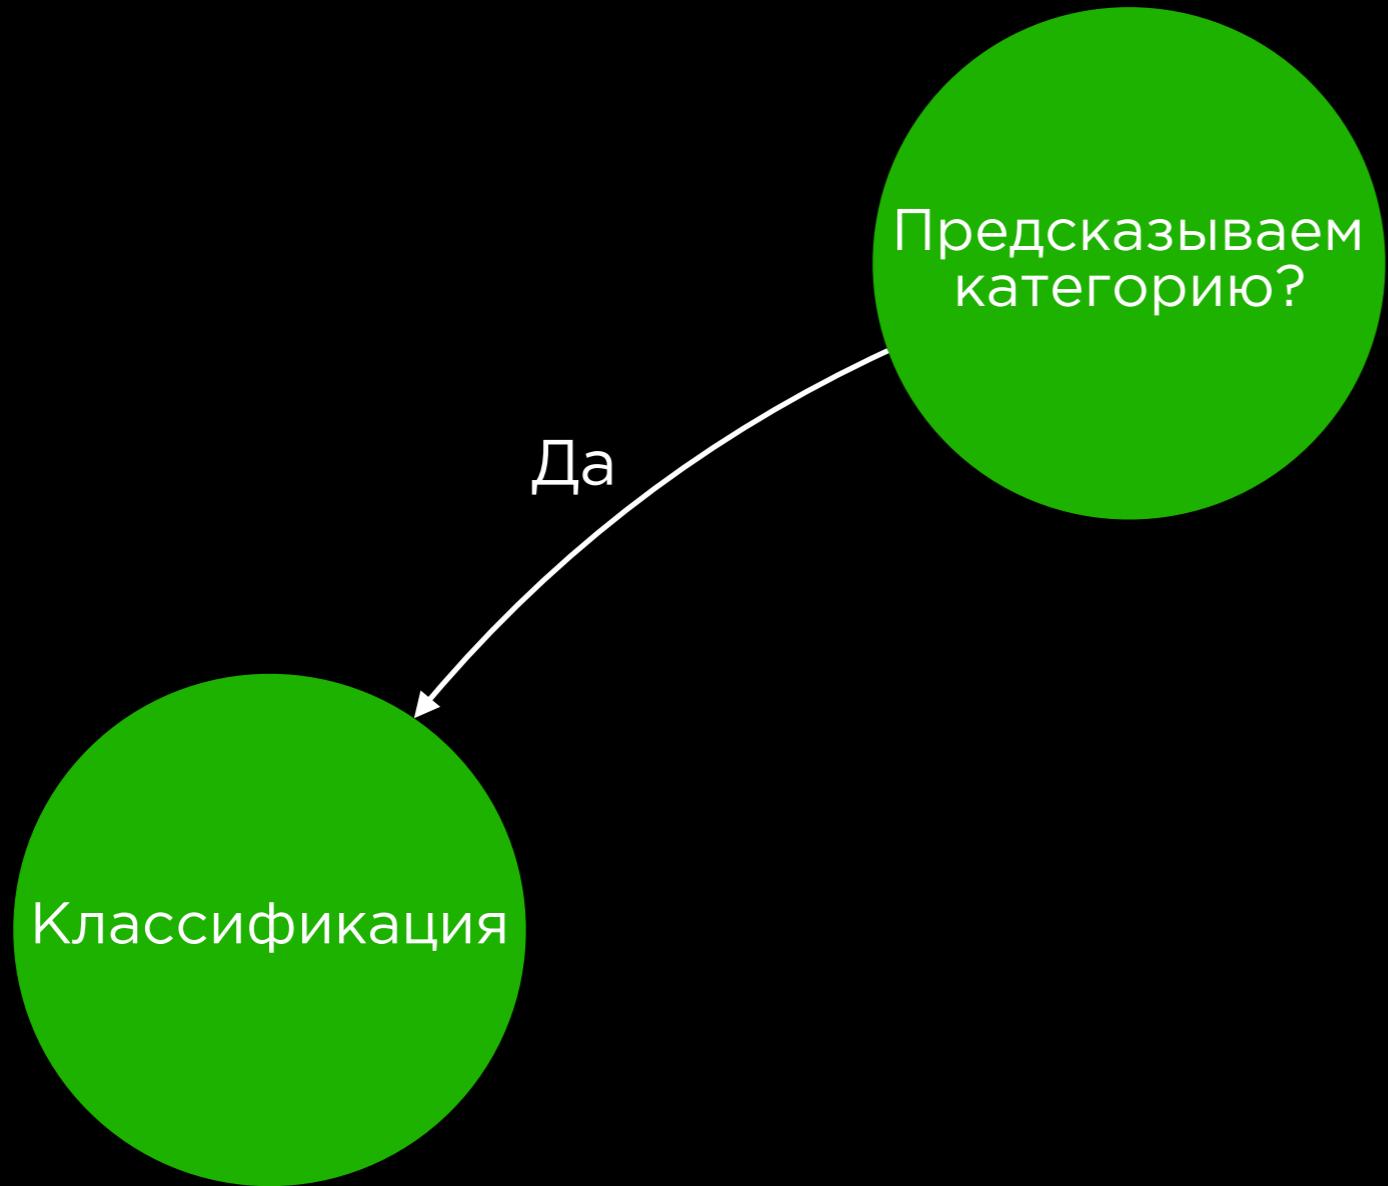
# Задачи машинного обучения

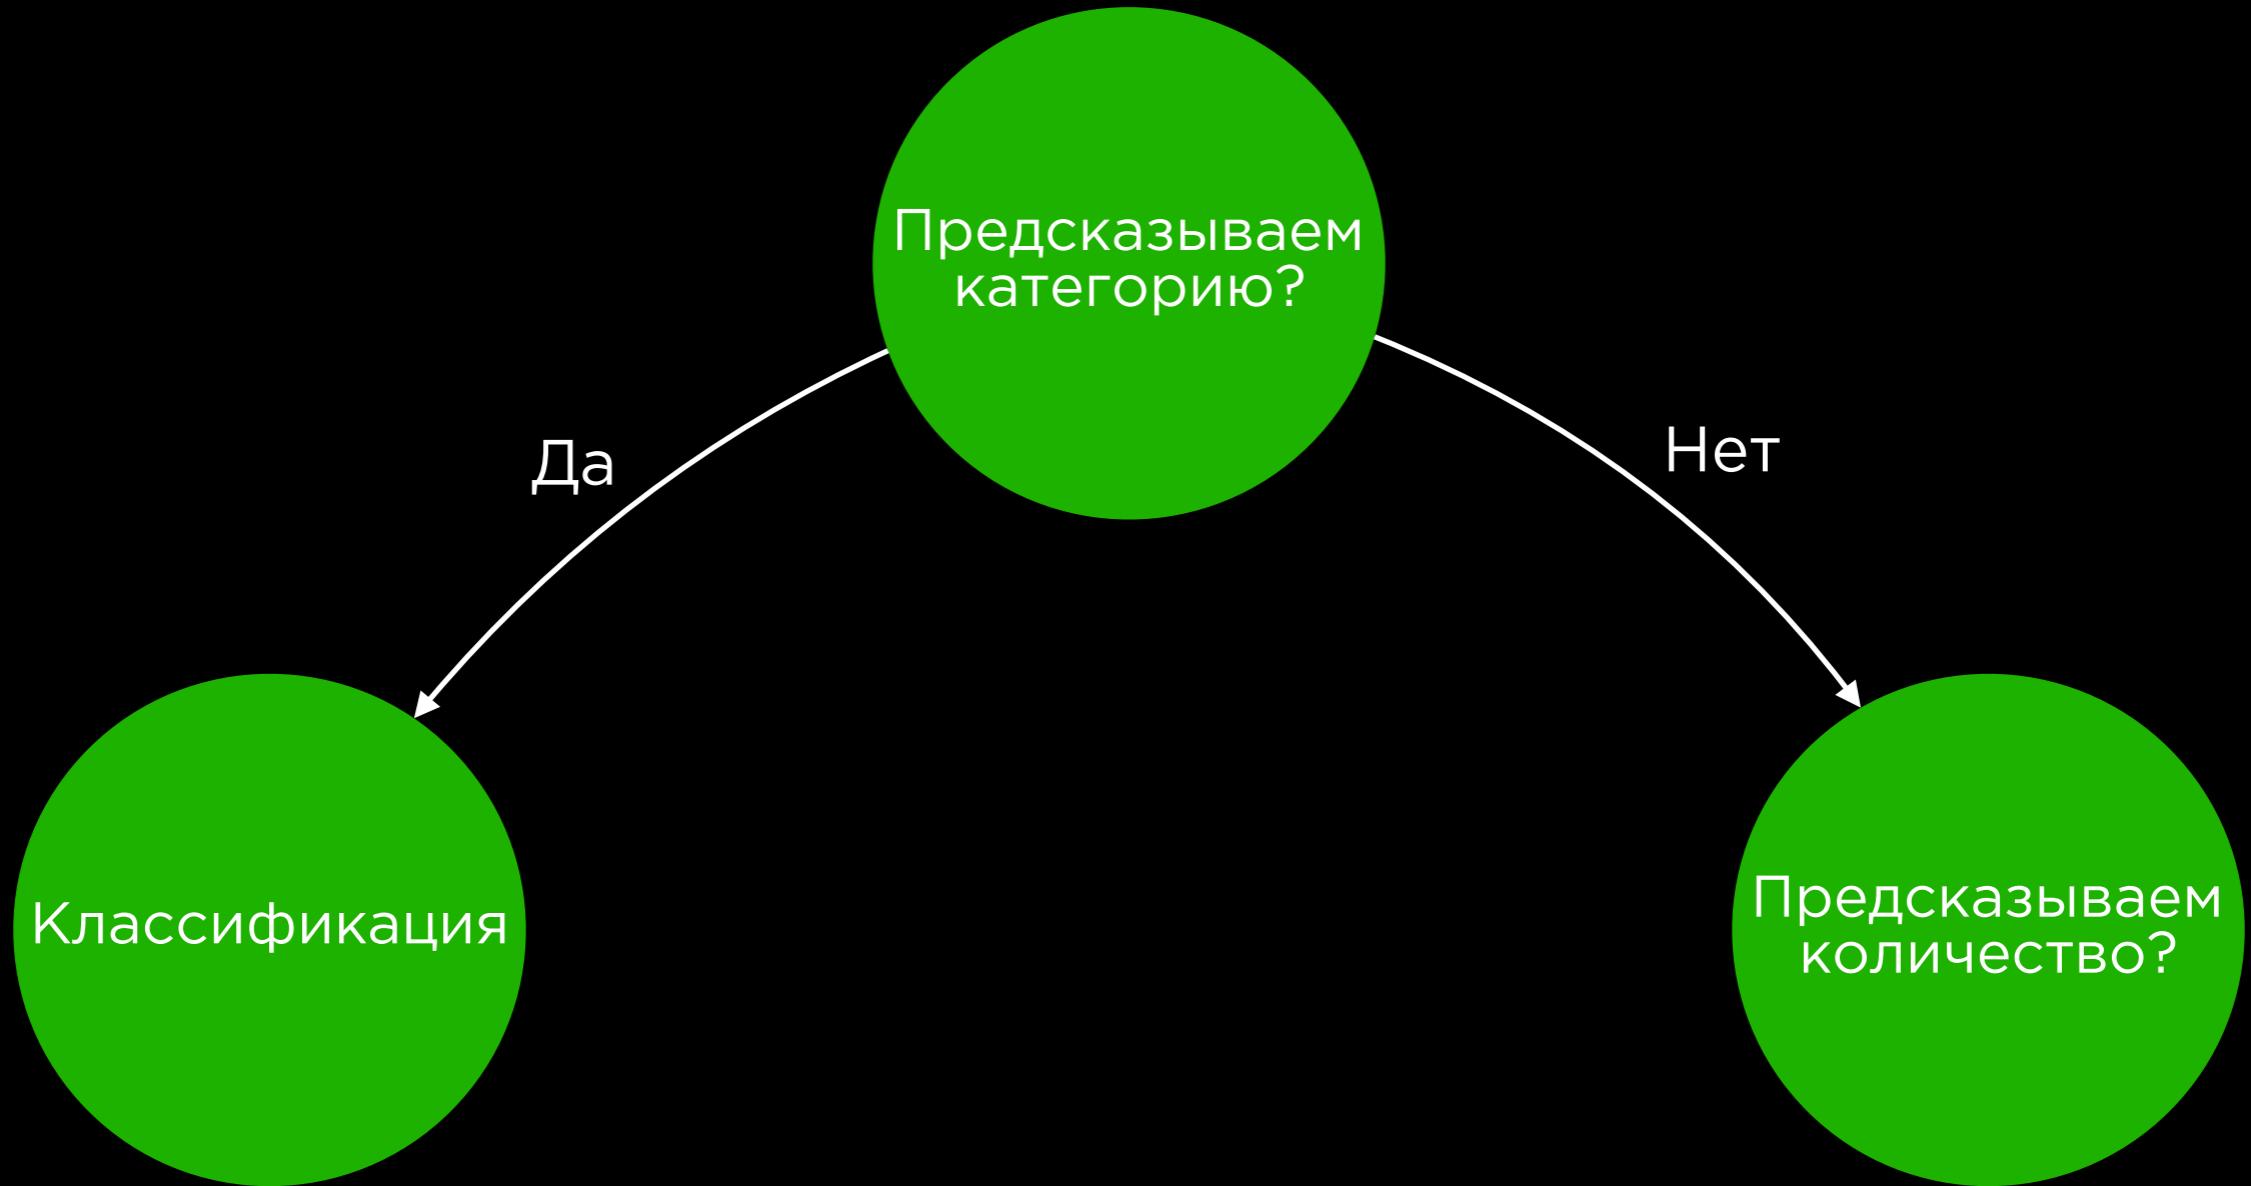
# scikit-learn algorithm cheat-sheet

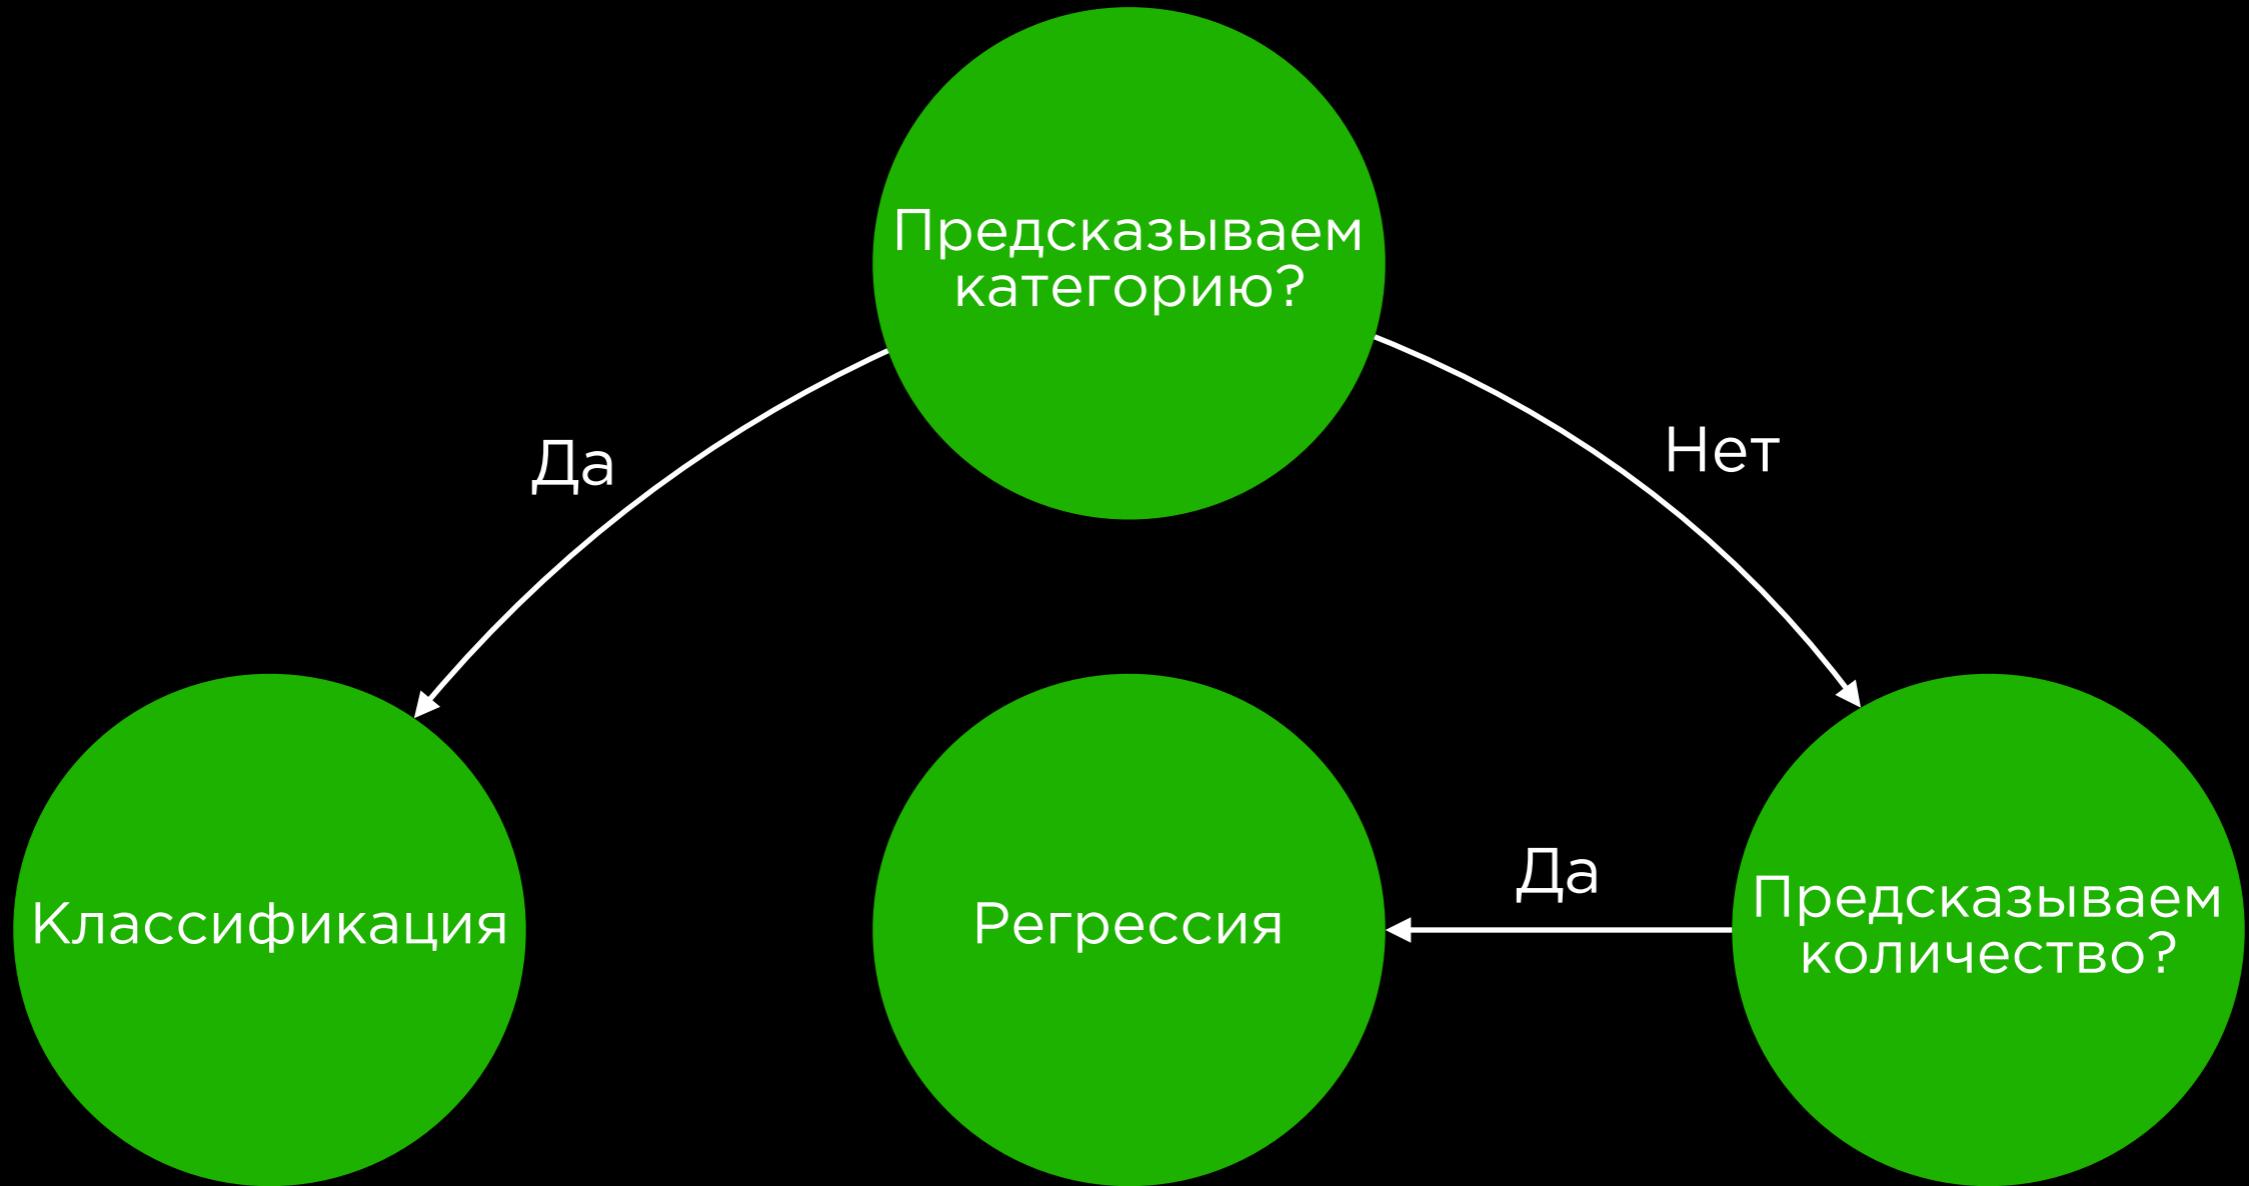


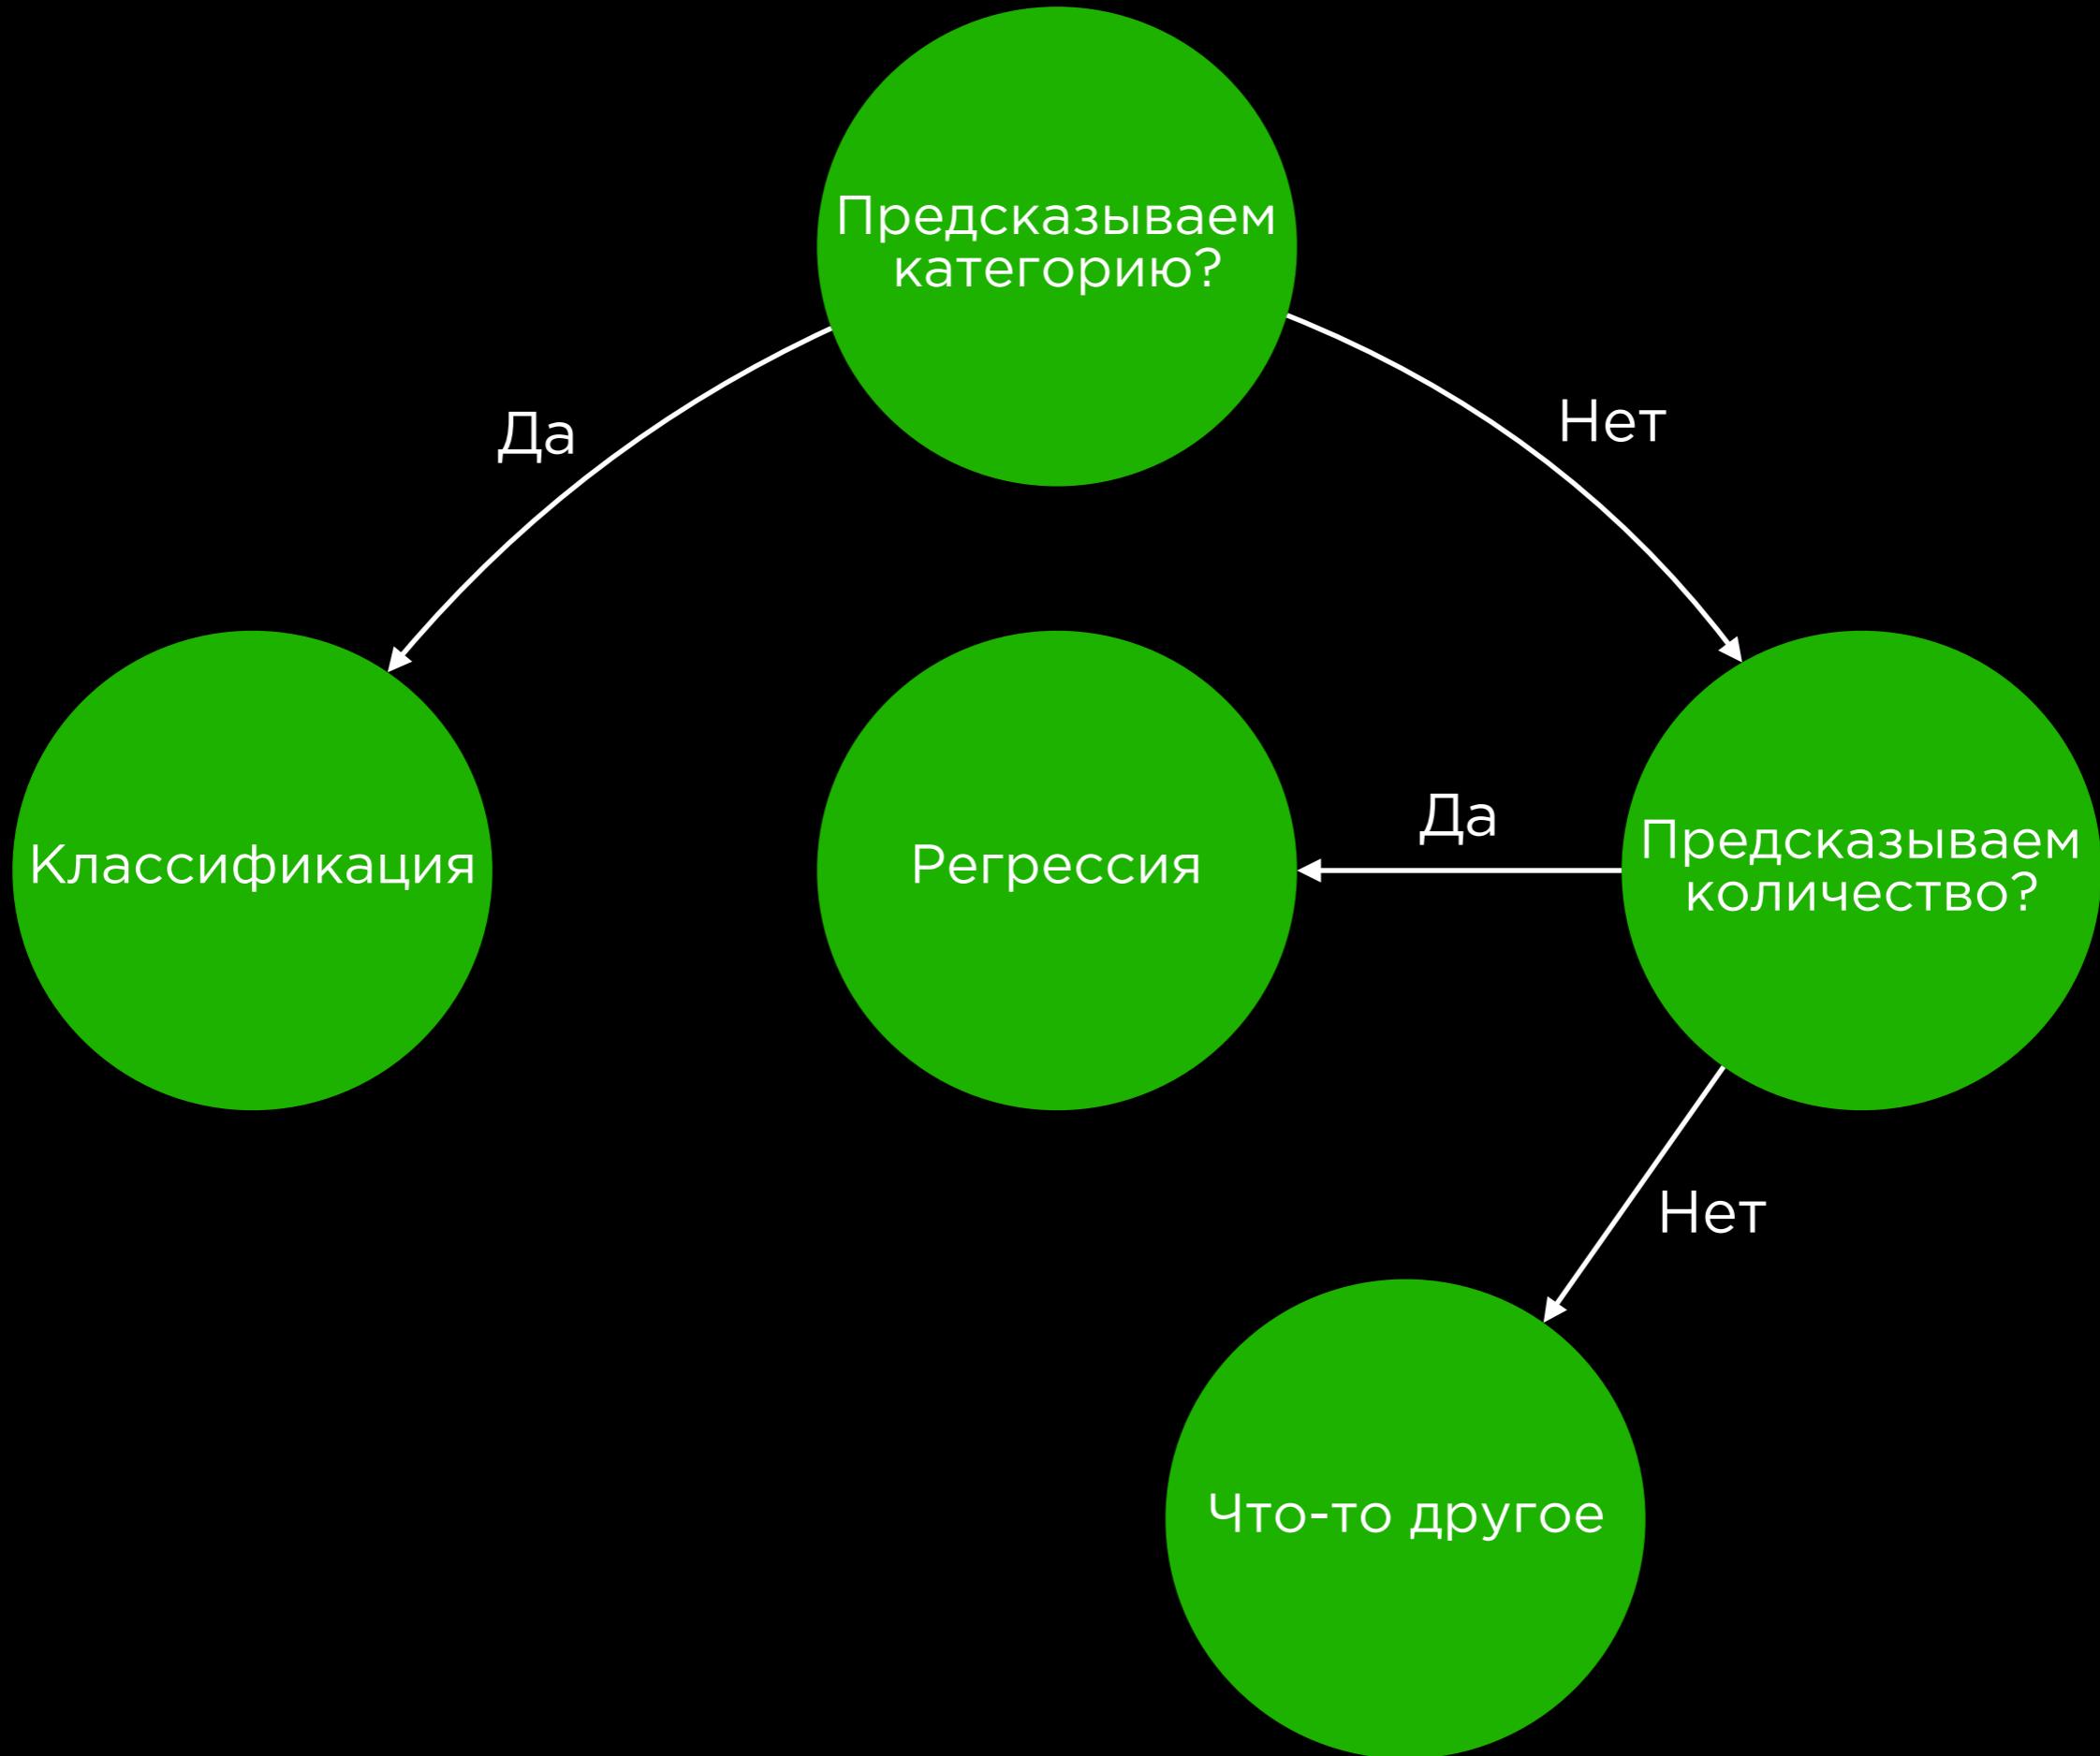


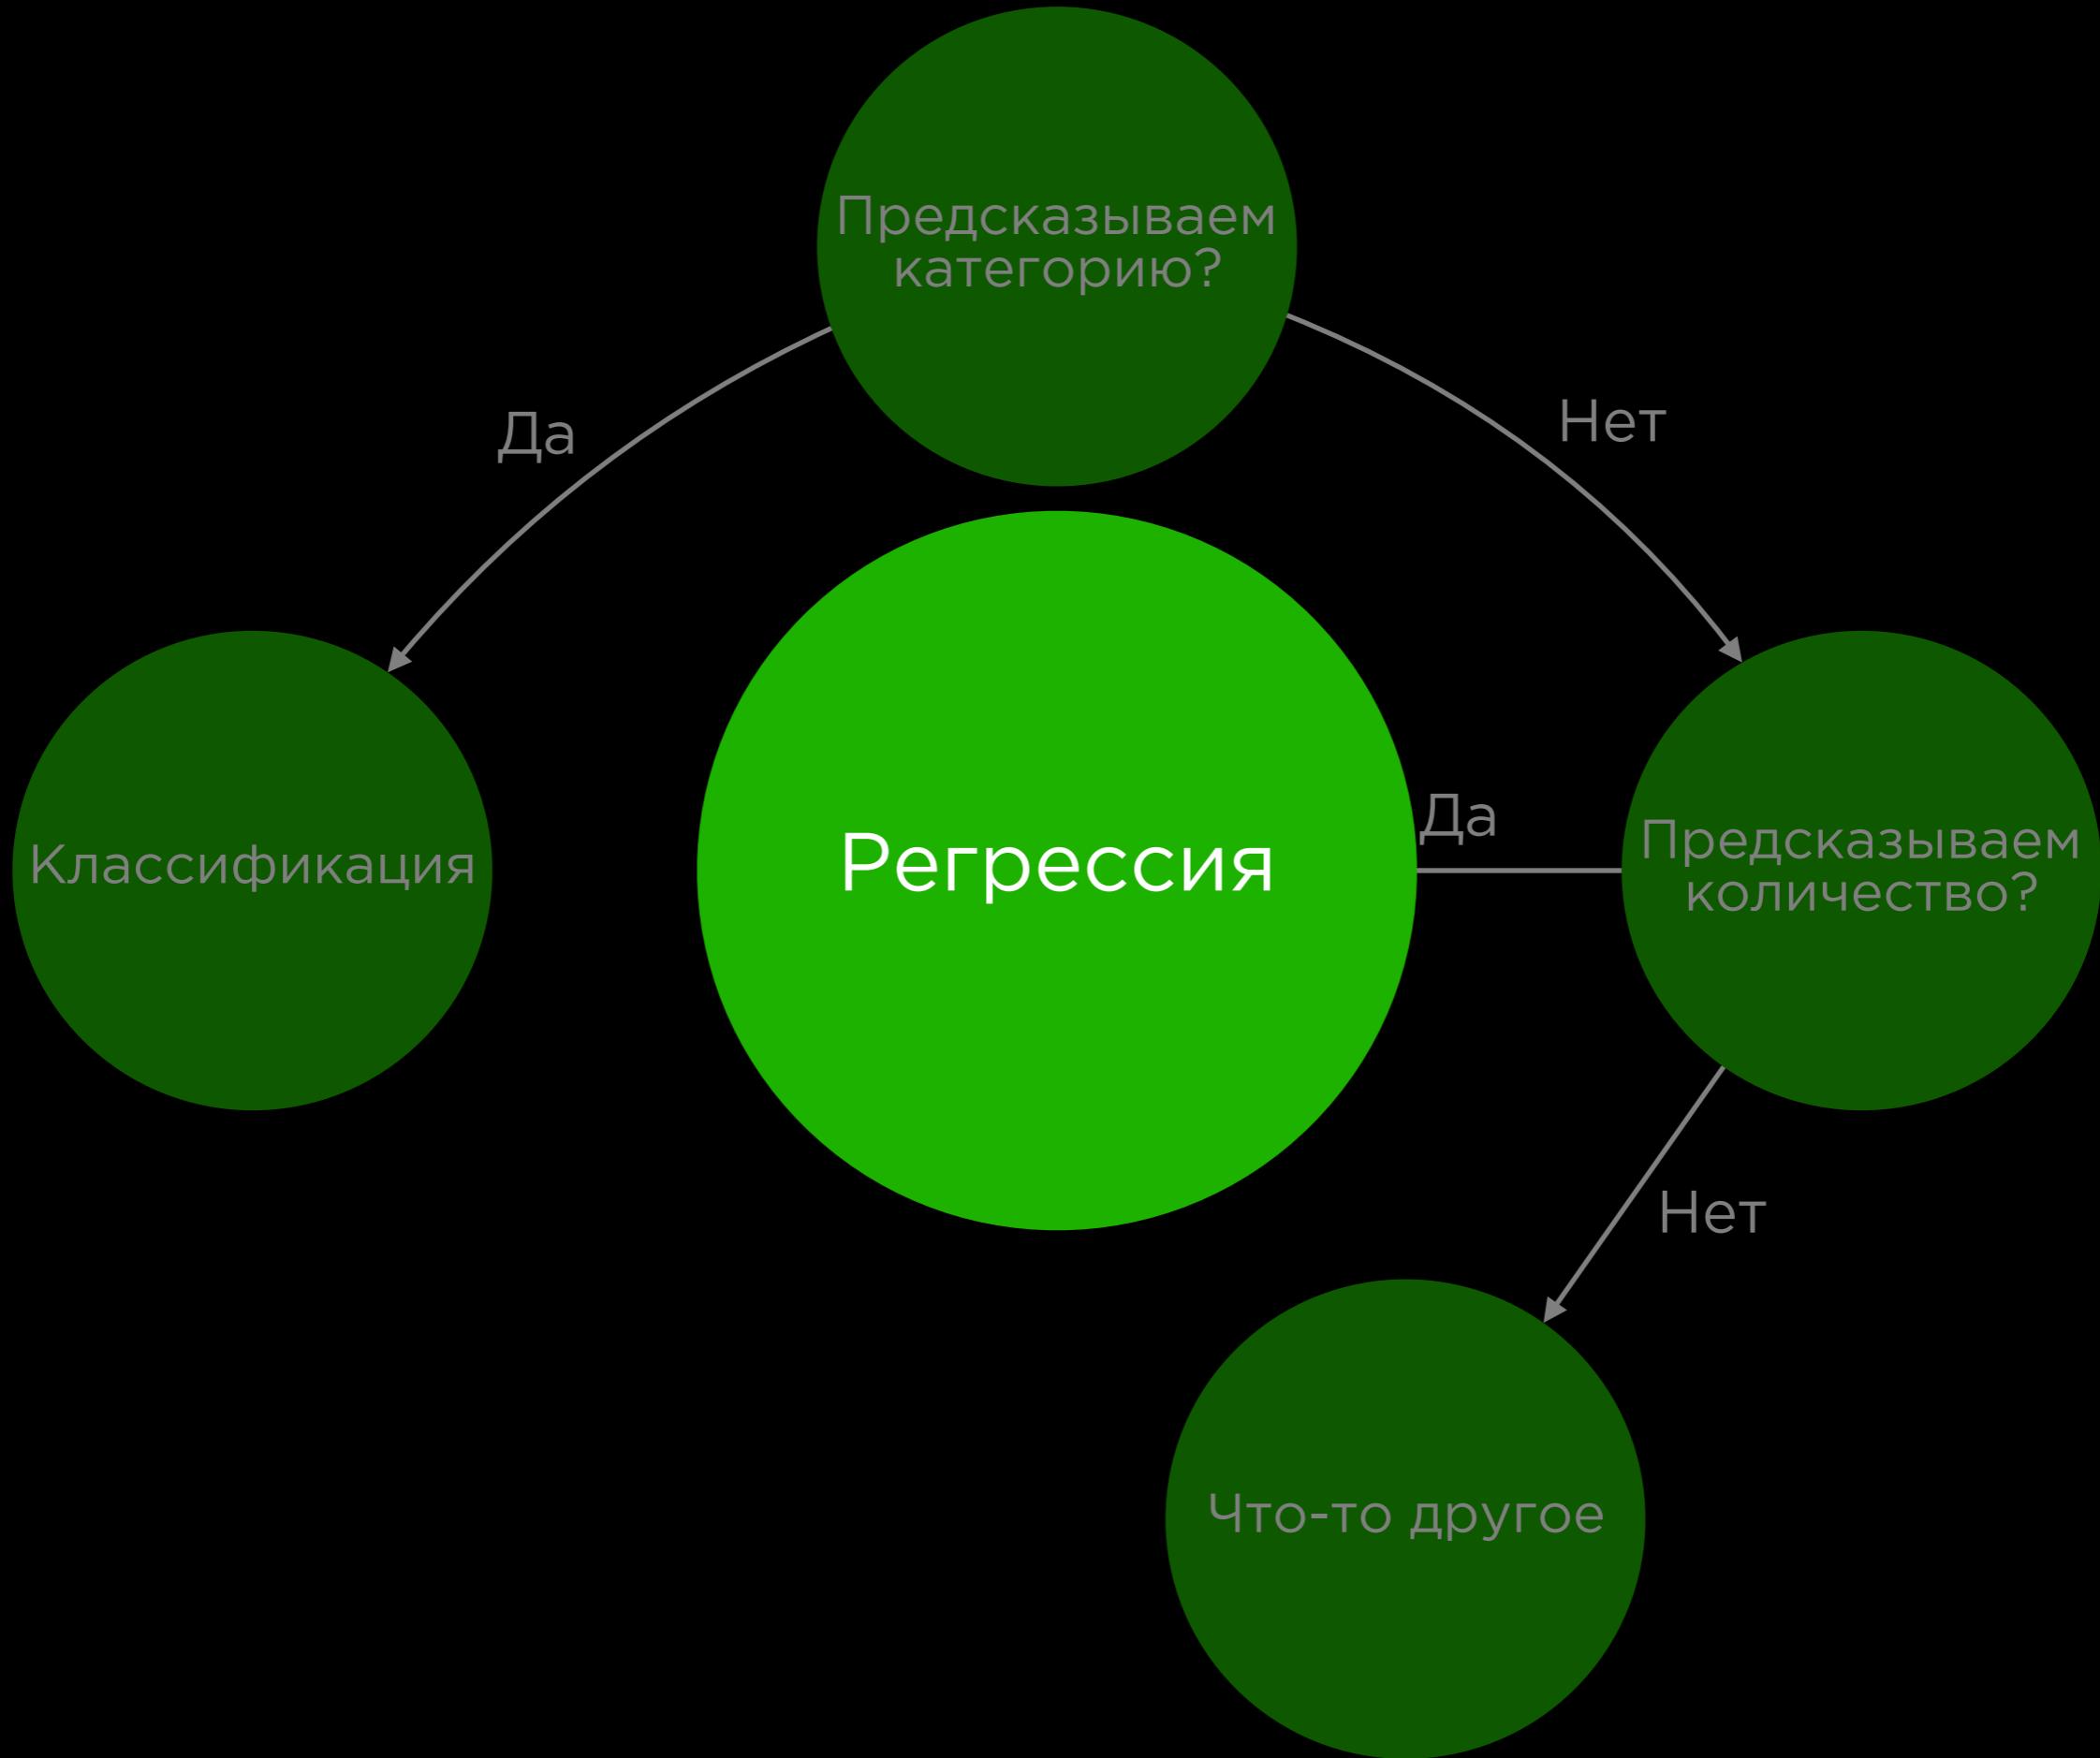
Предсказываем  
категорию?











# Регрессия

# Постановка задачи

$$Y = f(X_1, \dots, X_l) + \epsilon$$

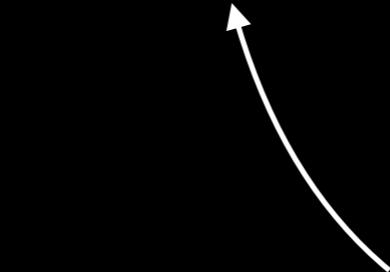
# Постановка задачи

$$Y = f(\underline{X_1, \dots, X_l}) + \epsilon$$

# Постановка задачи

$$Y = f(\underline{X_1, \dots, X_l}) + \epsilon$$

Независимые  
переменные



# Постановка задачи

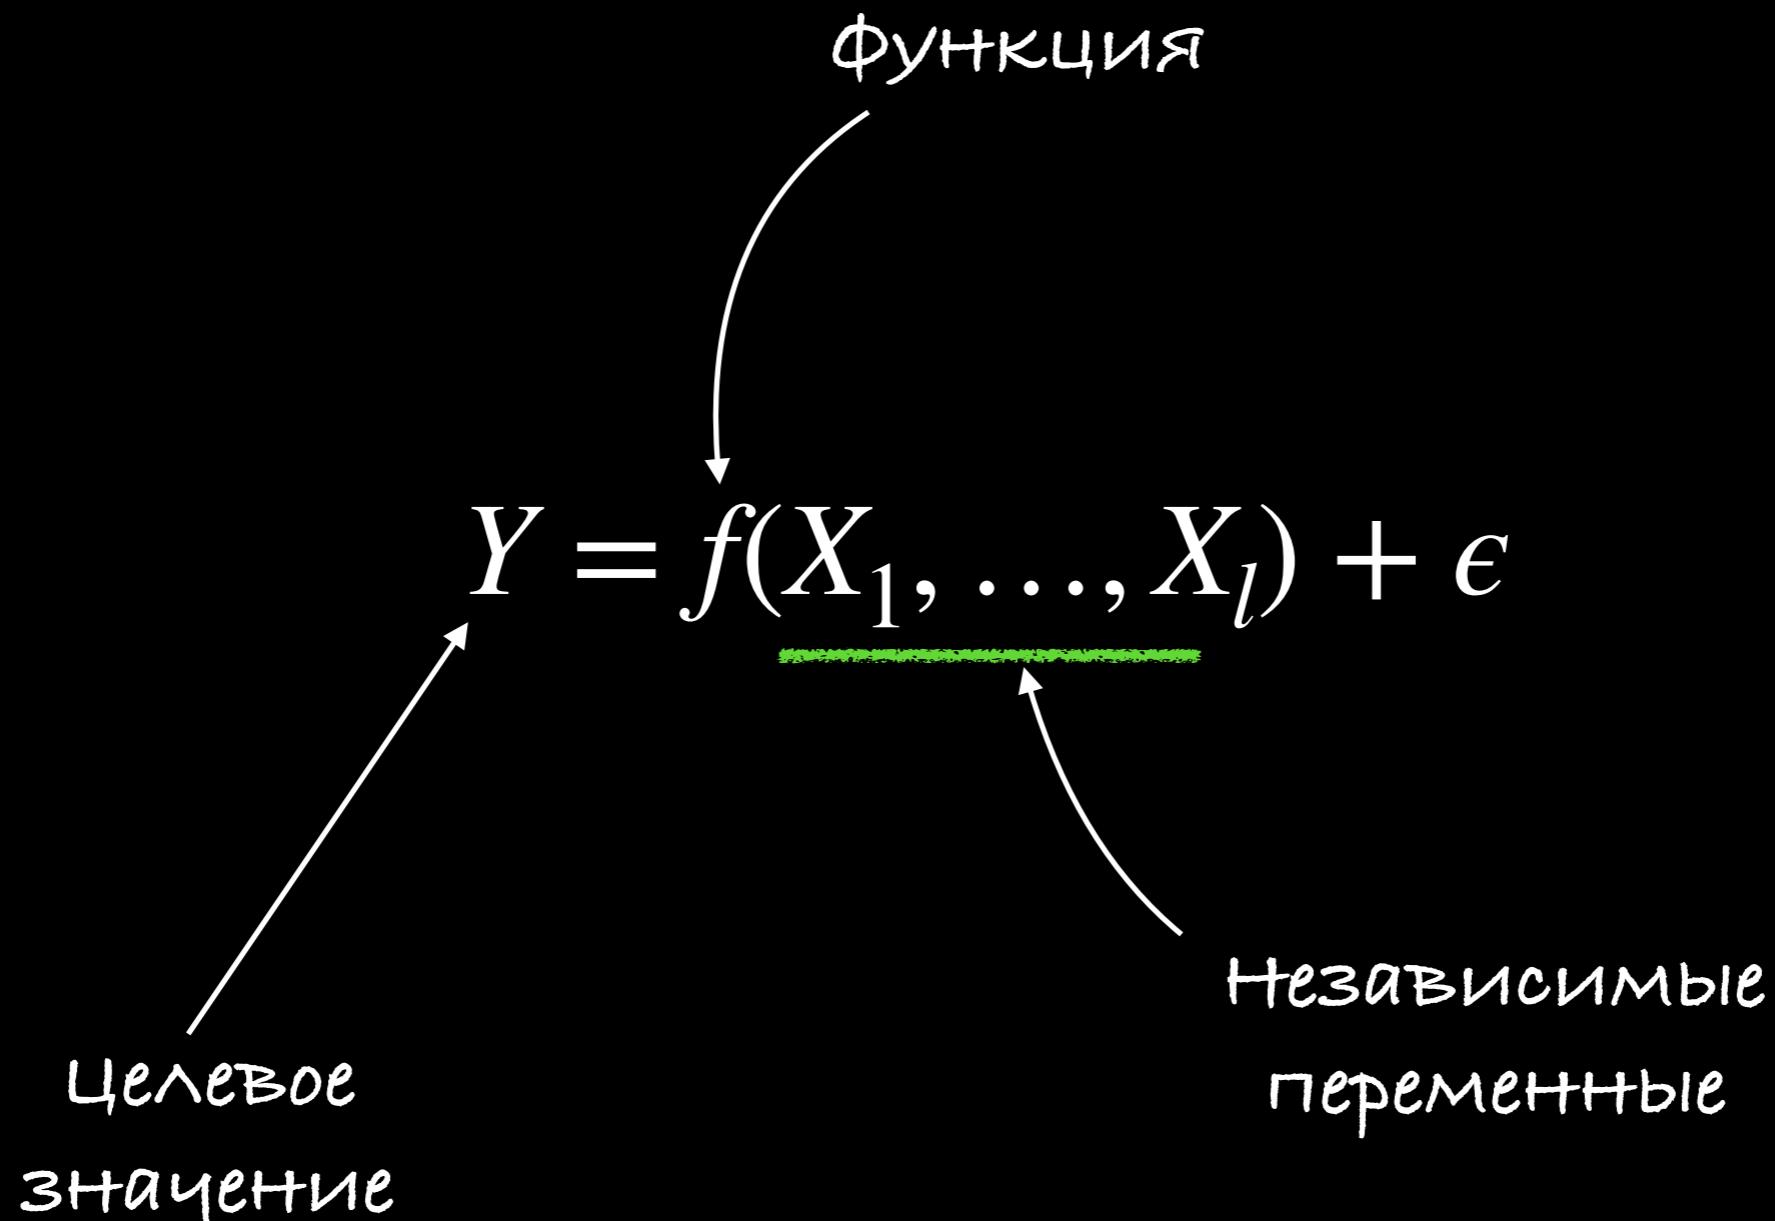
$$Y = f(\underline{X_1, \dots, X_l}) + \epsilon$$

Целевое значение

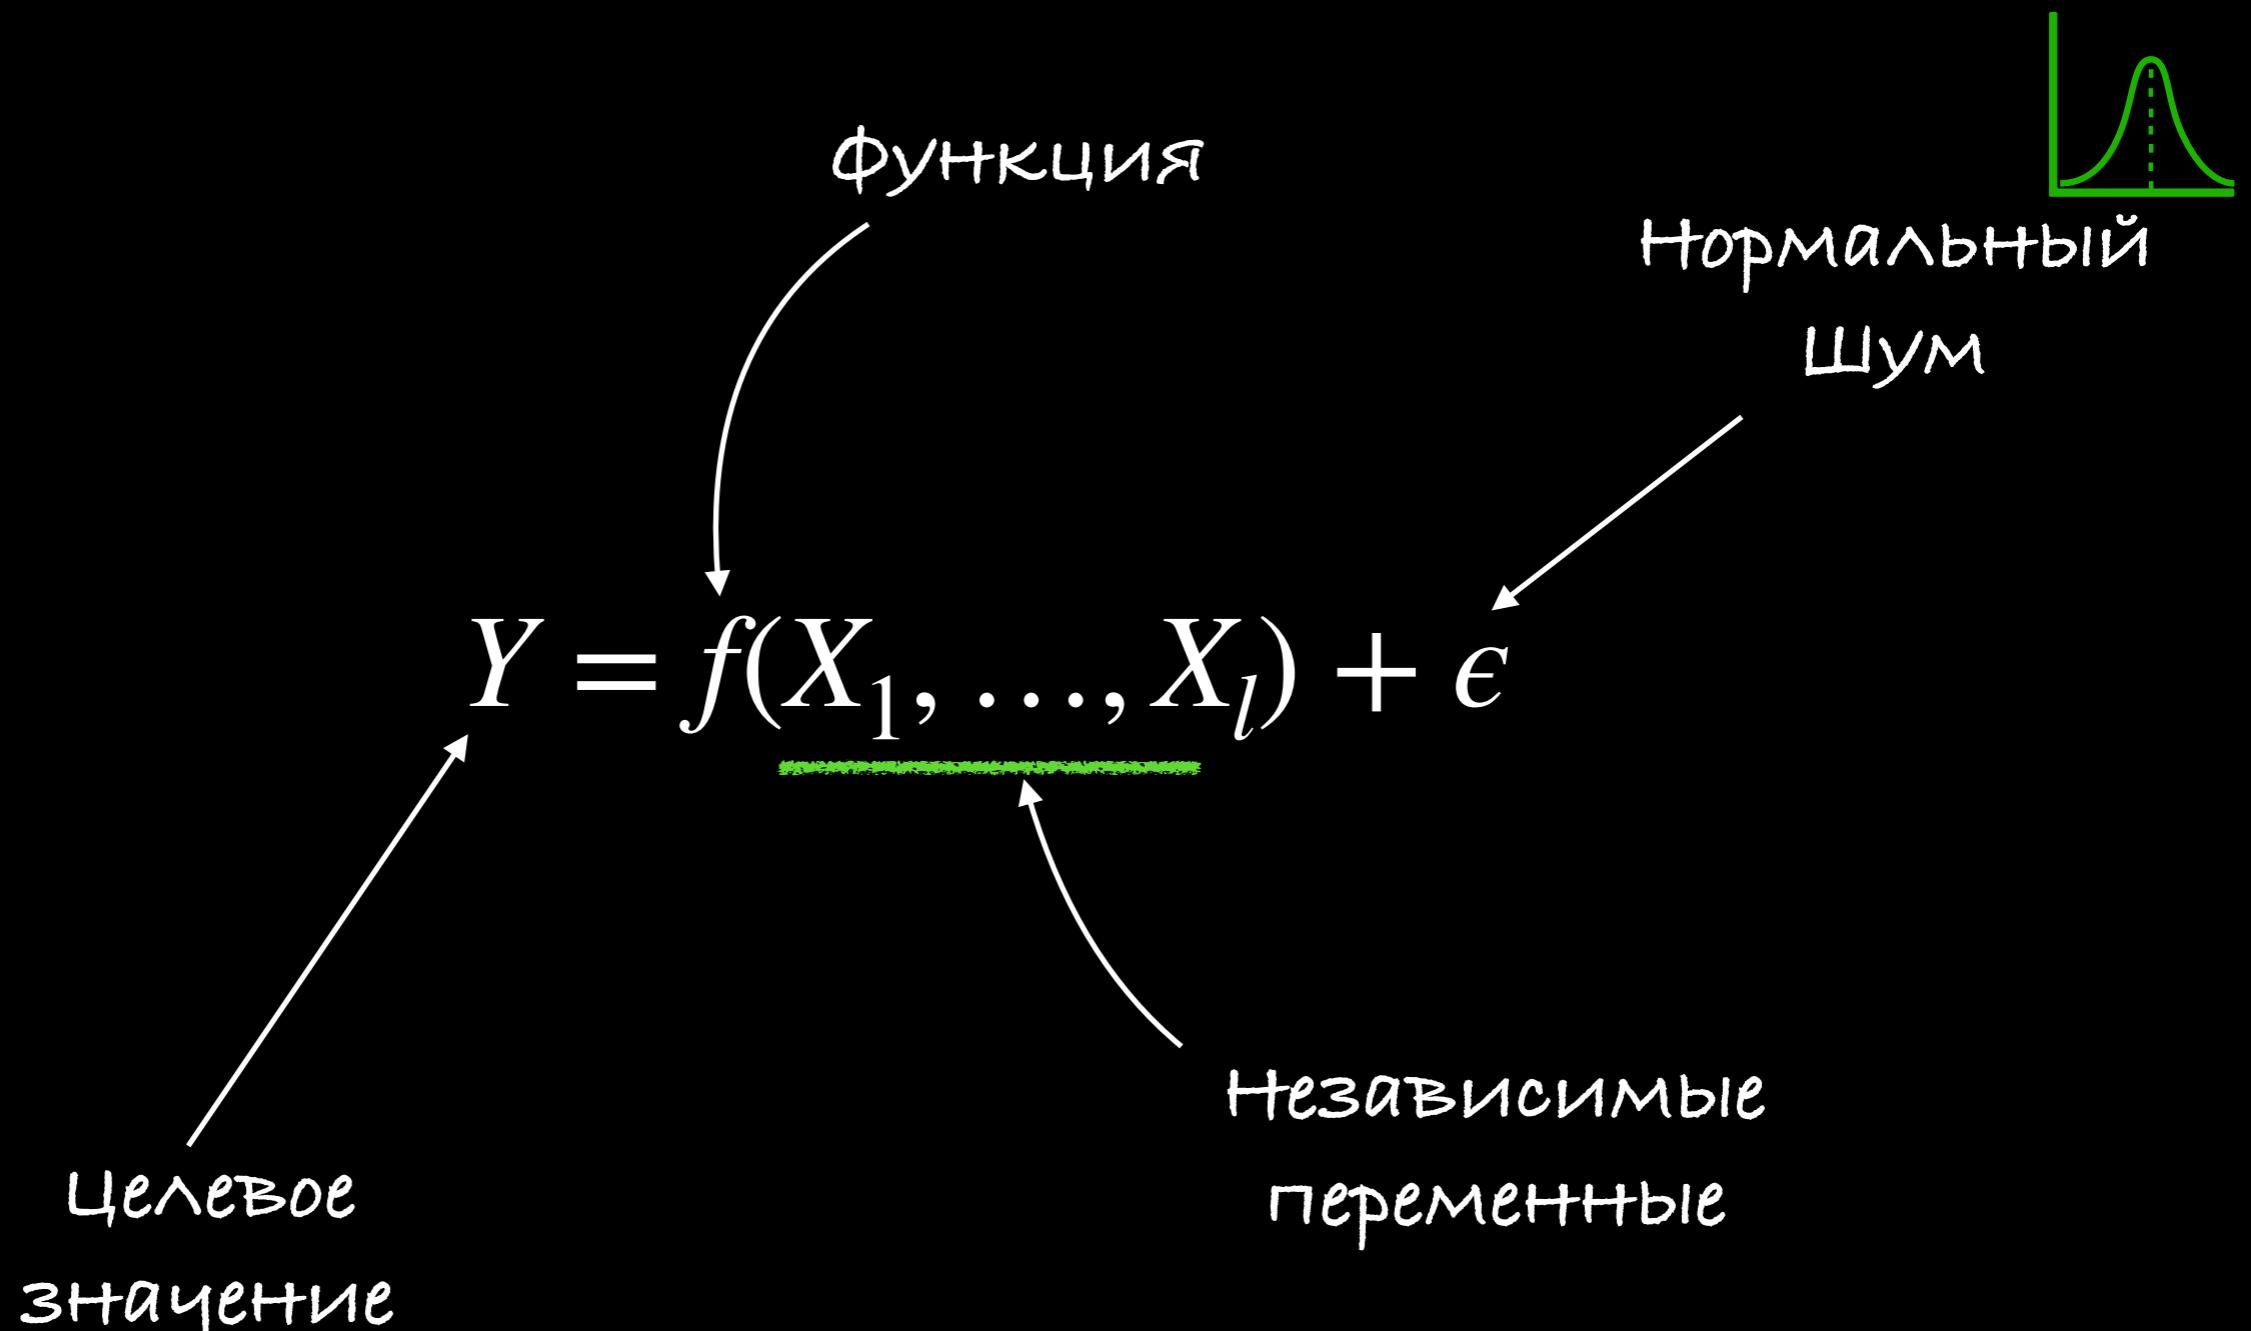
Независимые переменные

The diagram illustrates a regression model. At the top, the equation  $Y = f(\underline{X_1, \dots, X_l}) + \epsilon$  is shown. The variable  $Y$  is labeled "Целевое значение" (Target value) with an arrow pointing to it. The term  $\underline{X_1, \dots, X_l}$  is labeled "Независимые переменные" (Independent variables) with an arrow pointing to it. The label "Независимые переменные" is placed below the term  $X_1, \dots, X_l$  in the equation.

# Постановка задачи



# Постановка задачи



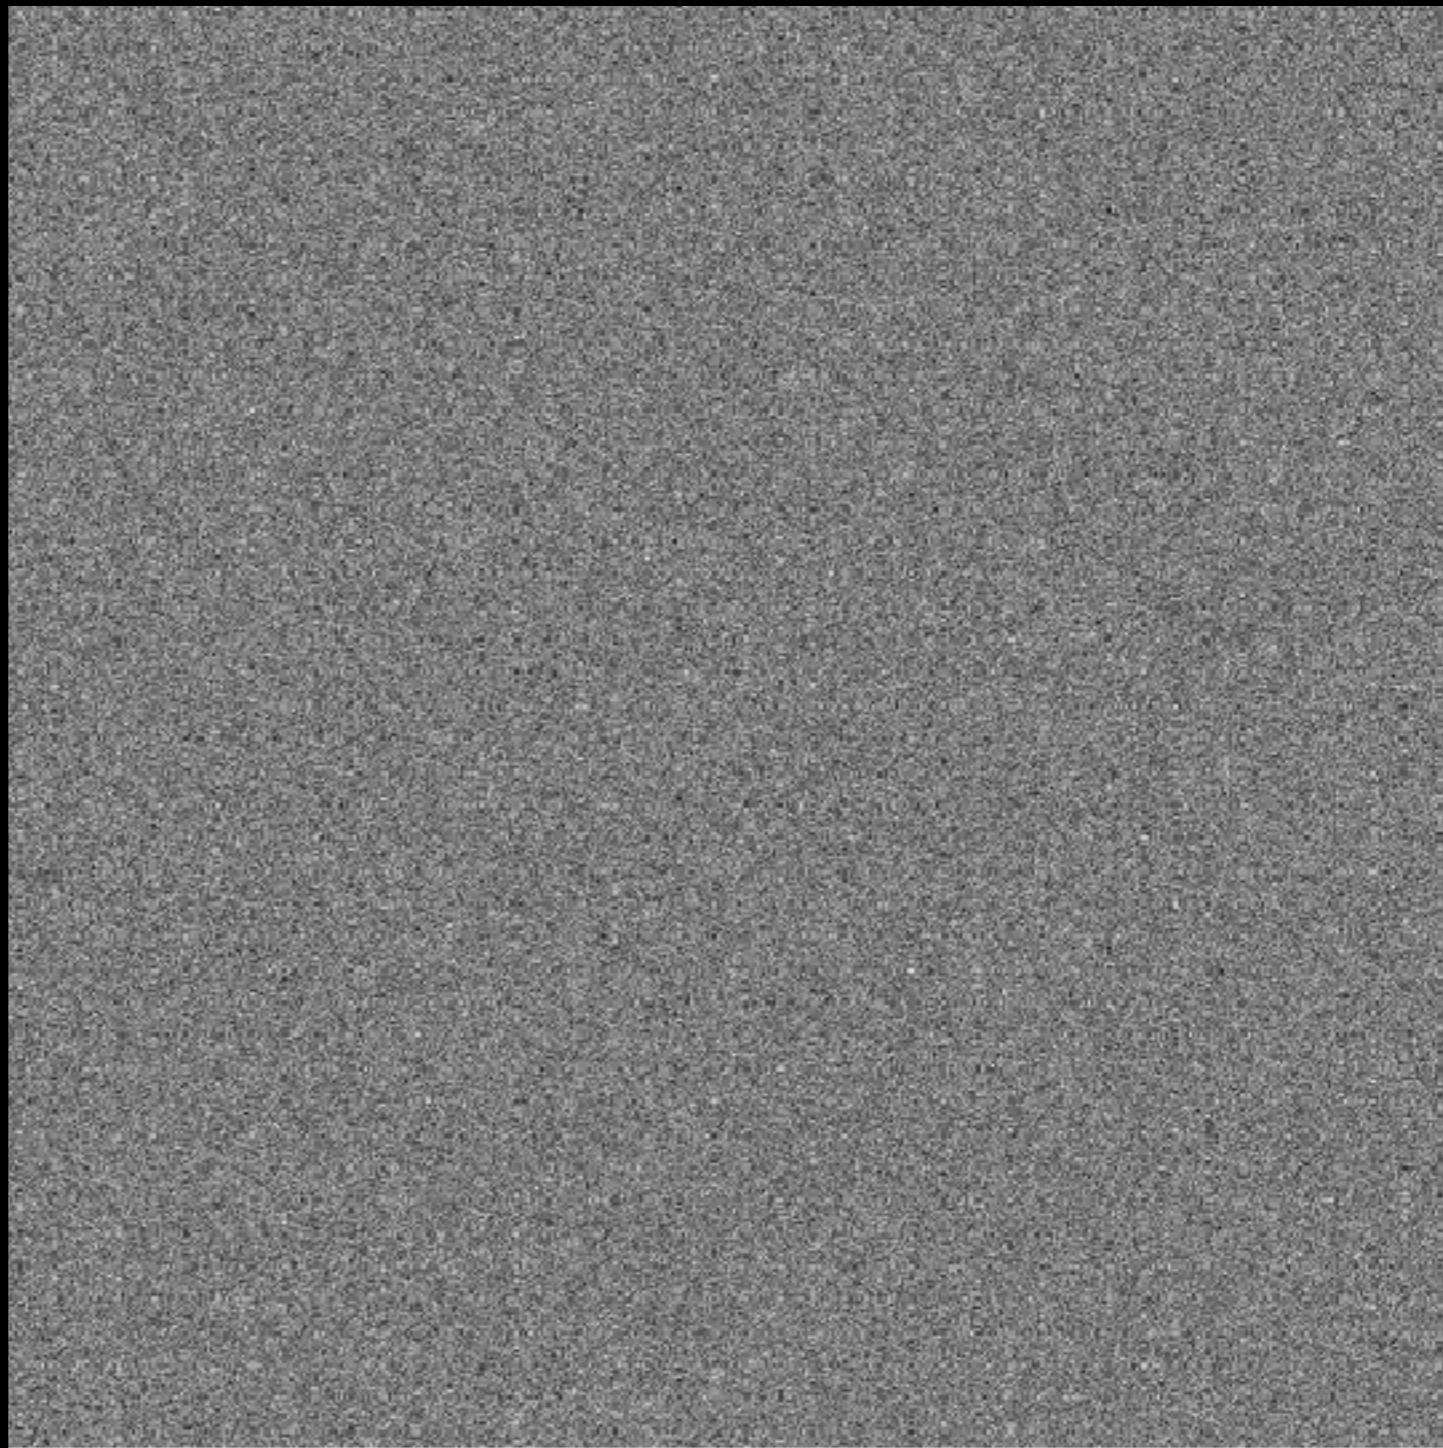
Самое простое F?

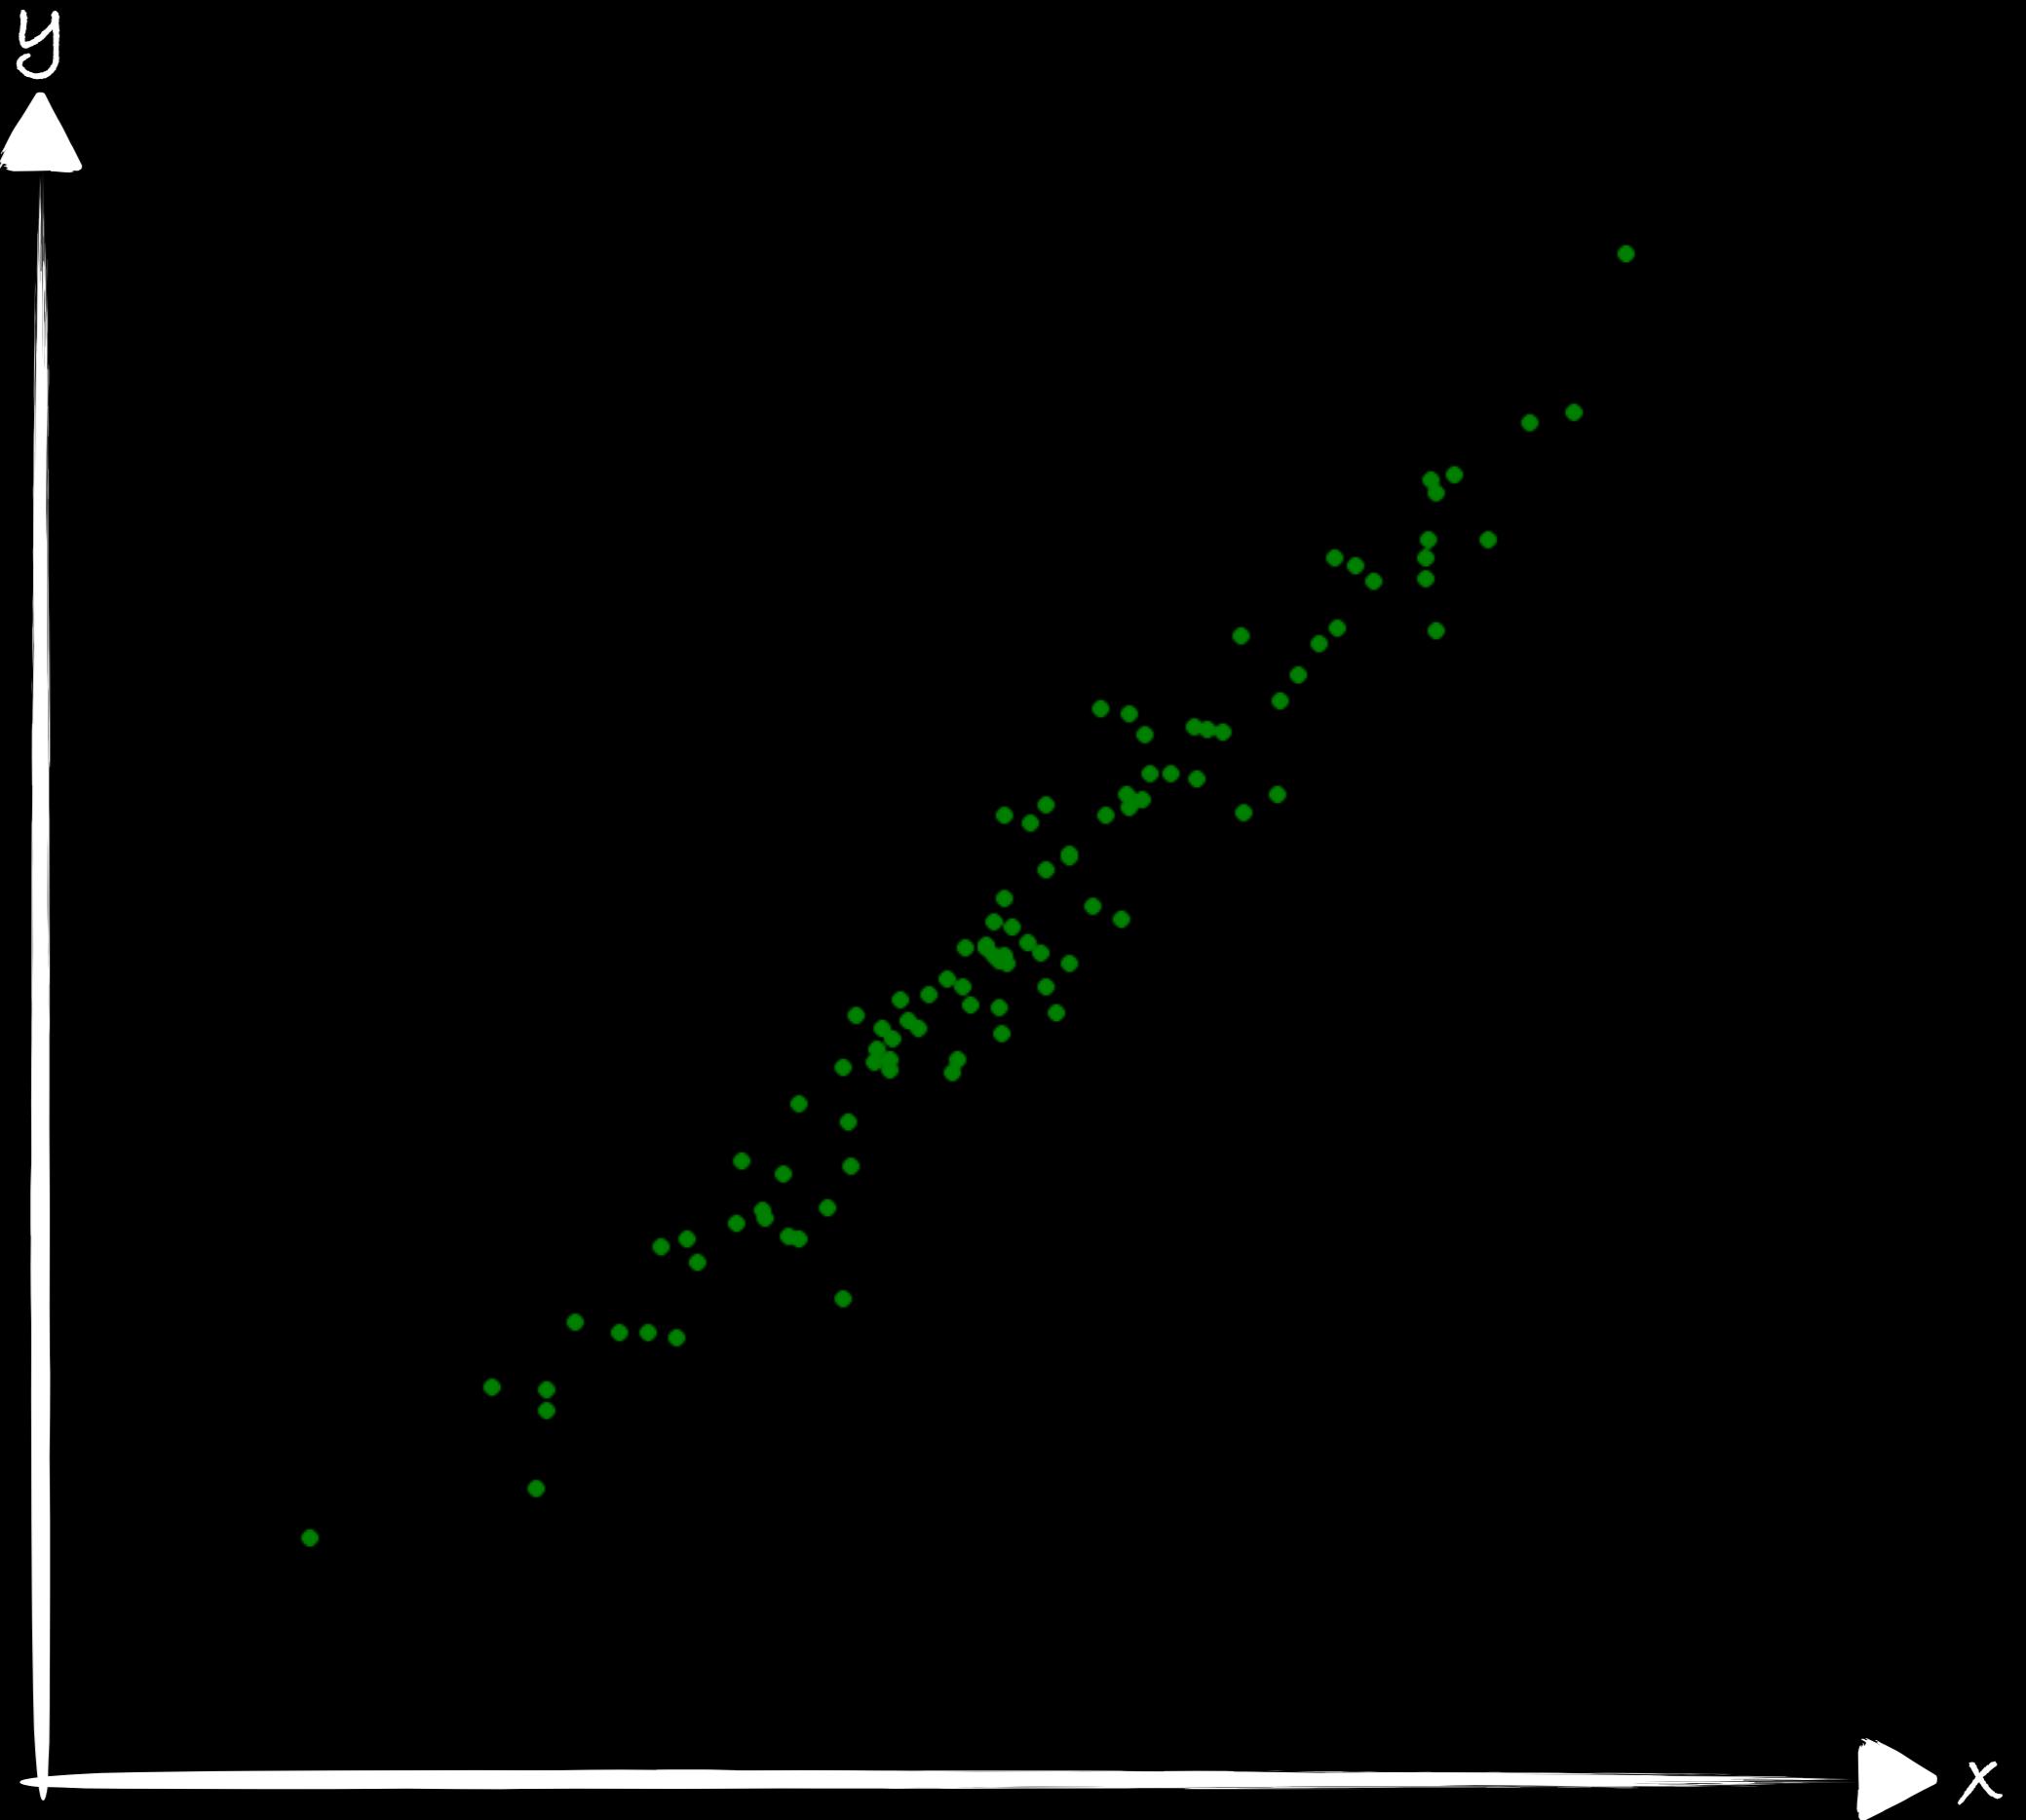
# Константа!

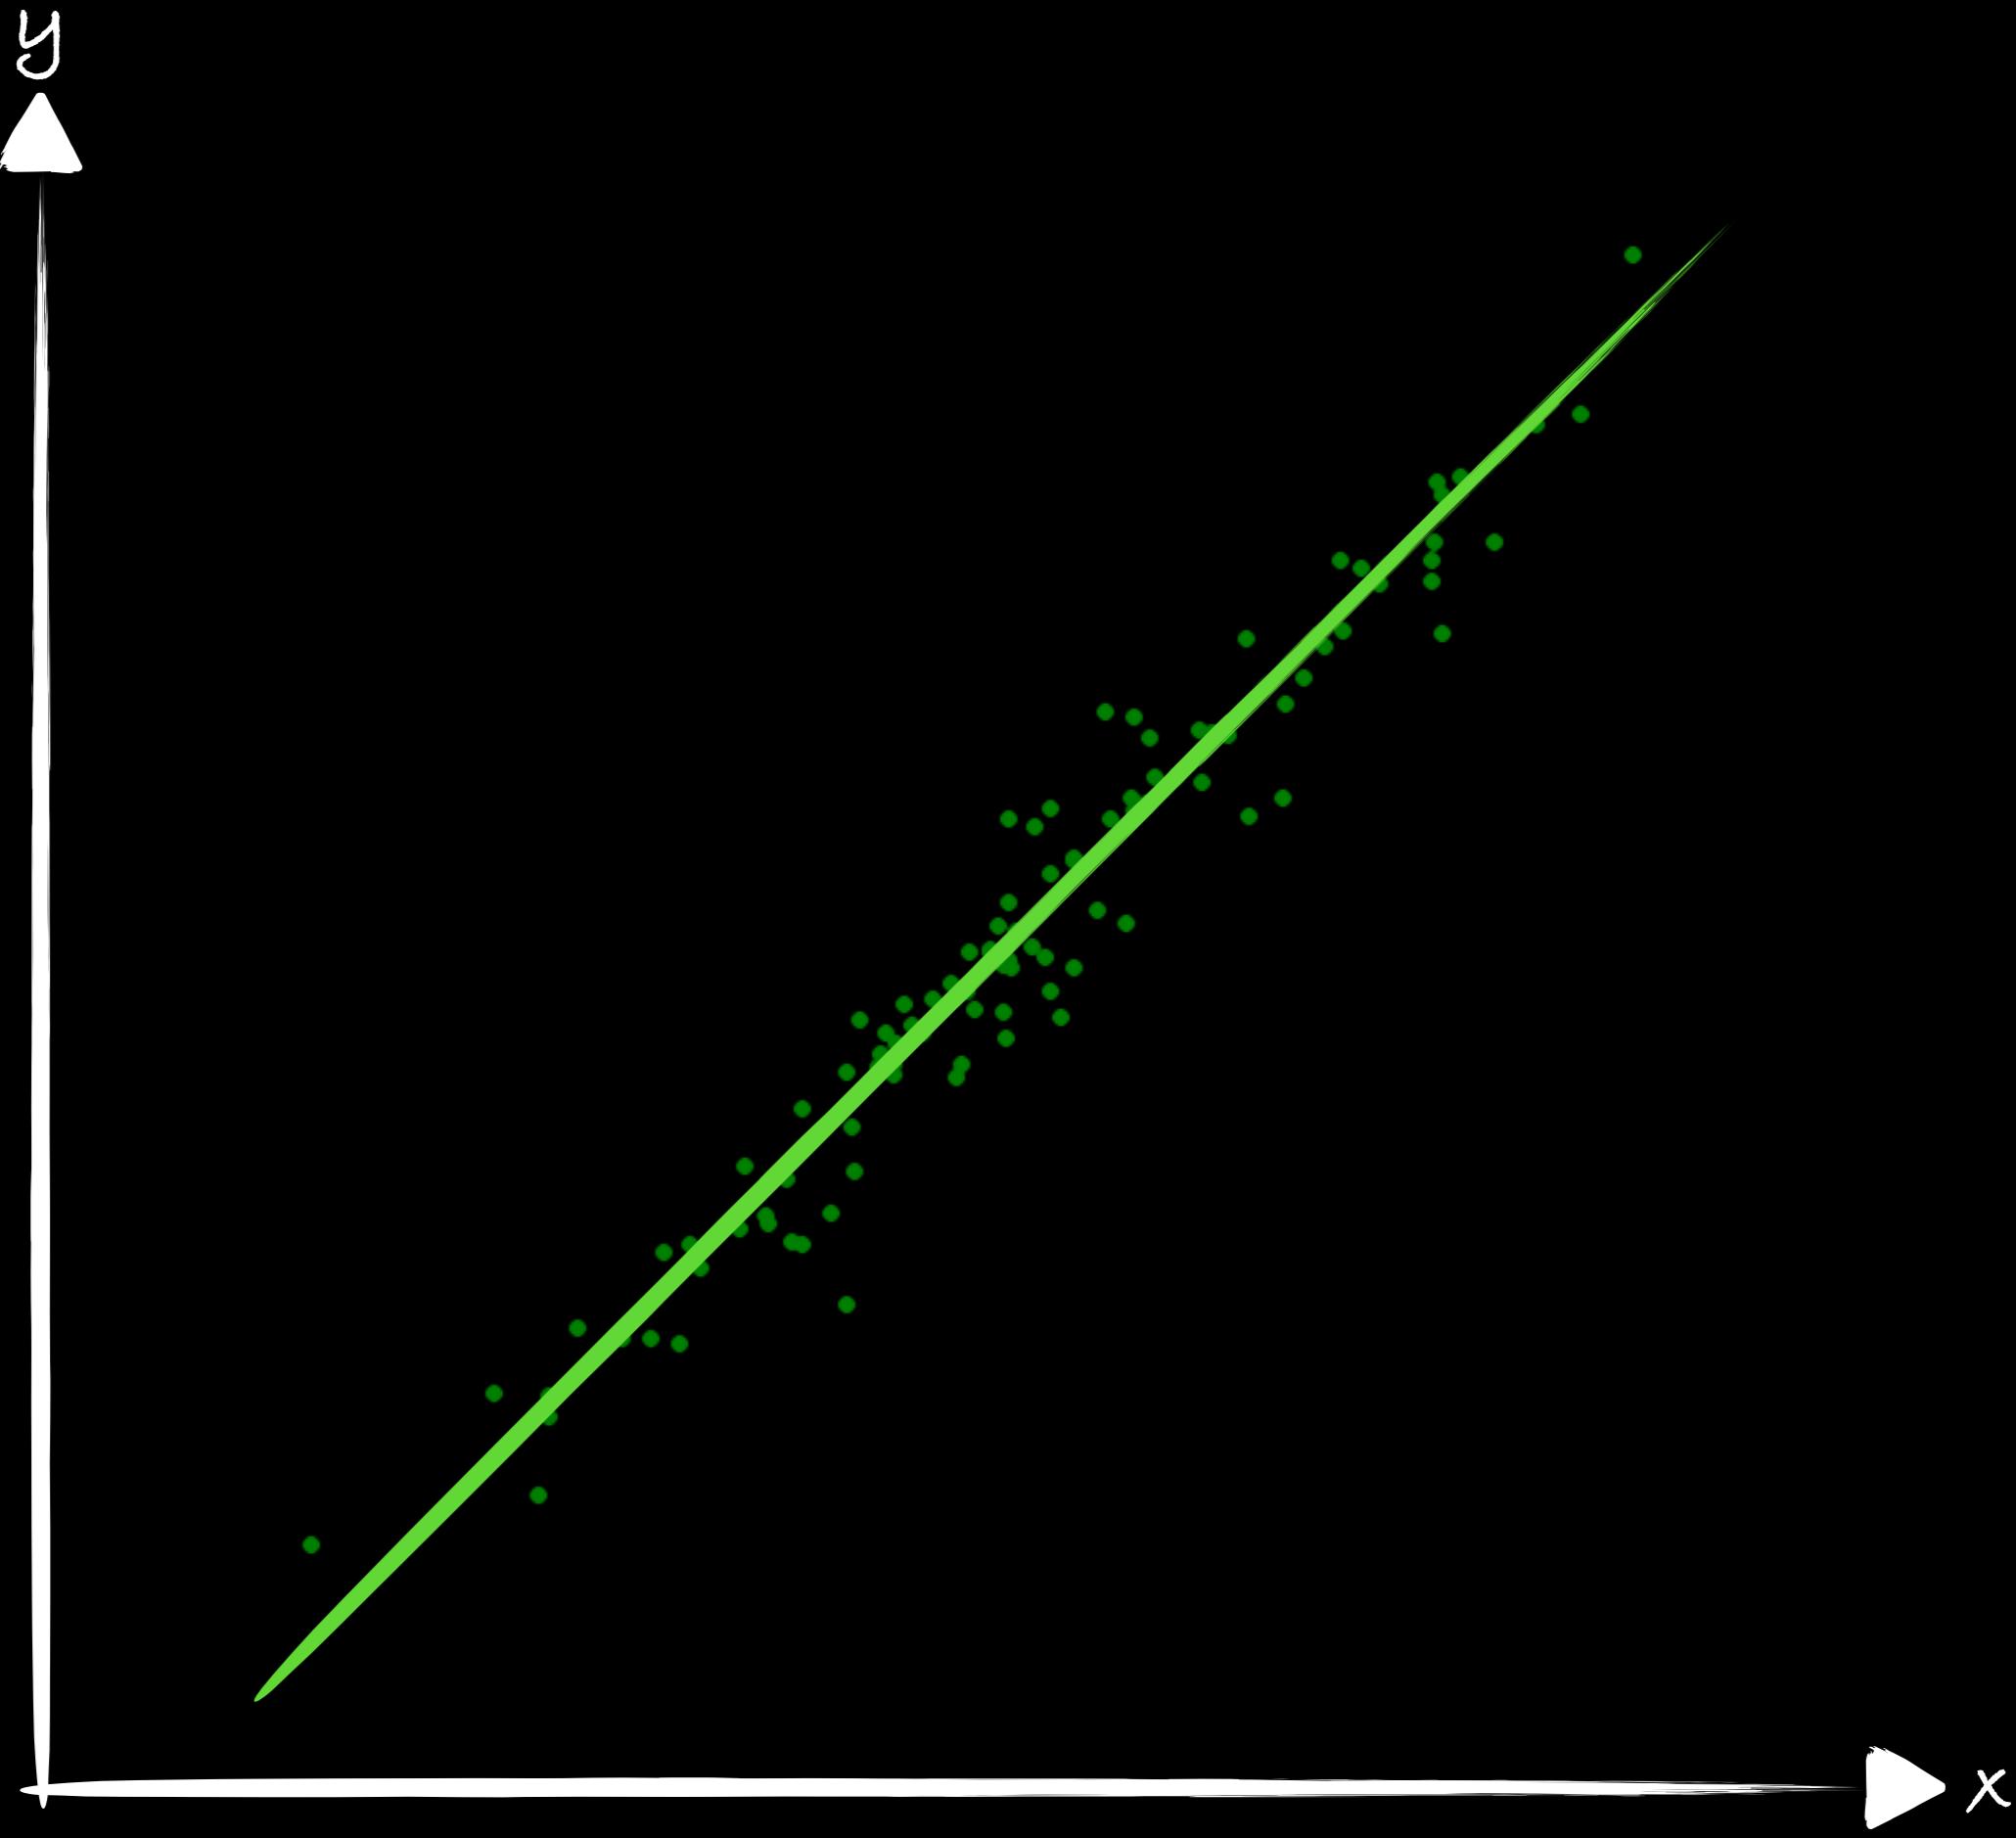
$$f(X) = 5$$

Сложнее, но также бесполезно?

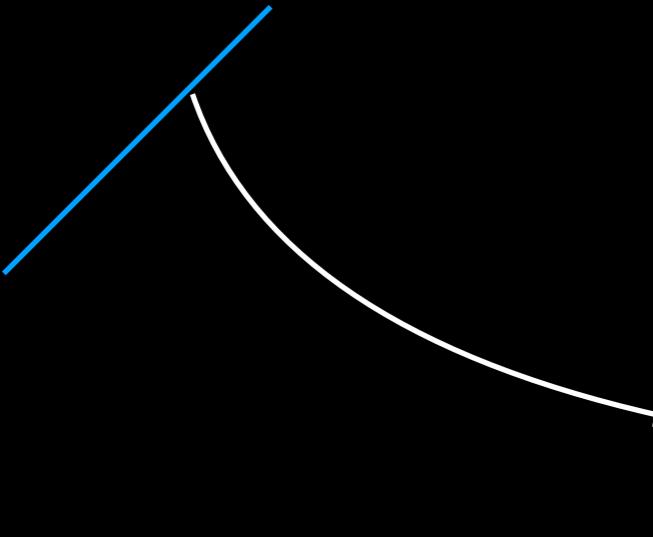
$f(X) =$

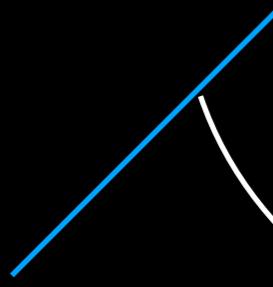






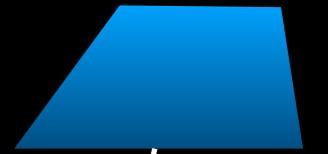


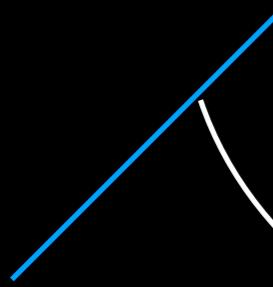

$$y = ax + b$$



$$y = ax + b$$

$$y = a_1x_1 + a_2x_2 + b$$



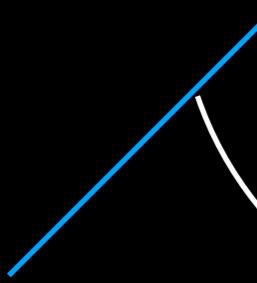


$$y = ax + b$$

$$y = a_1x_1 + a_2x_2 + b$$

• • •





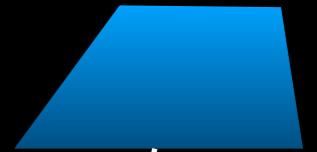
$$y = ax + b$$

$$y = a_1x_1 + a_2x_2 + b$$

⋮

$$Y = Xa + b$$

Плоскость в N-мерном  
пространстве





Магистратура

# Магистратура



# Магистратура

## Ожидаемые баллы



# Магистратура

## Ожидаемые баллы

Результаты прошлых лет



# Магистратура

## Ожидаемые баллы

Результаты прошлых лет

Количество мест





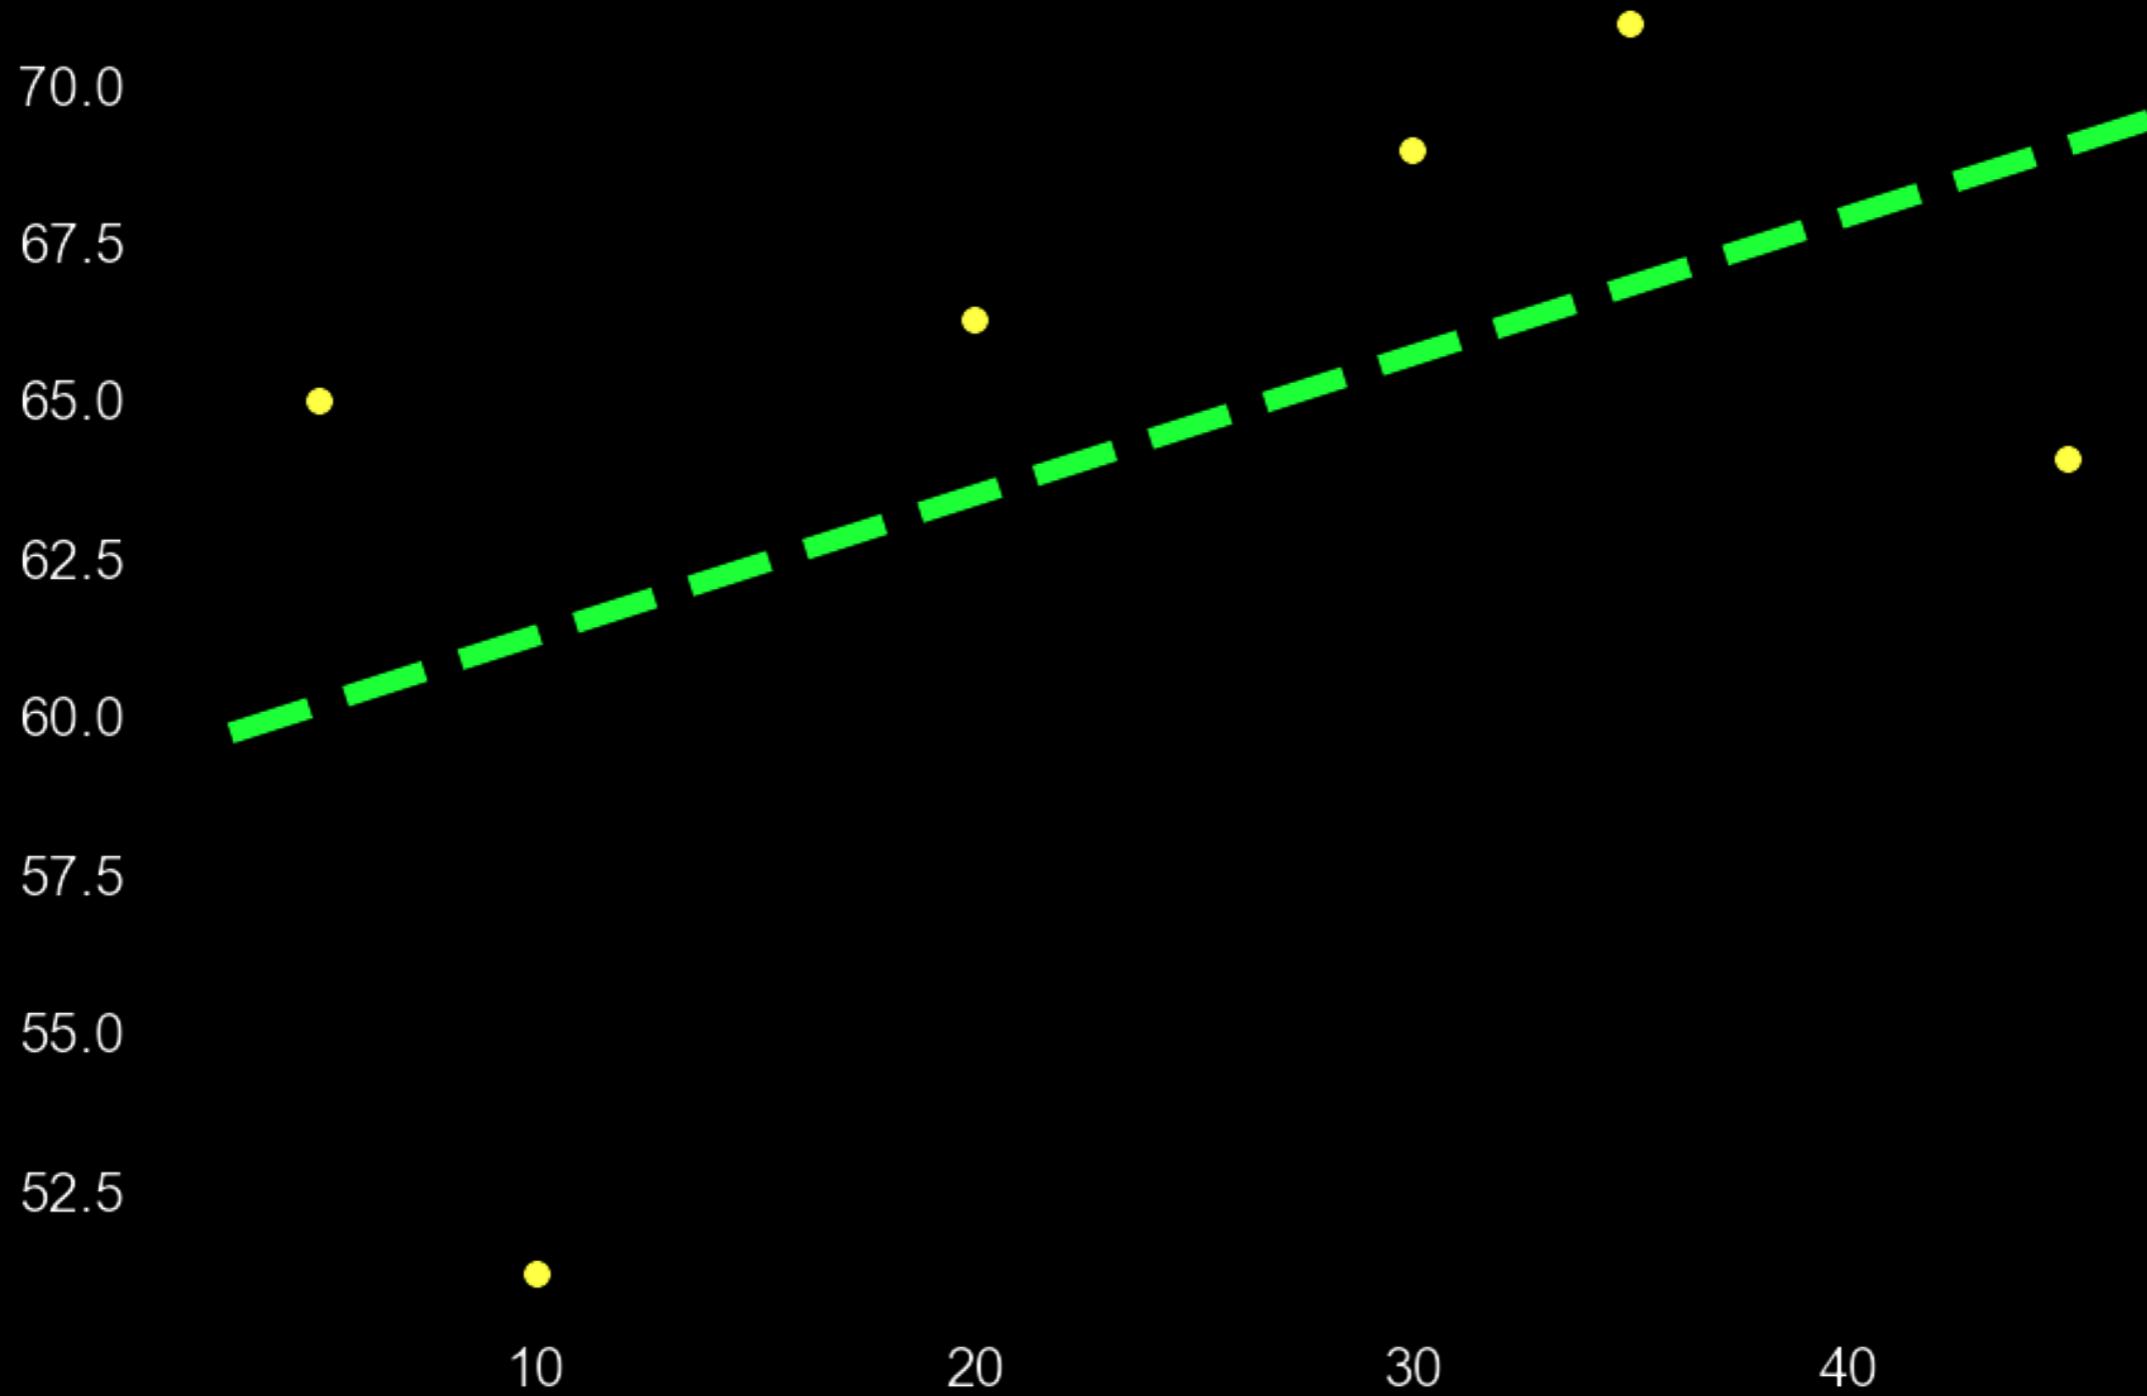
Магистратура

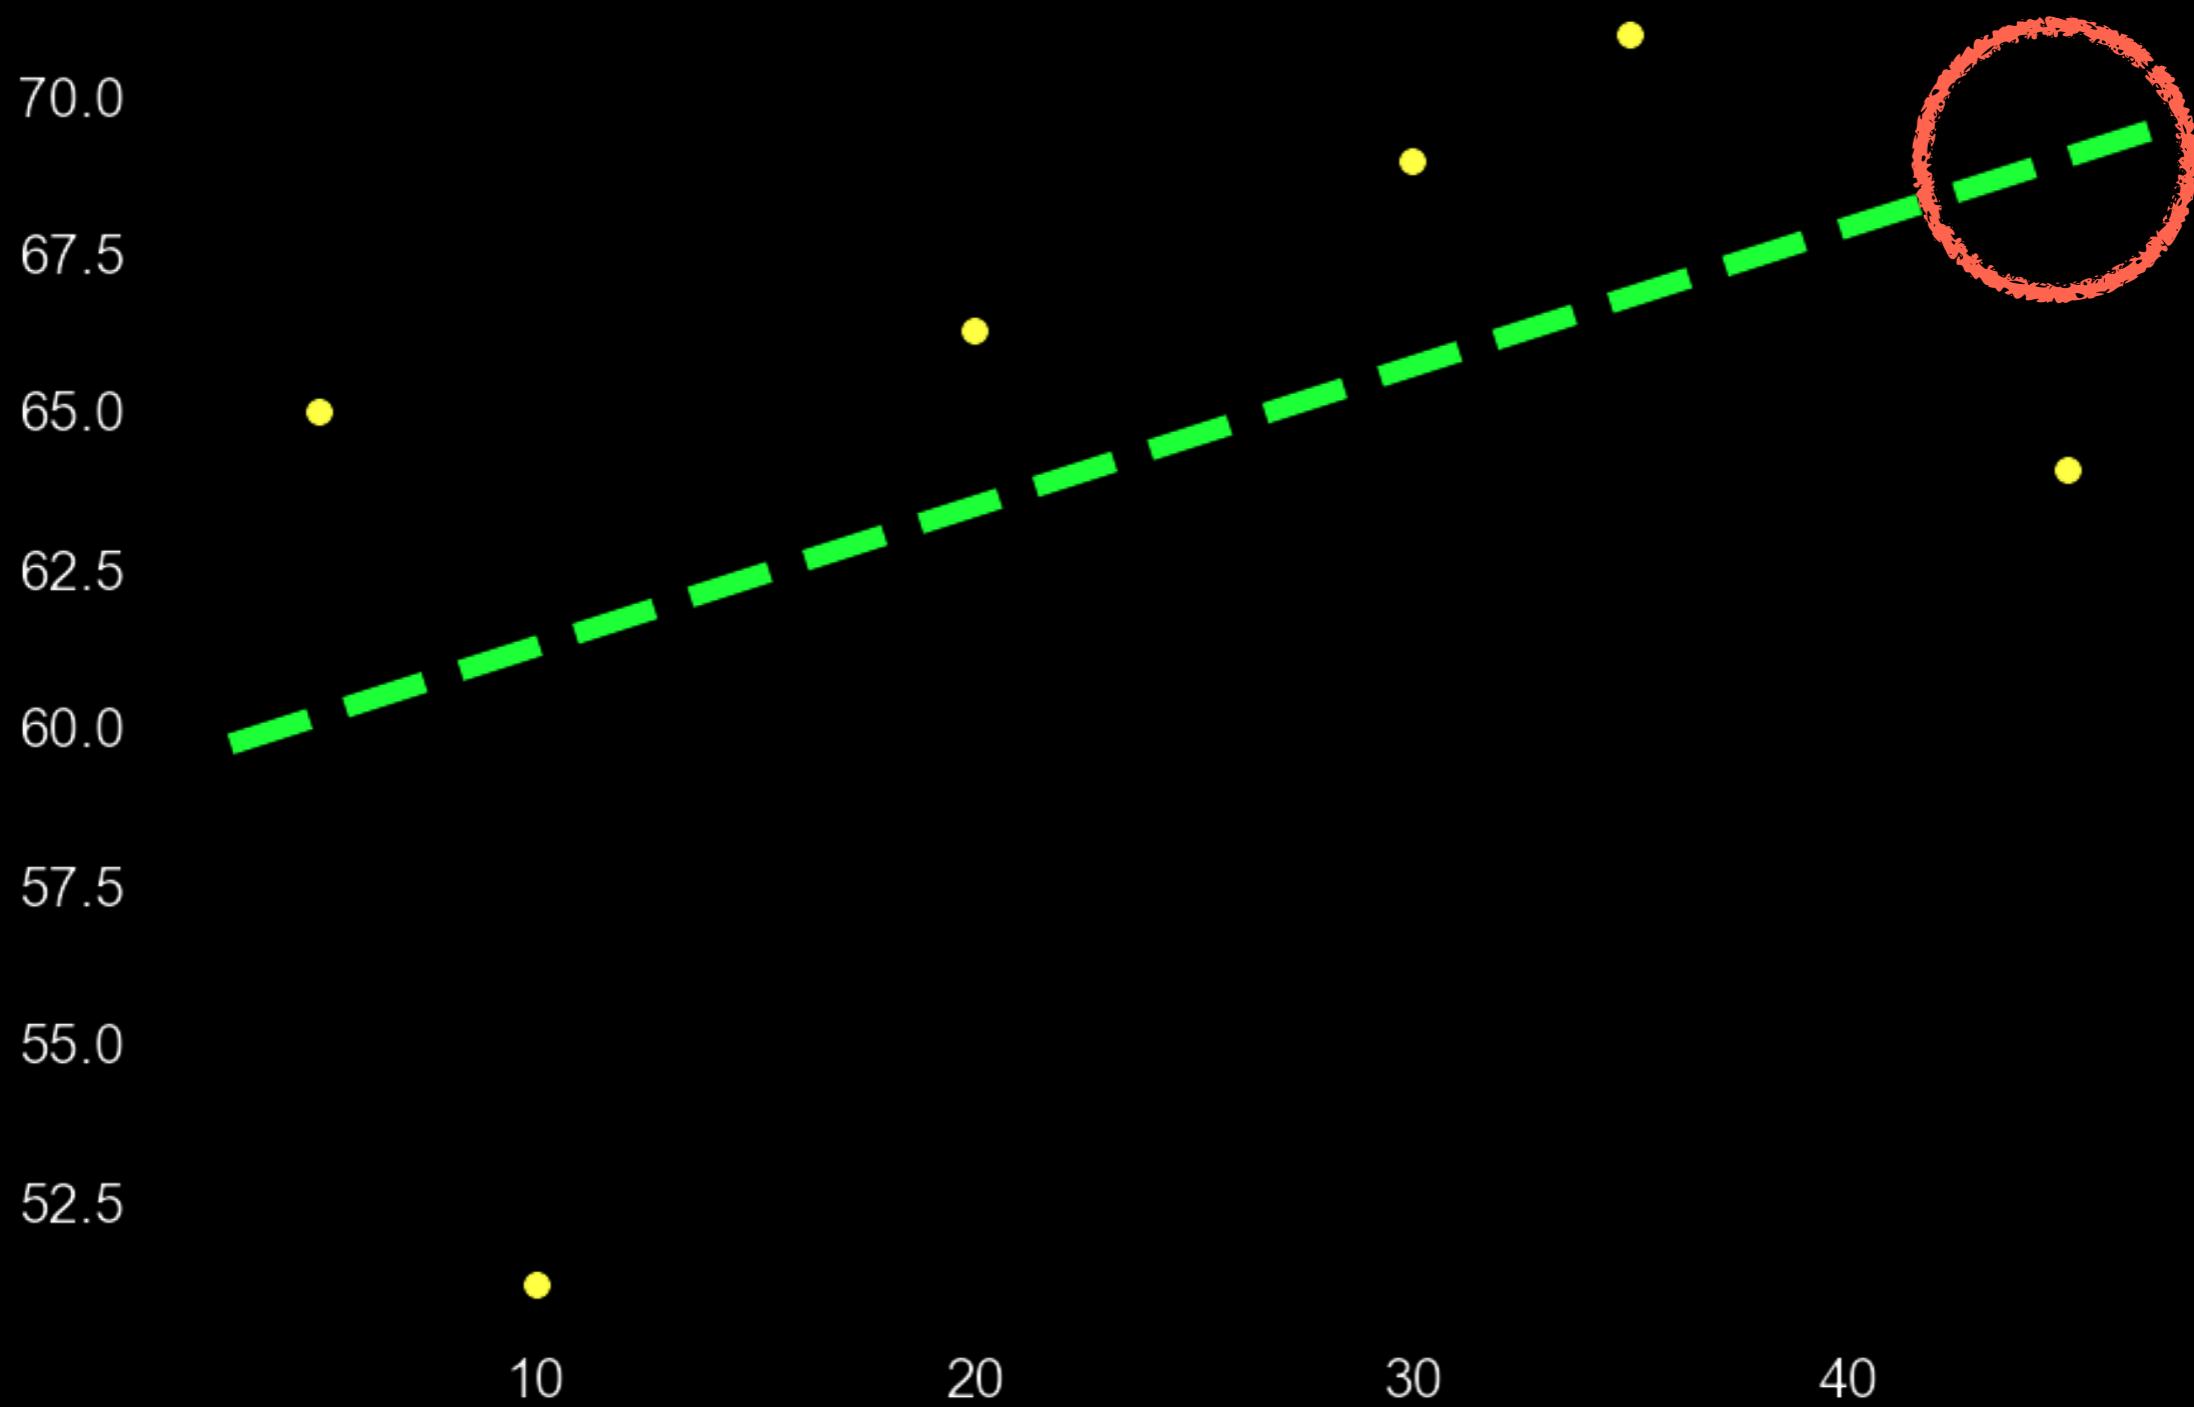
Ожидаемые баллы

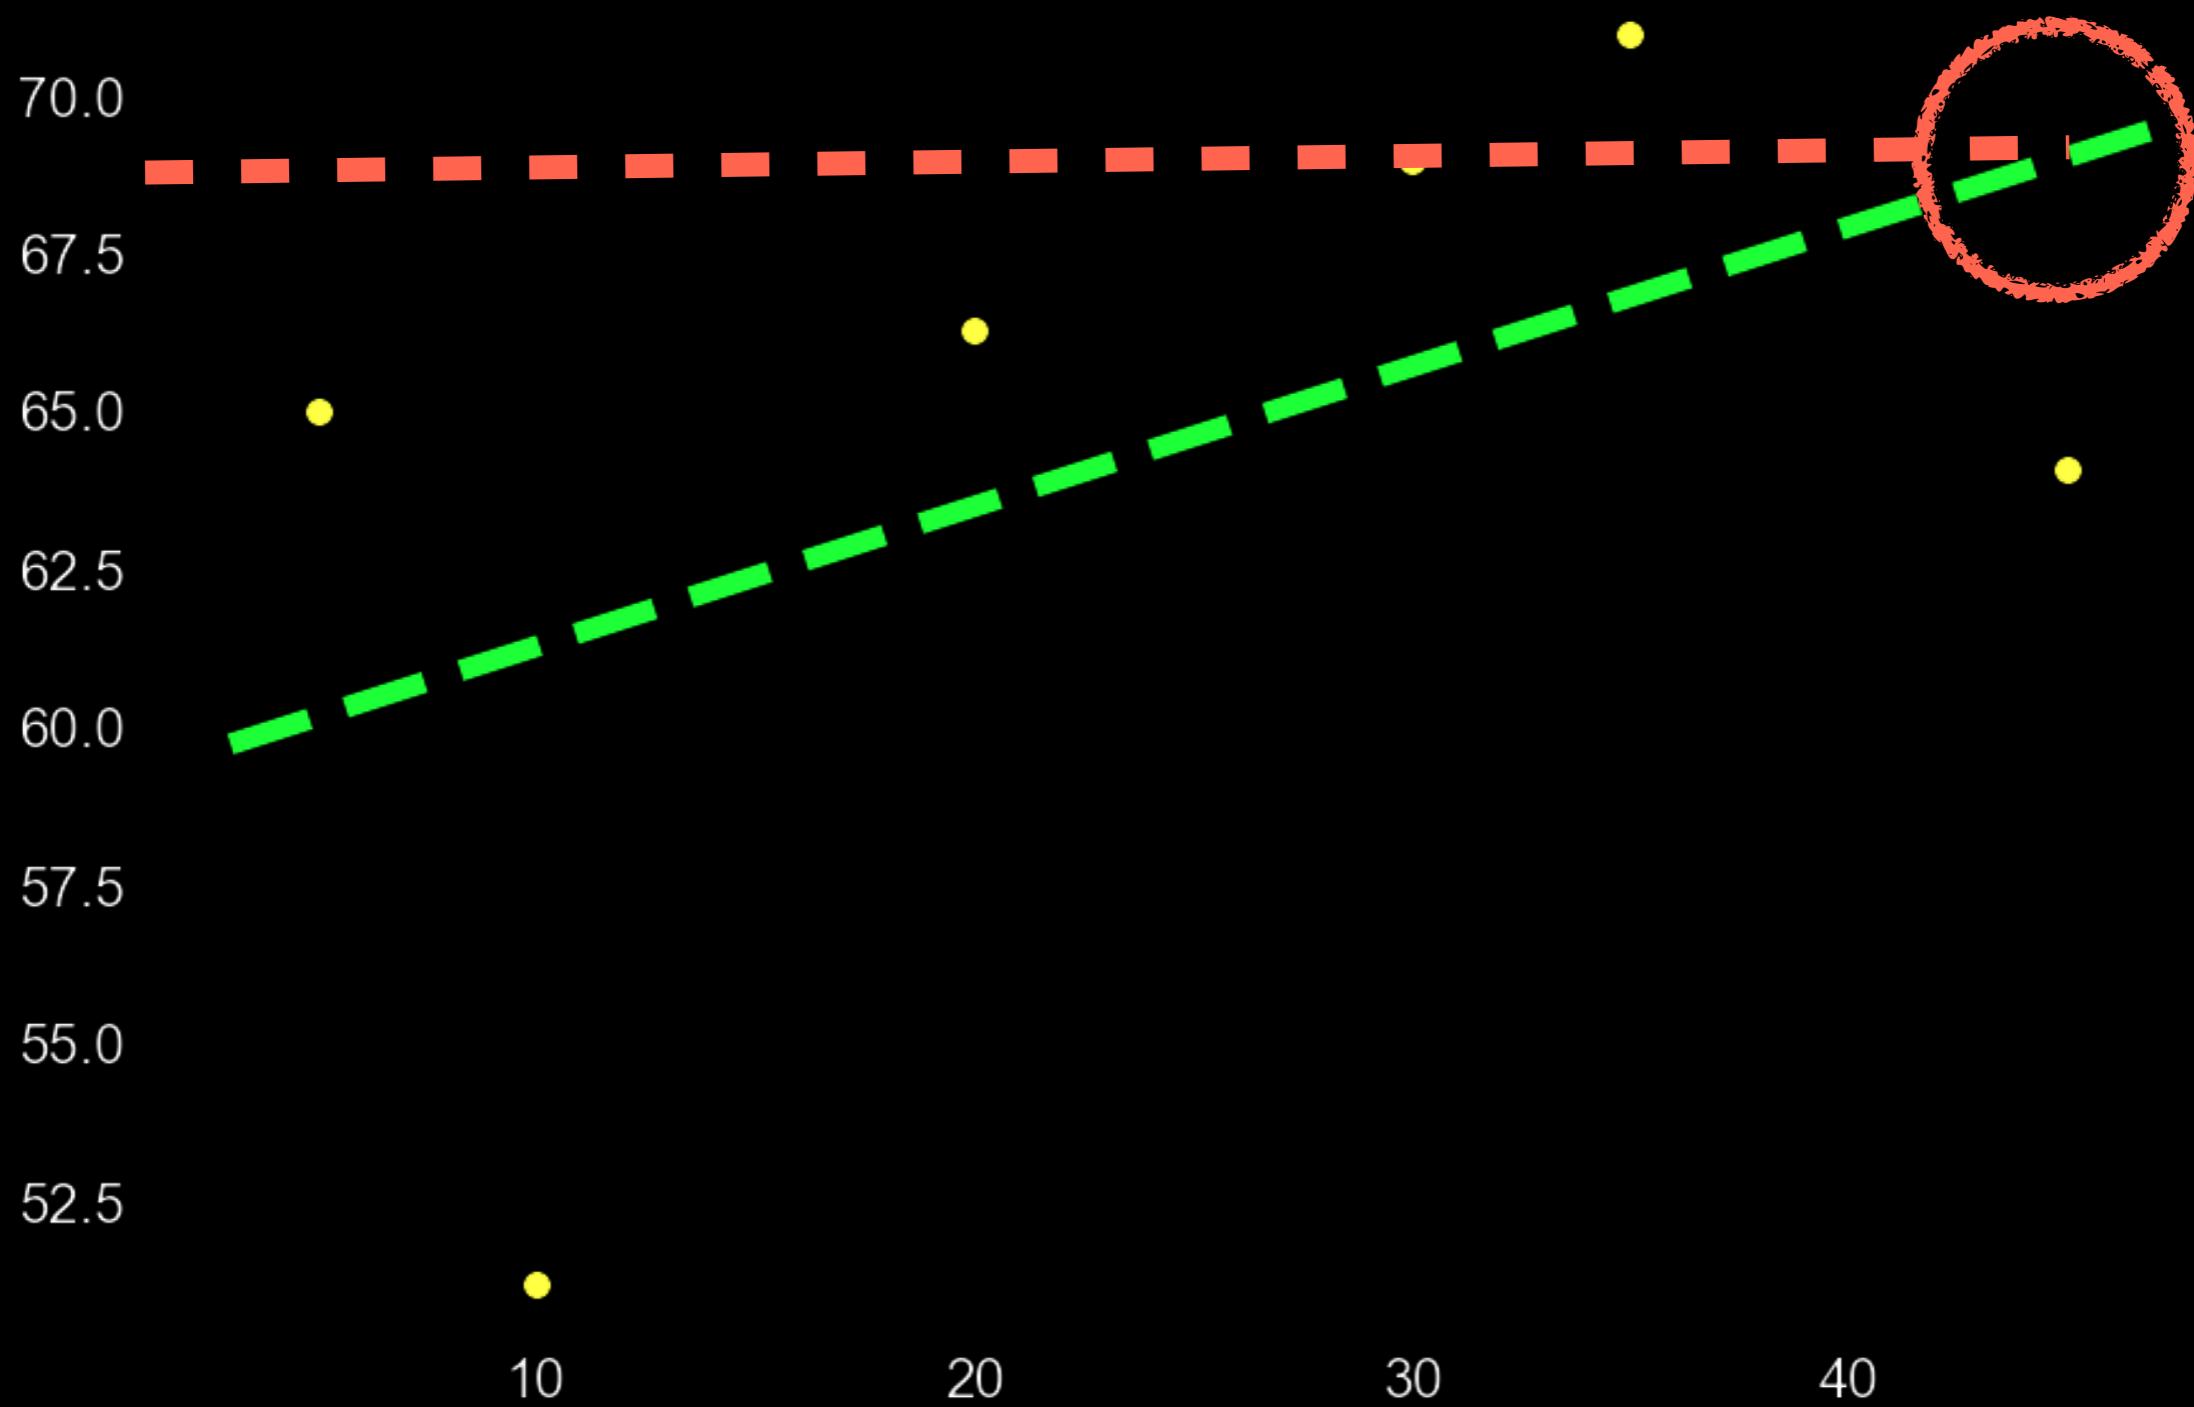
Результаты прошлых лет

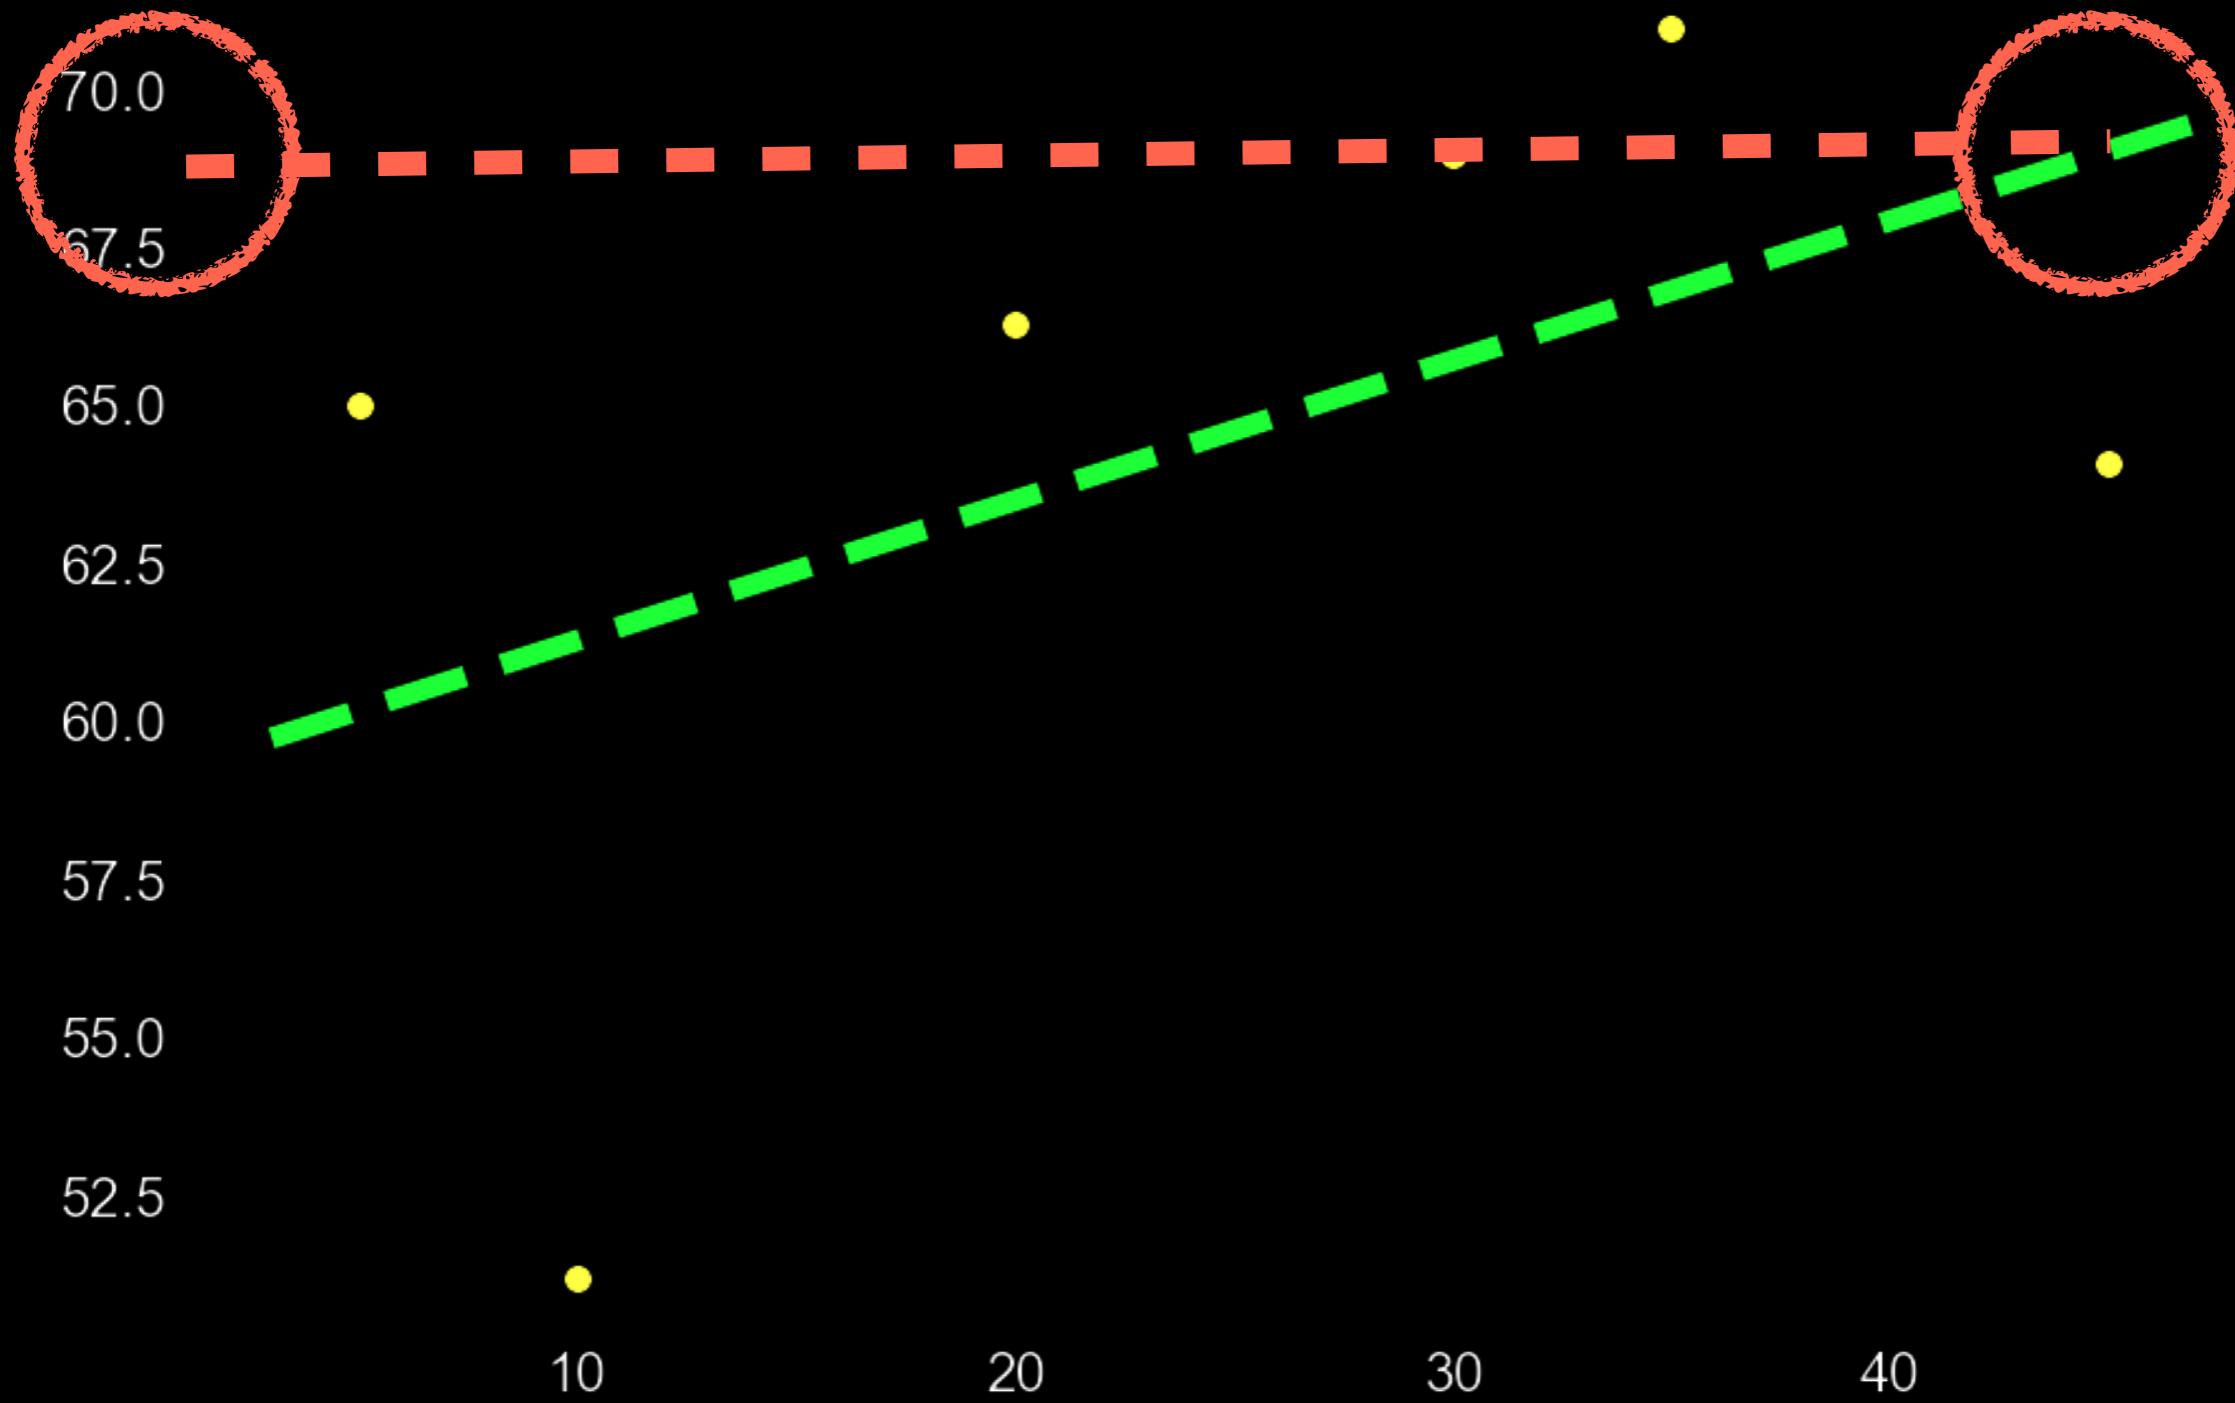
Количество мест

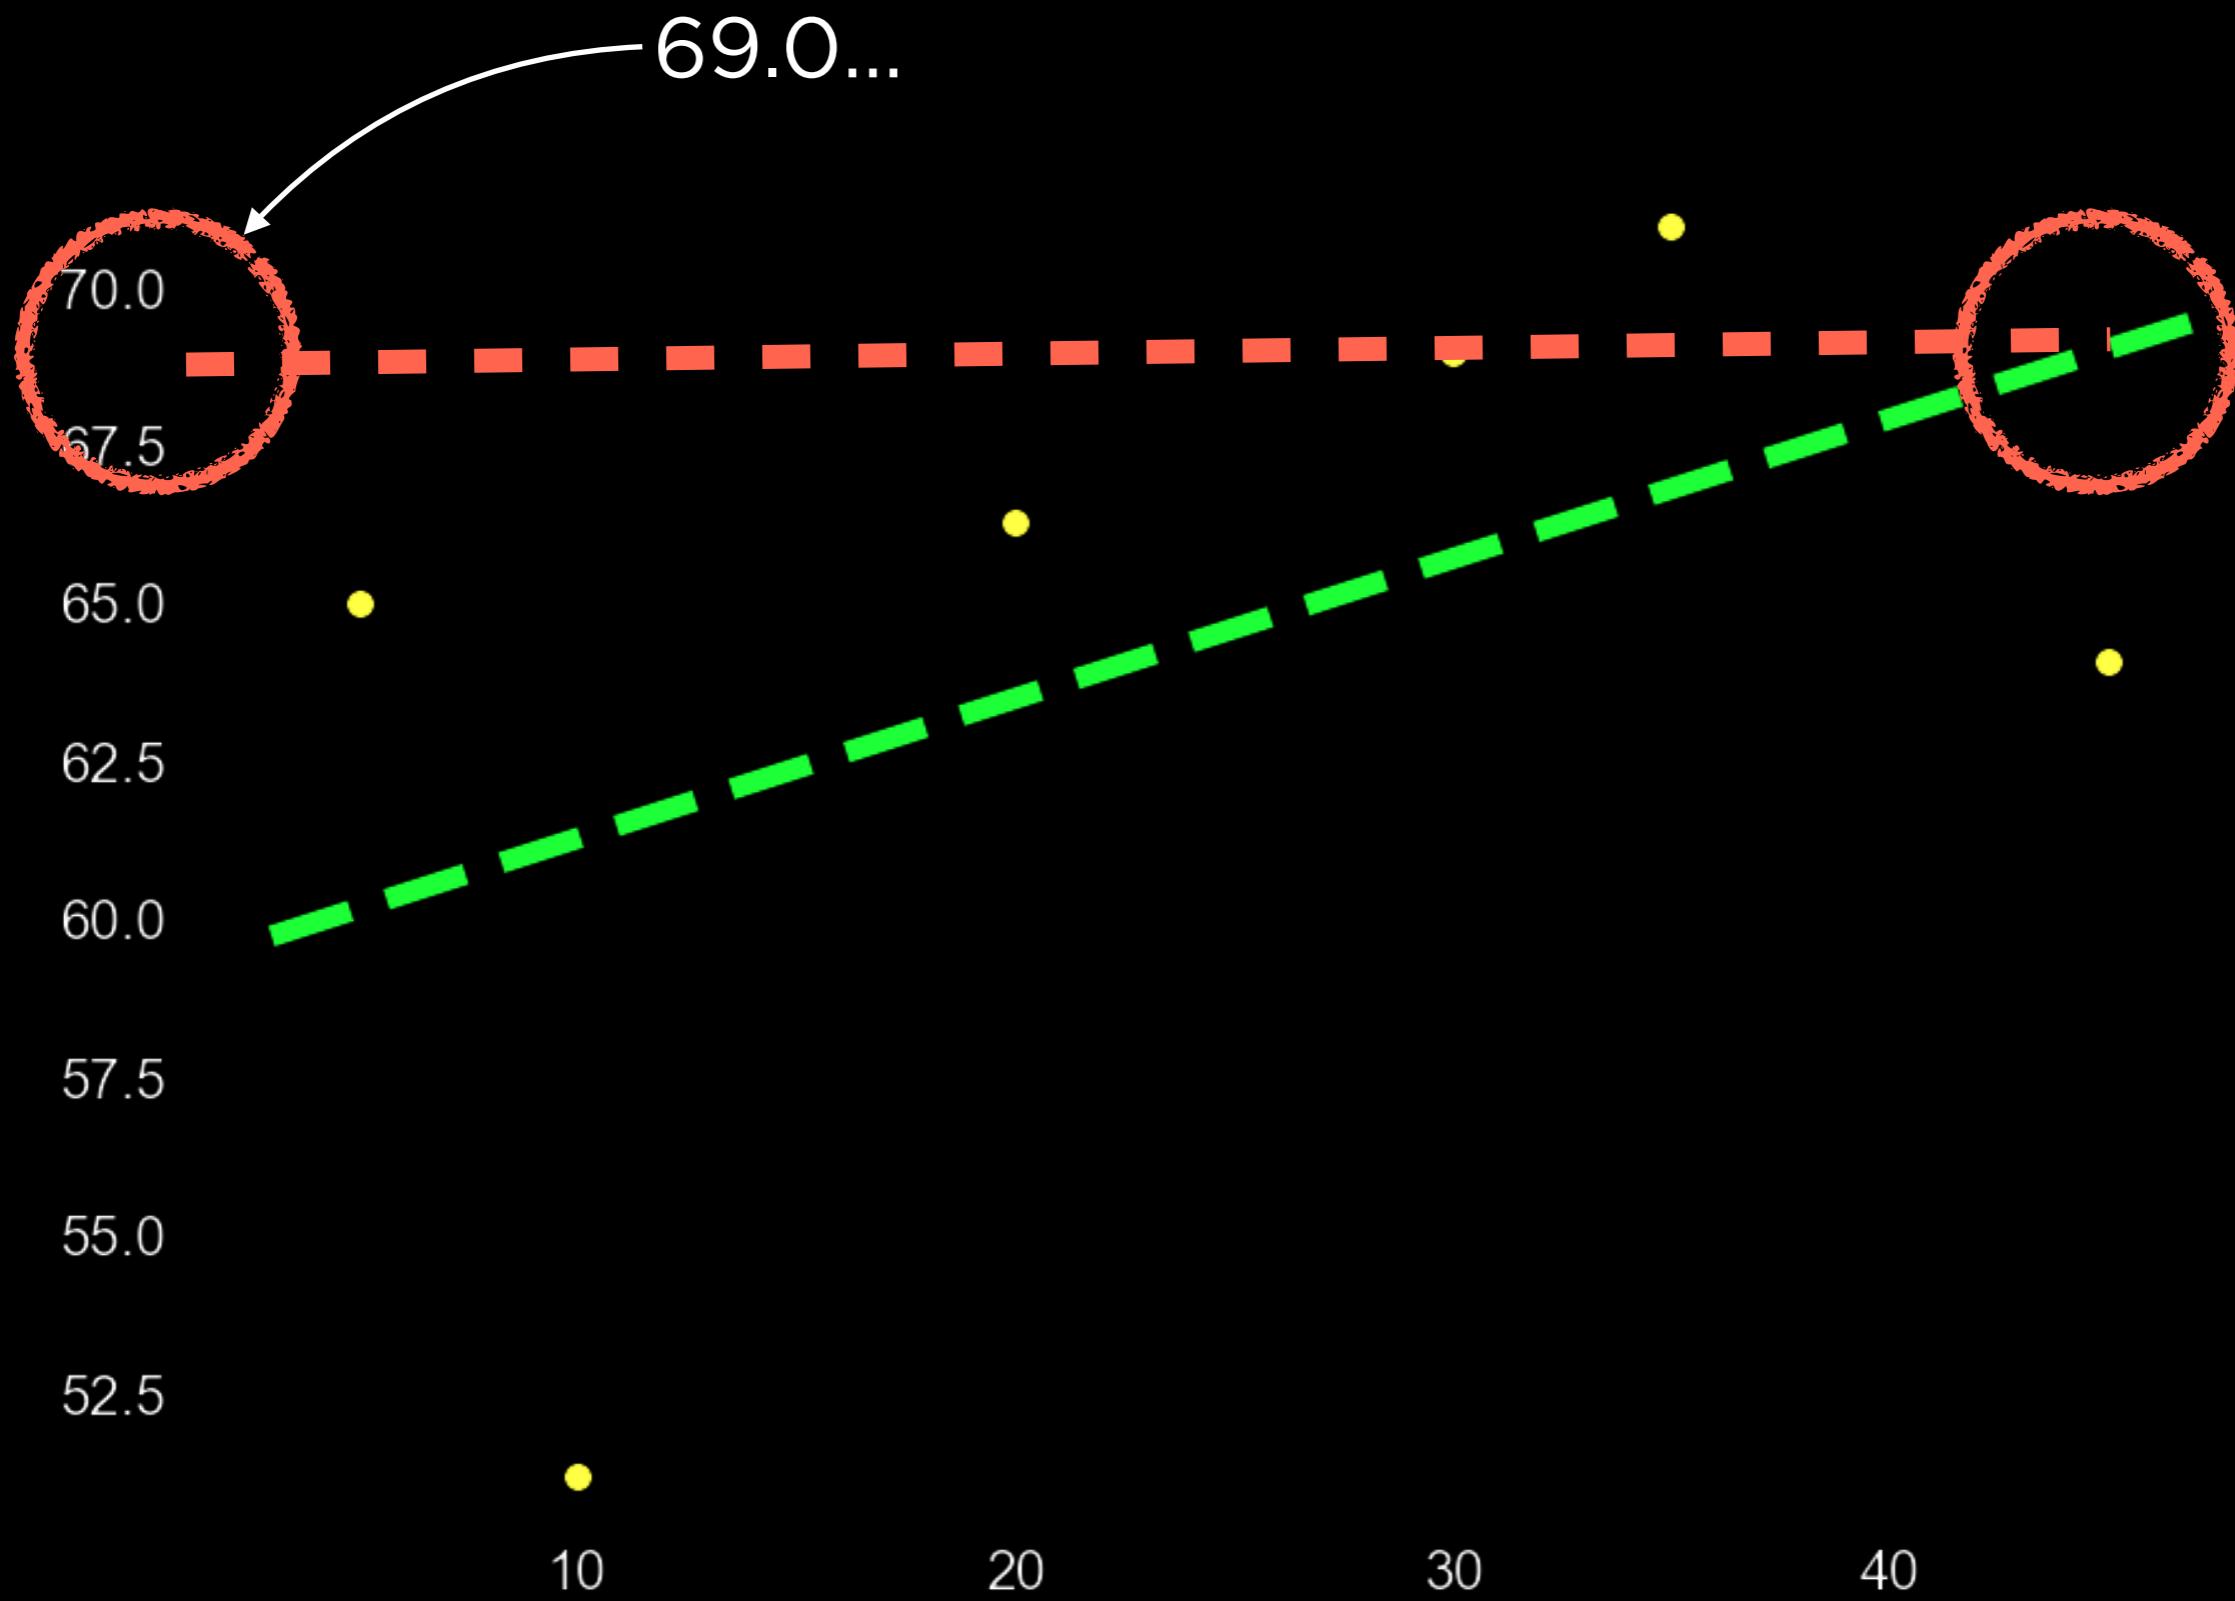


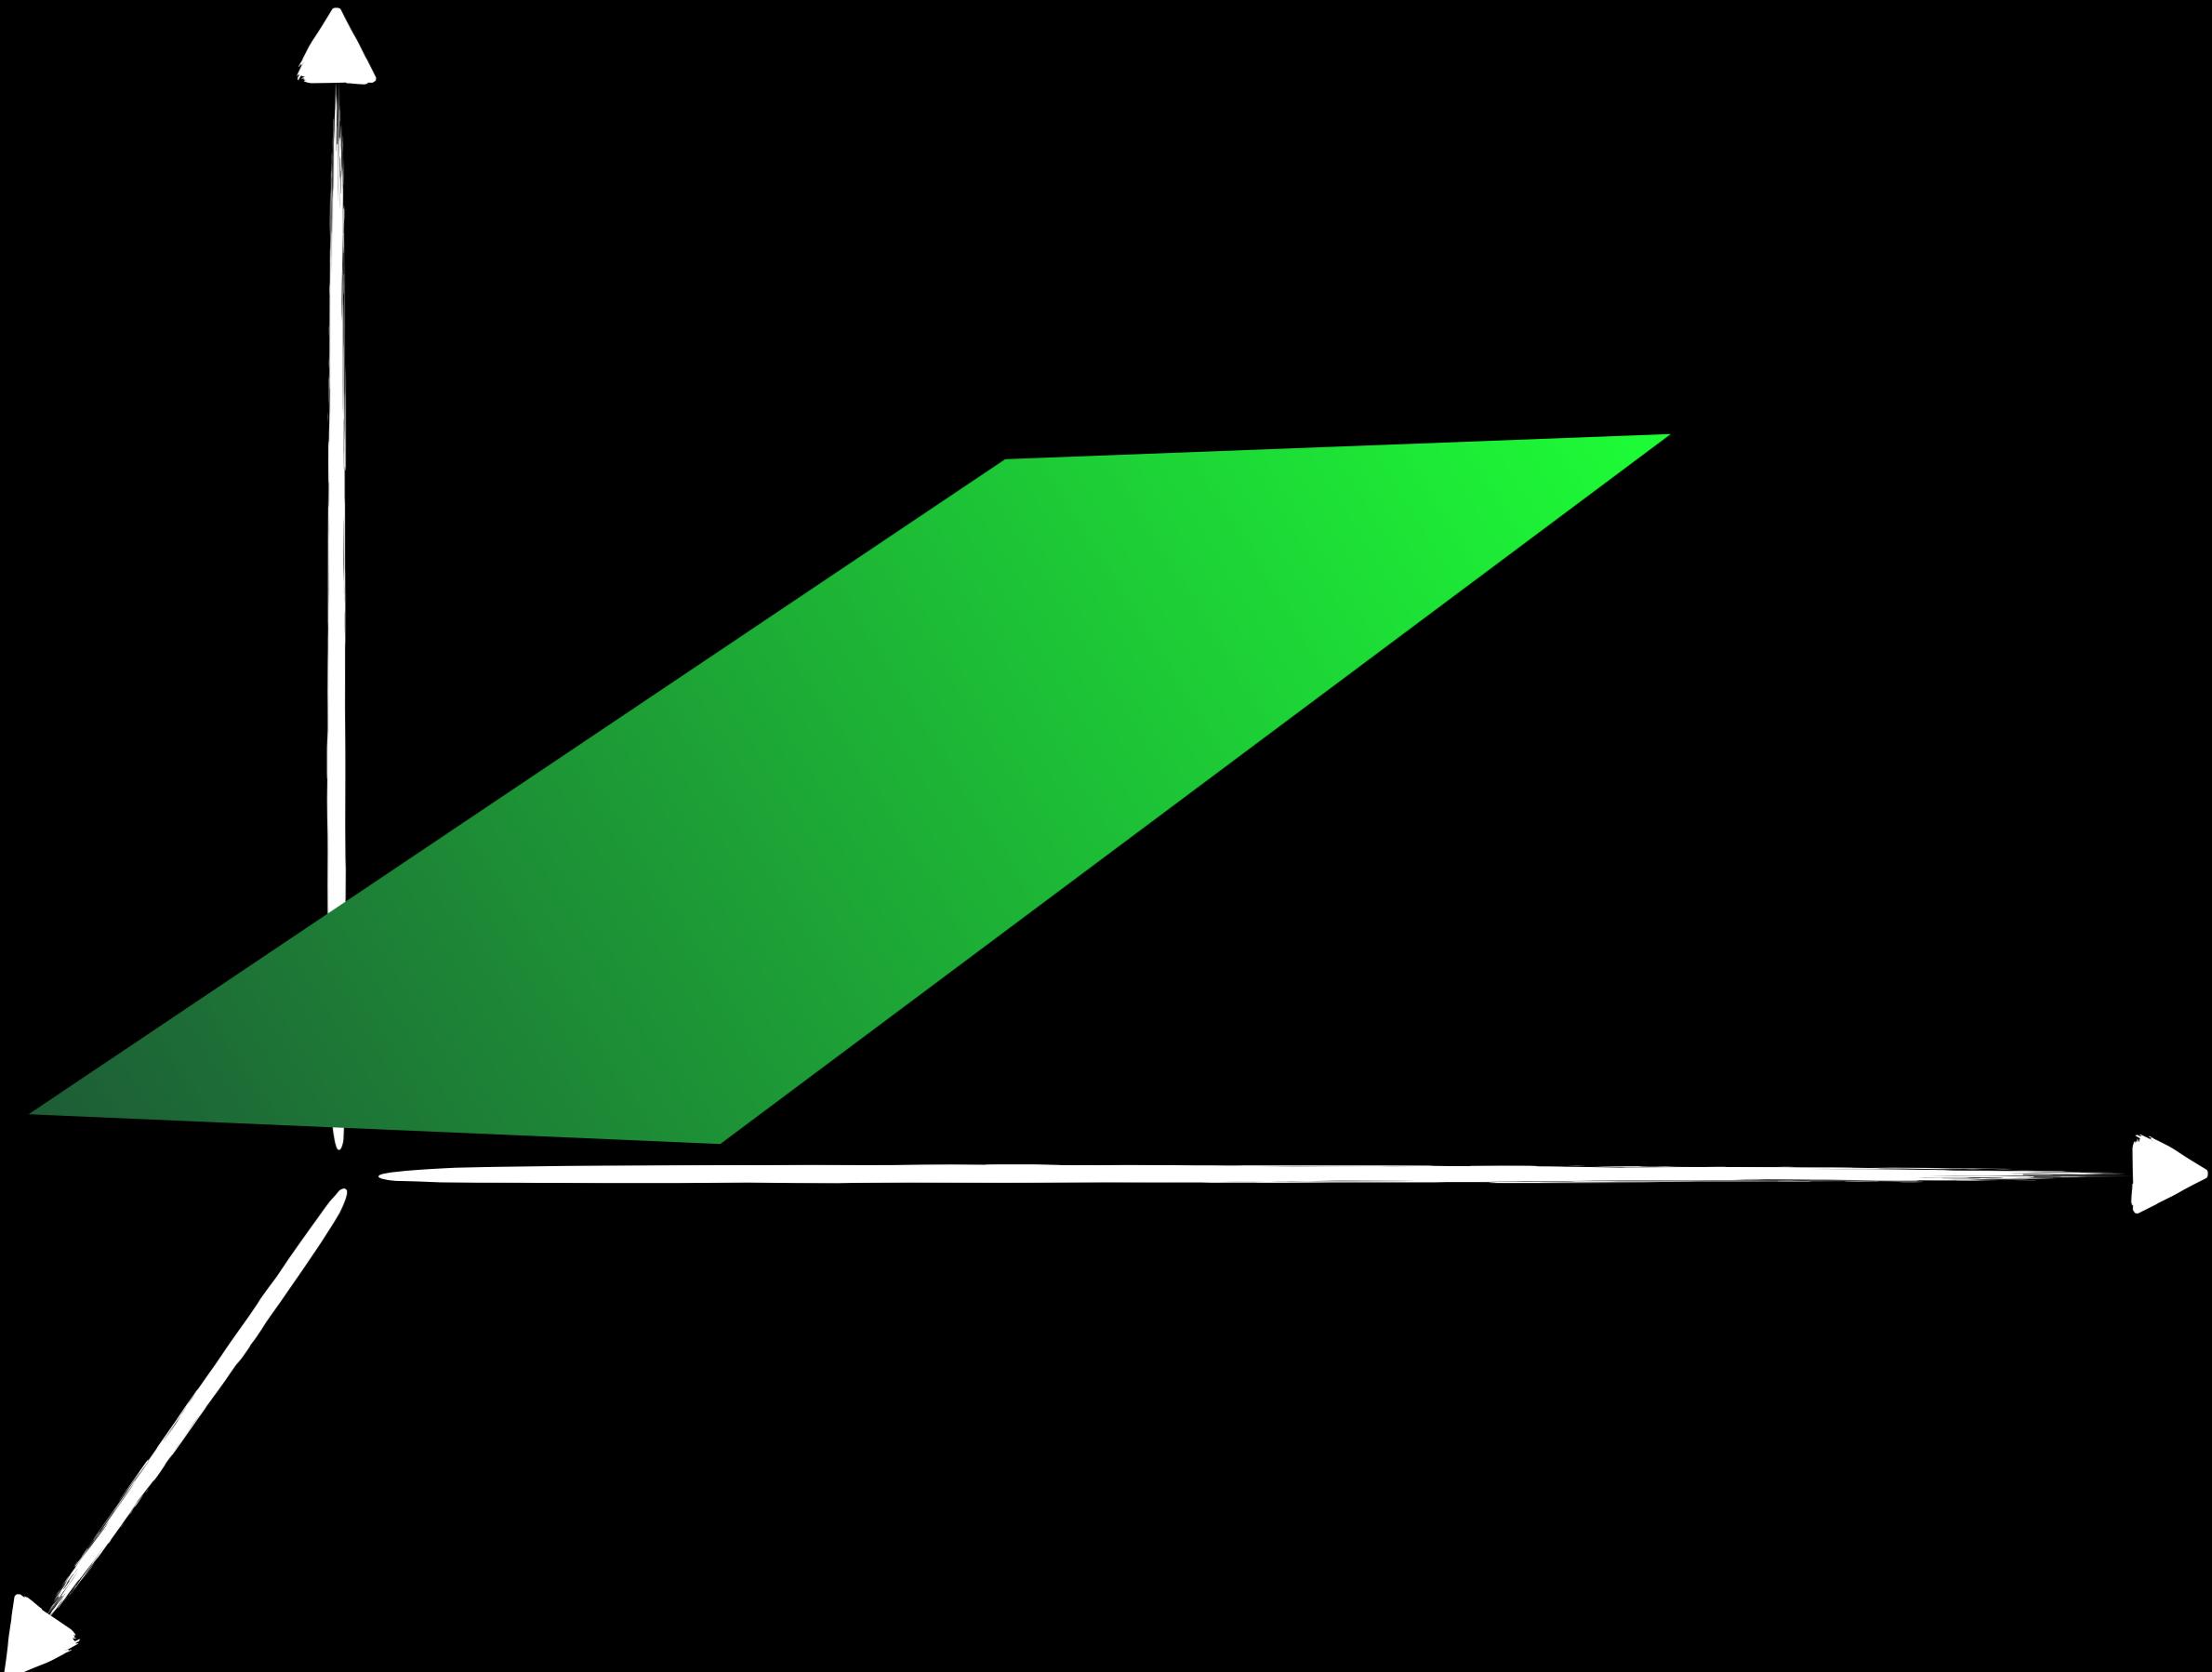


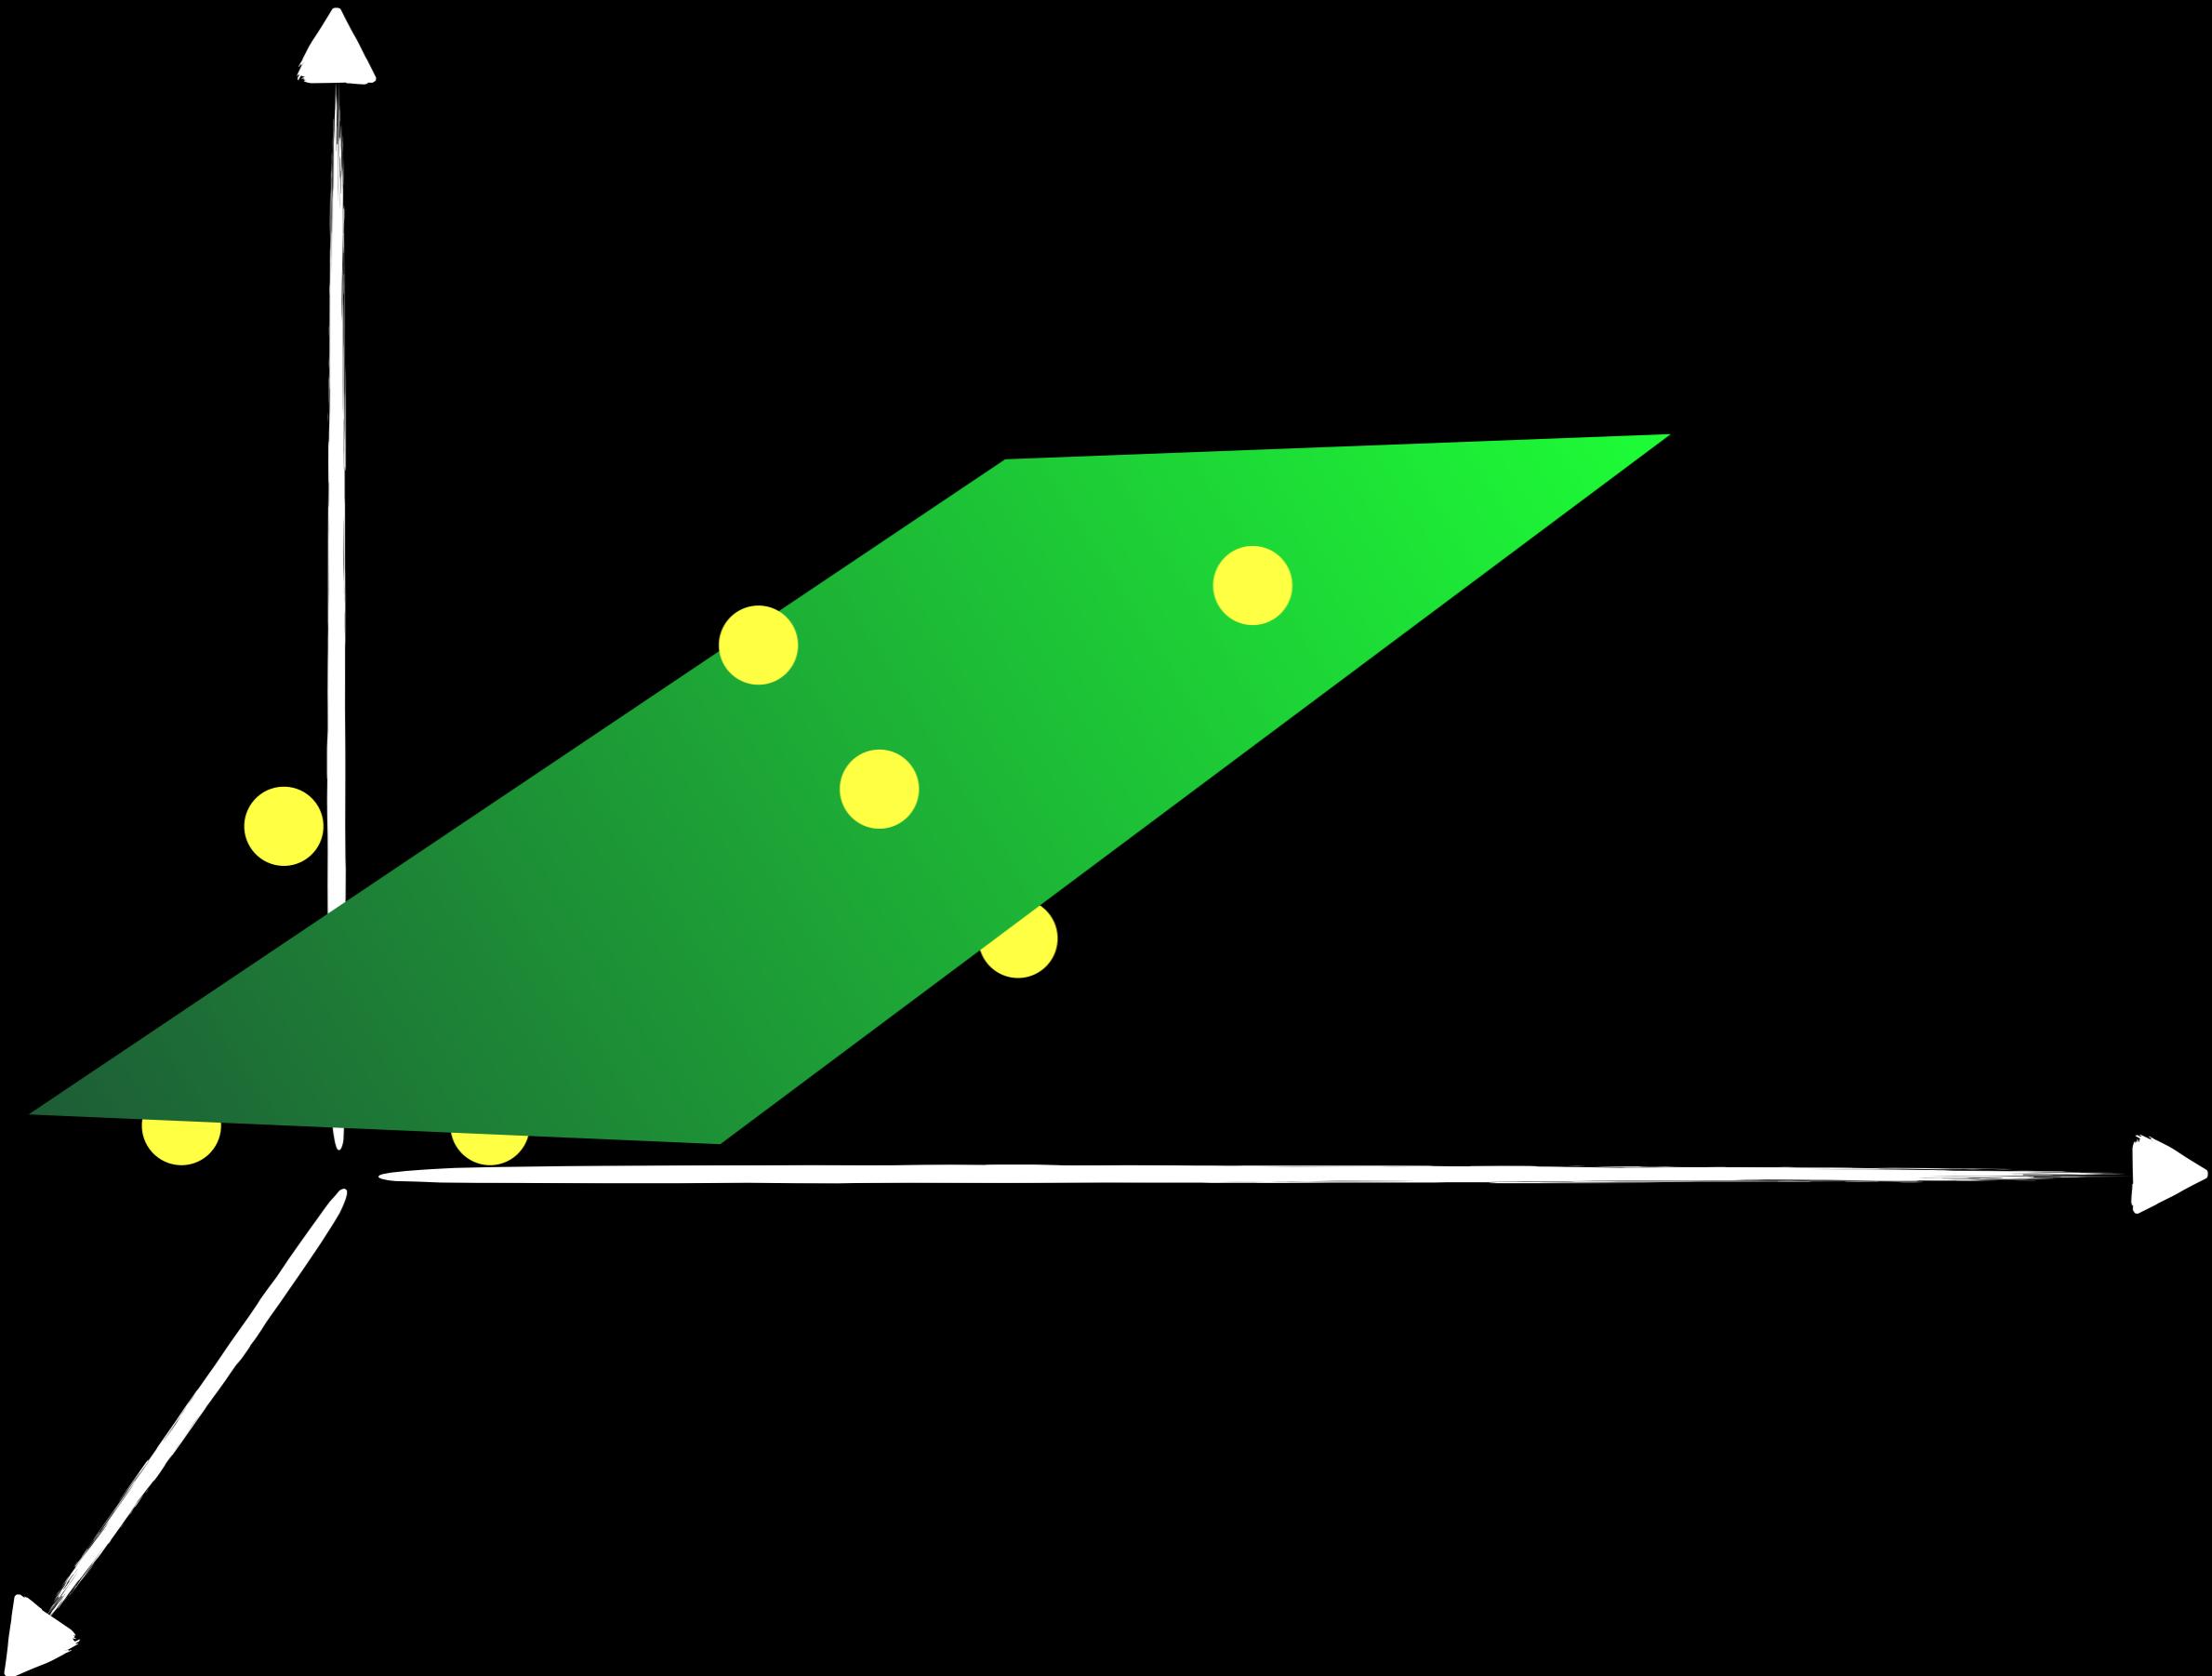














Провести **плоскость** так,

Провести **плоскость** так, чтобы **все точки** в пространстве

Провести **плоскость** так, чтобы **все точки** в пространстве  
**были как можно ближе** к плоскости



$$Y = Xa + b$$

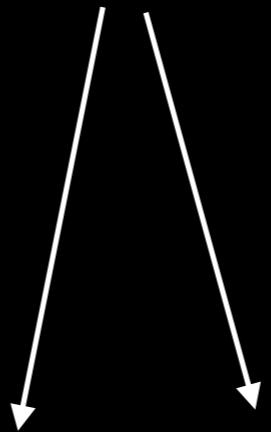
$$Y = Xa + b$$

\_\_\_\_\_

$$Y = Xa + b$$

— — —

Хотим найти



$$Y = Xa + b$$

— —

$$a = (a_1, \dots, a_n)$$

Хотим найти

$$Y = Xa + b$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots x_{l,n} \end{matrix}$$

Хотим найти

$$Y = Xa + b$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots, x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots, x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots, x_{l,n} \end{matrix}$$

Хотим найти

$$Y = Xa + b$$

$$\begin{aligned} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b \\ \vdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b \end{aligned}$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots, x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots, x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots, x_{l,n} \end{matrix}$$

Хотим найти

$$Y = Xa + b$$

$$\begin{aligned} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b \\ \vdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b \end{aligned} \longrightarrow$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots, x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots, x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots, x_{l,n} \end{matrix}$$

Хотим найти

$$Y = Xa + b$$

$$\begin{array}{ll} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b & + 1 * b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b & \longrightarrow \cdots + 1 * b \\ \vdots & \cdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b & + 1 * b \end{array}$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots, x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots, x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots, x_{l,n} \end{matrix}$$

Хотим найти

$$Y = X'w$$

$$\begin{array}{ll} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b & + 1 * b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b & \longrightarrow \cdots + 1 * b \\ \vdots & \cdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b & + 1 * b \end{array}$$

$$w = (b, a_1, \dots, a_n)$$

$$a = (a_1, \dots, a_n)$$

Хотим найти

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots, x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots, x_{2,n} \\ \vdots \quad \vdots \quad \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots, x_{l,n} \end{matrix}$$

$$Y = X'w$$

$$\begin{array}{ccc} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b & & + 1 * b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b & \longrightarrow & \dots + 1 * b \\ \vdots & & \vdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b & & + 1 * b \end{array}$$

$$w = (b, a_1, \dots, a_n)$$

$$a = (a_1, \dots, a_n)$$

$$X = \begin{matrix} x_{1,1}, x_{1,2}, x_{1,3}, \dots x_{1,n} \\ x_{2,1}, x_{2,2}, x_{2,3}, \dots x_{2,n} \\ \vdots \\ x_{l,1}, x_{l,2}, x_{l,3}, \dots x_{l,n} \end{matrix}$$

Хотим найти

$$X = \begin{matrix} 1, x_{1,1}, x_{1,2}, x_{1,3}, \dots x_{1,n} \\ 1, x_{2,1}, x_{2,2}, x_{2,3}, \dots x_{2,n} \\ \vdots \\ 1, x_{l,1}, x_{l,2}, x_{l,3}, \dots x_{l,n} \end{matrix}$$

$$Y = X'w$$

$$\begin{array}{c} a_1x_{1,1} + a_2x_{1,2} + a_3x_{1,3} + \dots + a_nx_{1,n} + b \\ a_1x_{2,1} + a_2x_{2,2} + a_3x_{2,3} + \dots + a_nx_{2,n} + b \\ \vdots \\ a_1x_{l,1} + a_2x_{l,2} + a_3x_{l,3} + \dots + a_nx_{l,n} + b \end{array} \longrightarrow \begin{array}{c} + 1 * b \\ \dots + 1 * b \\ \dots \\ + 1 * b \end{array}$$

$$Y=X'w$$

$$Y = X' w$$

$$w=(X')^{-1} Y$$

$$Y=X'\omega$$

$$\dim(X)=[l,n], l\neq n$$

# Метод наименьших квадратов

# Формулировка МНК

$$(Xw - y)^T(Xw - y) \rightarrow \min_w$$

$$X_W=Y$$

$$X_{\mathcal{W}} = Y$$

$$X^TX_{\mathcal{W}}=X^TY$$

$$Xw = Y$$

$$X^TXw=X^TY$$

$$w=(X^TX)^{-1}X^TY$$

# Проблемы

# Проблемы

- Имеется операция взятия обратной матрицы

# Проблемы

$O(n^3)$  операций

- Имеется операция взятия обратной матрицы

# Проблемы

$O(n^3)$  операций

- Имеется операция взятия обратной матрицы
- Могут быть линейно зависимые вектора

# Проблемы

$O(n^3)$  операций

- Имеется операция взятия обратной матрицы
- Могут быть линейно зависимые вектора

Тогда матрица  
необратима

Что мы делаем, когда  
невозможно аналитически?

Апроксимируем!

# Градиентный спуск

# Градиентный спуск

$$(Xw - y)^T(Xw - y) \rightarrow \min_w$$

# Градиентный спуск

$$(Xw - y)^T(Xw - y) \rightarrow \min_w$$

$$\frac{1}{l} ||Xw - y||^2 \rightarrow \min_w$$

# Градиентный спуск

$$Q(w, X)$$

$$(Xw - y)^T (Xw - y) \rightarrow \min_w$$

$$\frac{1}{l} ||Xw - y||^2 \rightarrow \min_w$$

# Градиентный спуск

# Градиентный спуск

$$w^0 = 0$$

# Градиентный спуск

$$w^0 = 0$$

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

# Градиентный спуск

$$w^0 = 0$$

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

$$||w^t - w^{t-1}|| < \epsilon$$

# Градиентный спуск

$$w^0 = 0$$

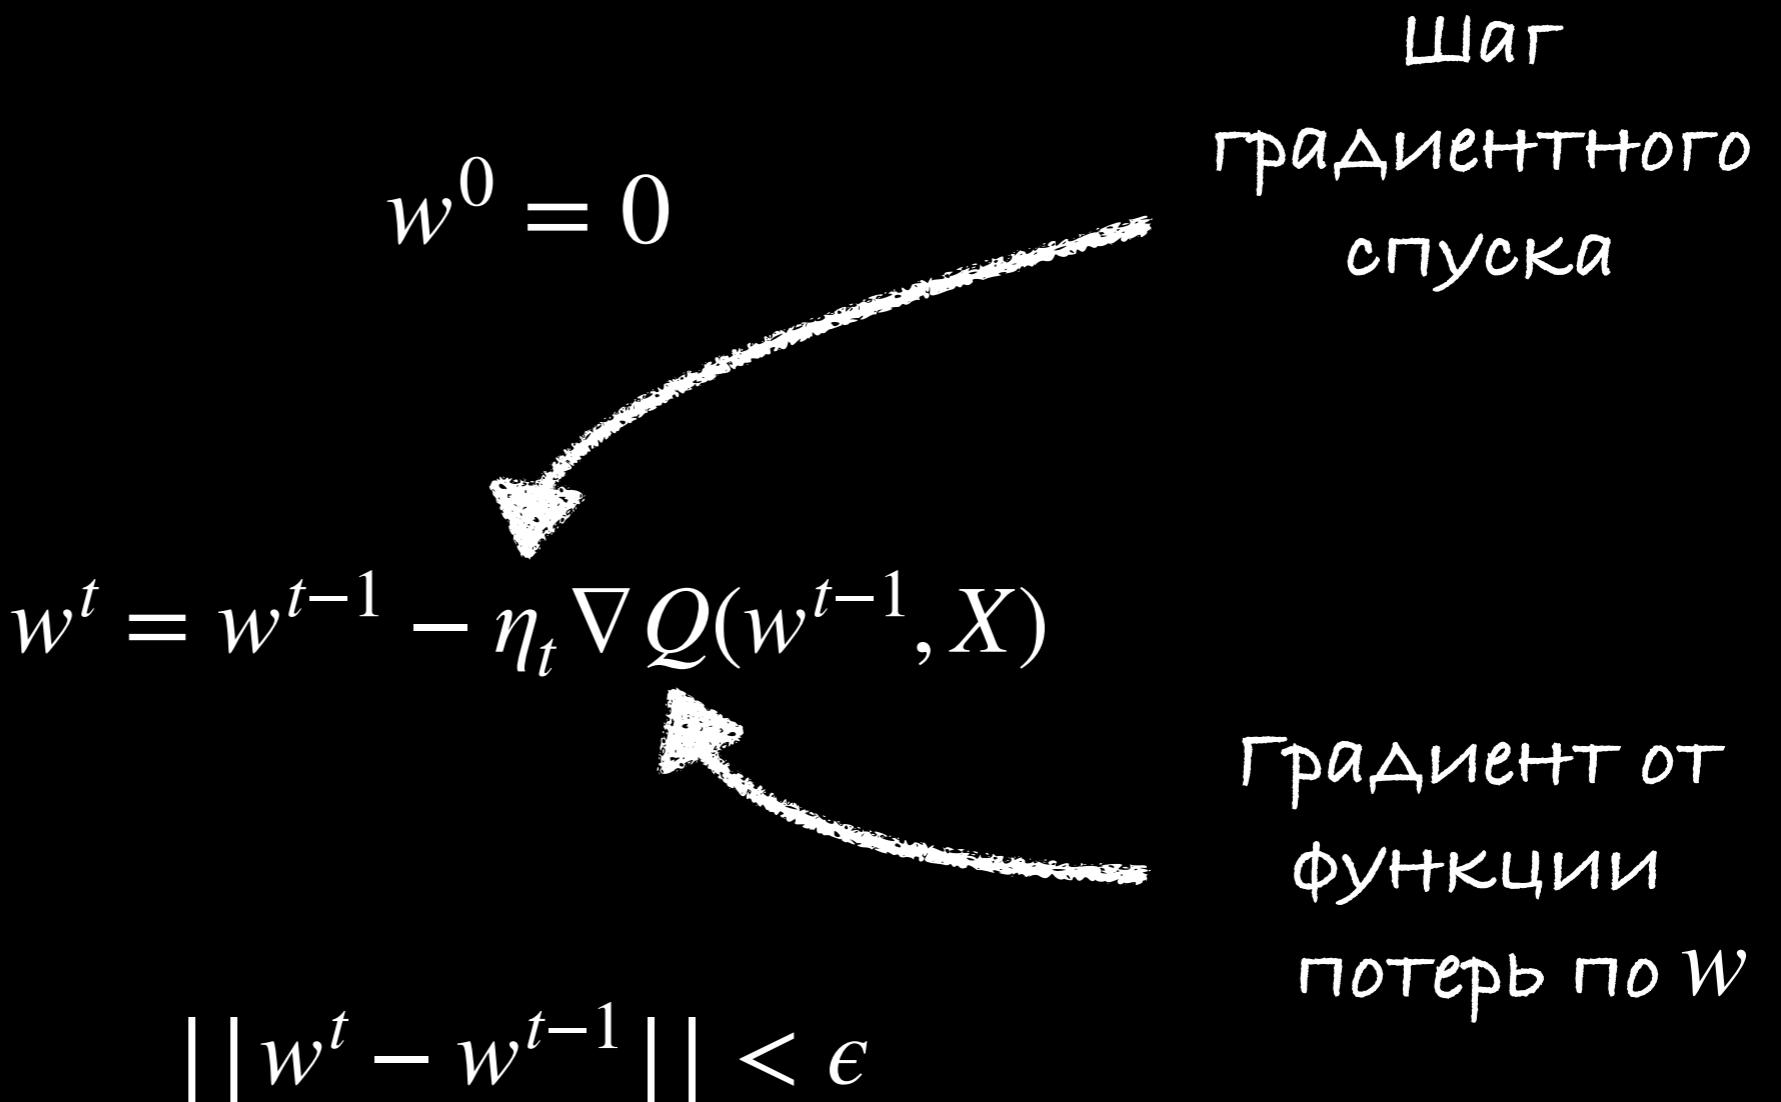
Шаг  
градиентного  
спуска



$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

$$\| w^t - w^{t-1} \| < \epsilon$$

# Градиентный спуск



# Градиентный спуск

Веса на  
предыдущем  
шаге

$$w^0 = 0$$

Шаг  
градиентного  
спуска

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

Градиент от  
функции  
потерь по  $w$

$$||w^t - w^{t-1}|| < \epsilon$$

# Градиентный спуск

Веса на  
предыдущем  
шаге

$$w^0 = 0$$

Шаг  
градиентного  
спуска

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

Градиент от  
функции  
потерь по  $w$

$$\|w^t - w^{t-1}\| < \epsilon$$

Очень  
маленькое  
значение

# Комментарий насчет шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

# Комментарий насчет шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

# Комментарий насчет шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

$$\eta_t = \frac{k}{t}$$

# Комментарий насчет шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

константа  
(сами выбираем)

$k$

$$\eta_t = \frac{k}{t}$$

# Комментарий насчет шага

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, X)$$

Константа  
(сами выбираем)

$$\eta_t = \frac{k}{t}$$

Номер итерации

Как посчитать градиент?

# Like baby steps

$$f(x) = w_0 + xw_1$$

$$Q(w_0, w_1, X) = \frac{1}{l} \sum_{i=1}^l (w_1 x_i + w_0 - y_i)^2$$

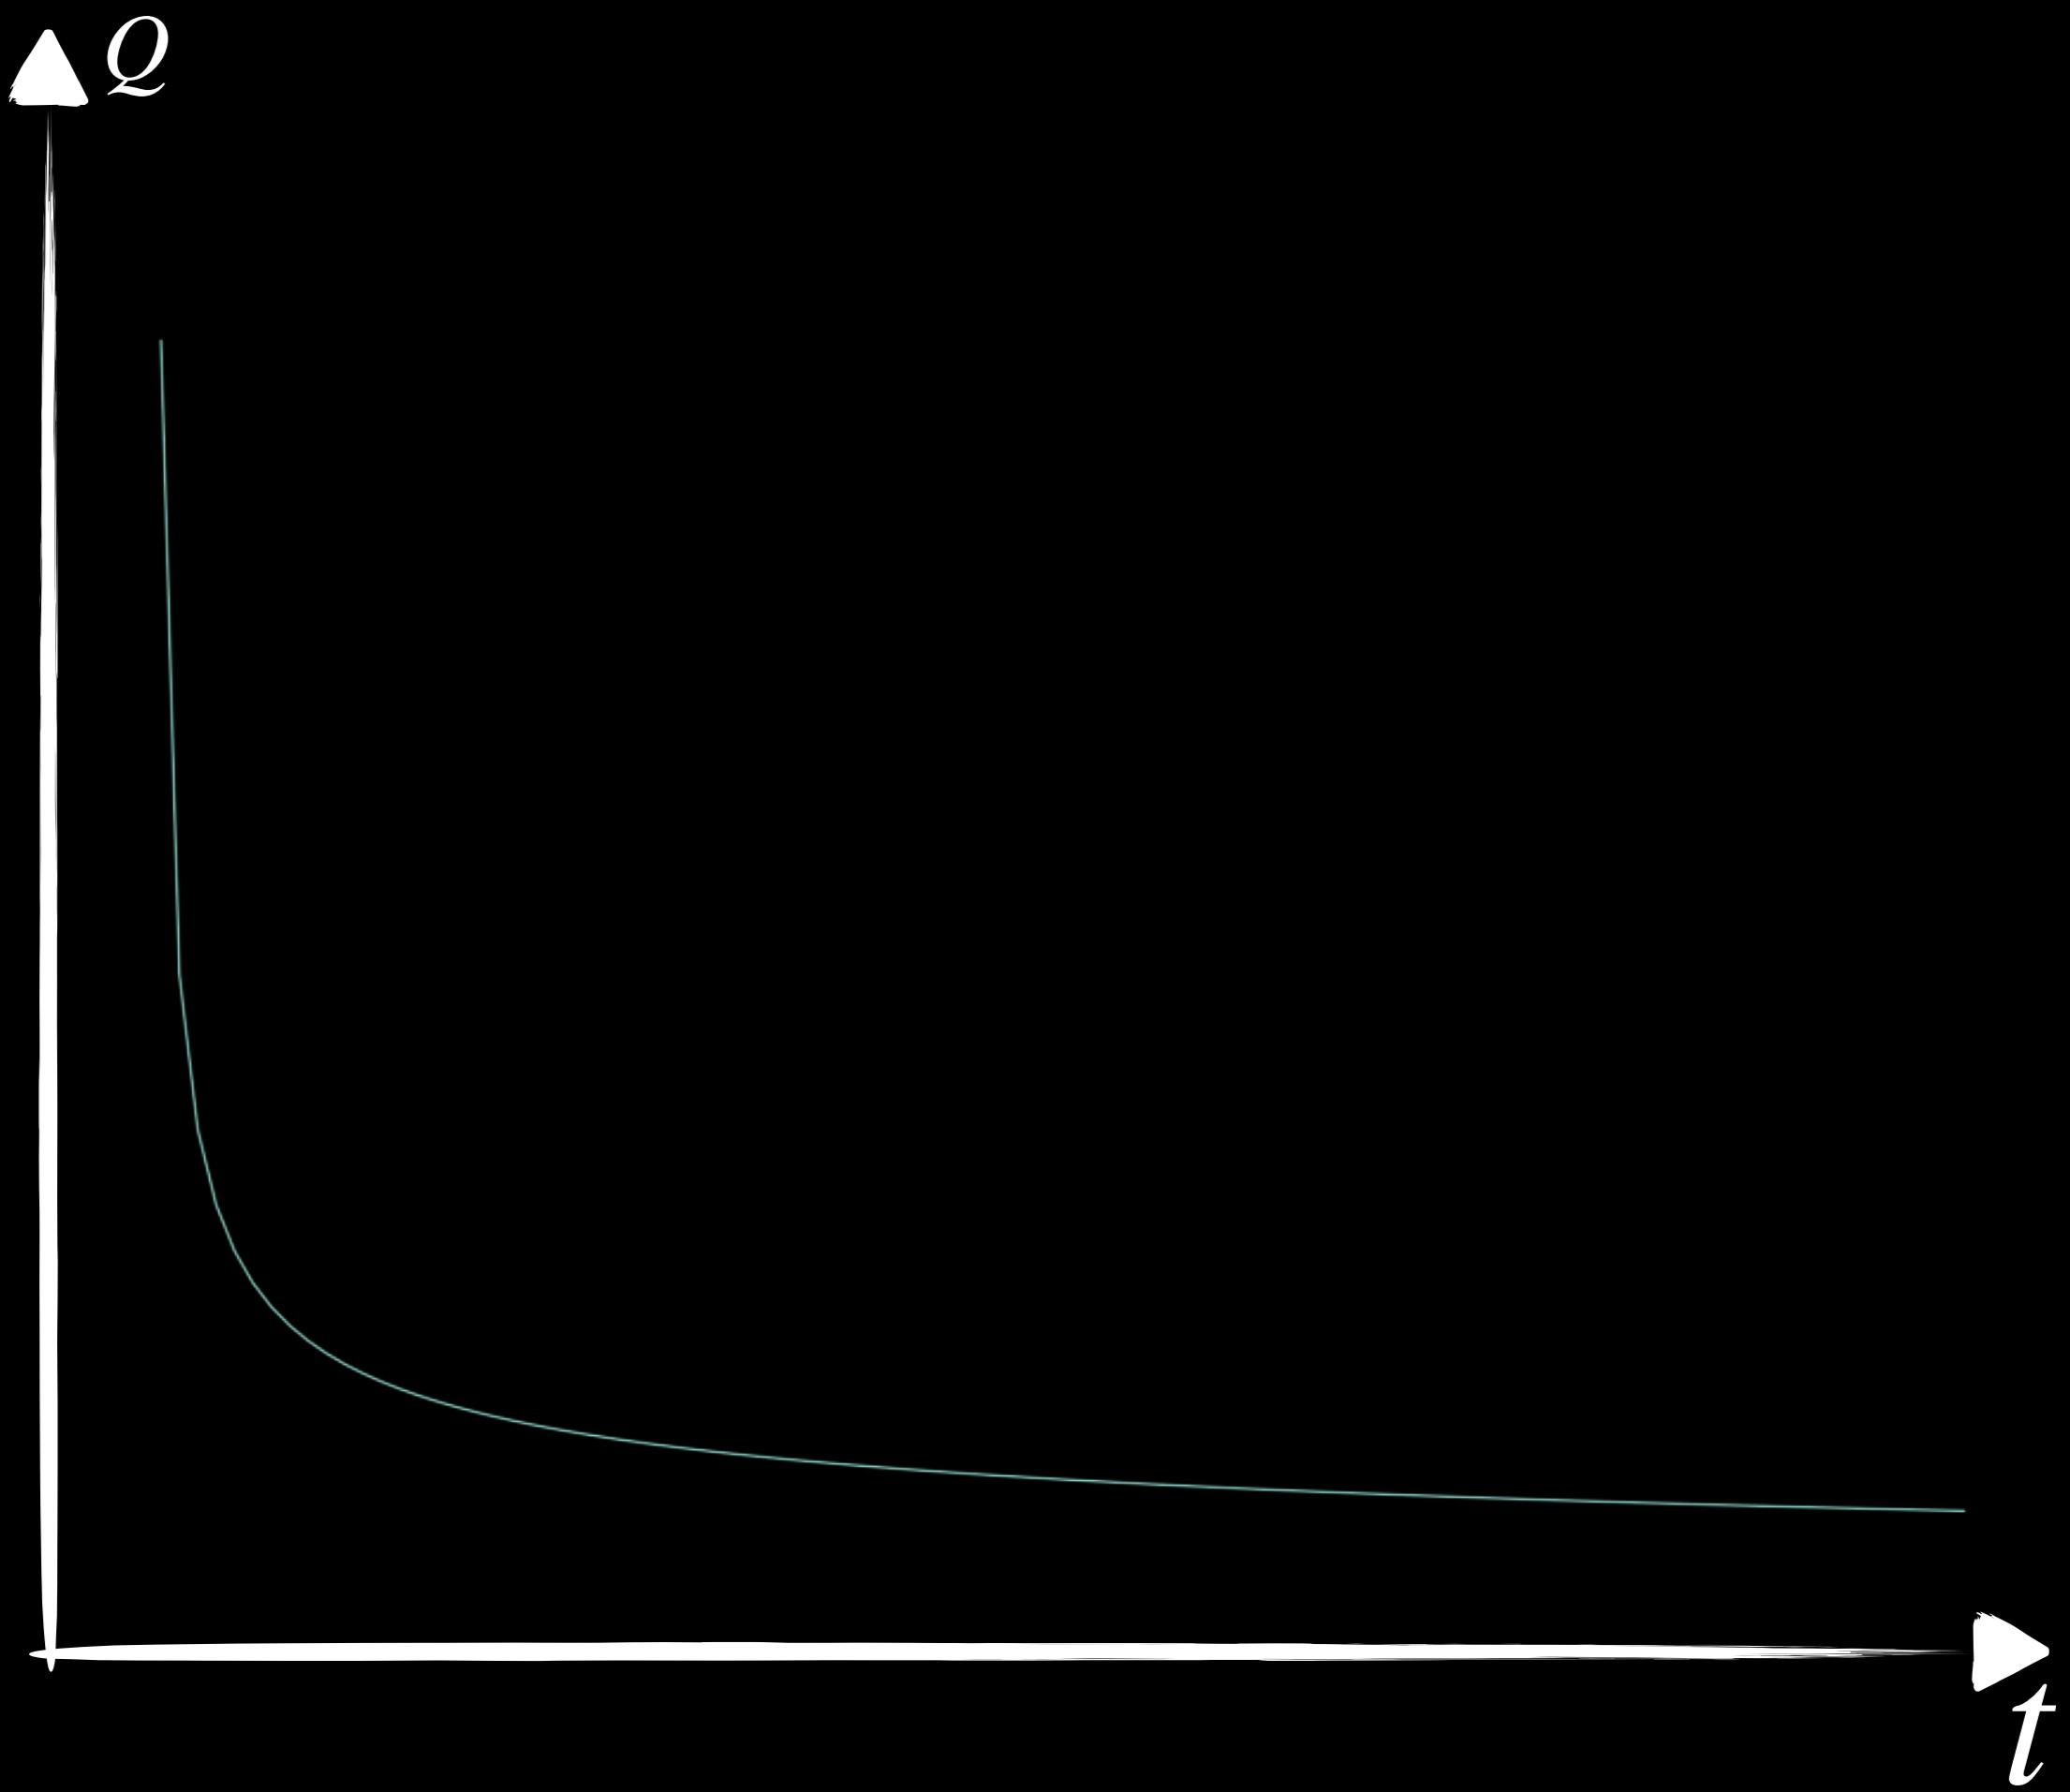
$$\frac{\partial Q}{\partial w_1} = \frac{2}{l} \sum_{i=1}^l (w_1 x_i + w_0 - y_i) x_i$$

$$\frac{\partial Q}{\partial w_0} = \frac{2}{l} \sum_{i=1}^l (w_1 x_i + w_0 - y_i)$$

# Обобщим

$$Q(w, X) = \frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

$$\nabla Q(w, X) = \frac{2}{l} X^T(Xw - y)$$



# Проблемы

- Он может долго считаться при большой выборке

# Проблемы

- Он может долго считаться при большой выборке

$$\nabla Q(w, X) = \frac{2}{l} X^T (Xw - y)$$

# Проблемы

- Он может долго считаться при большой выборке

$$\nabla Q(w, X) = \frac{2}{l} X^T (Xw - y)$$

Примеров может  
быть очень много

# Стохастический градиентный спуск

# Стохастический градиентный спуск

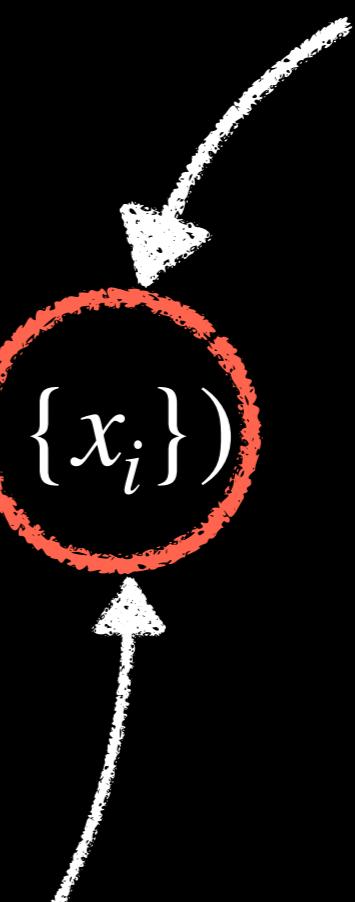
$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, \{x_i\})$$



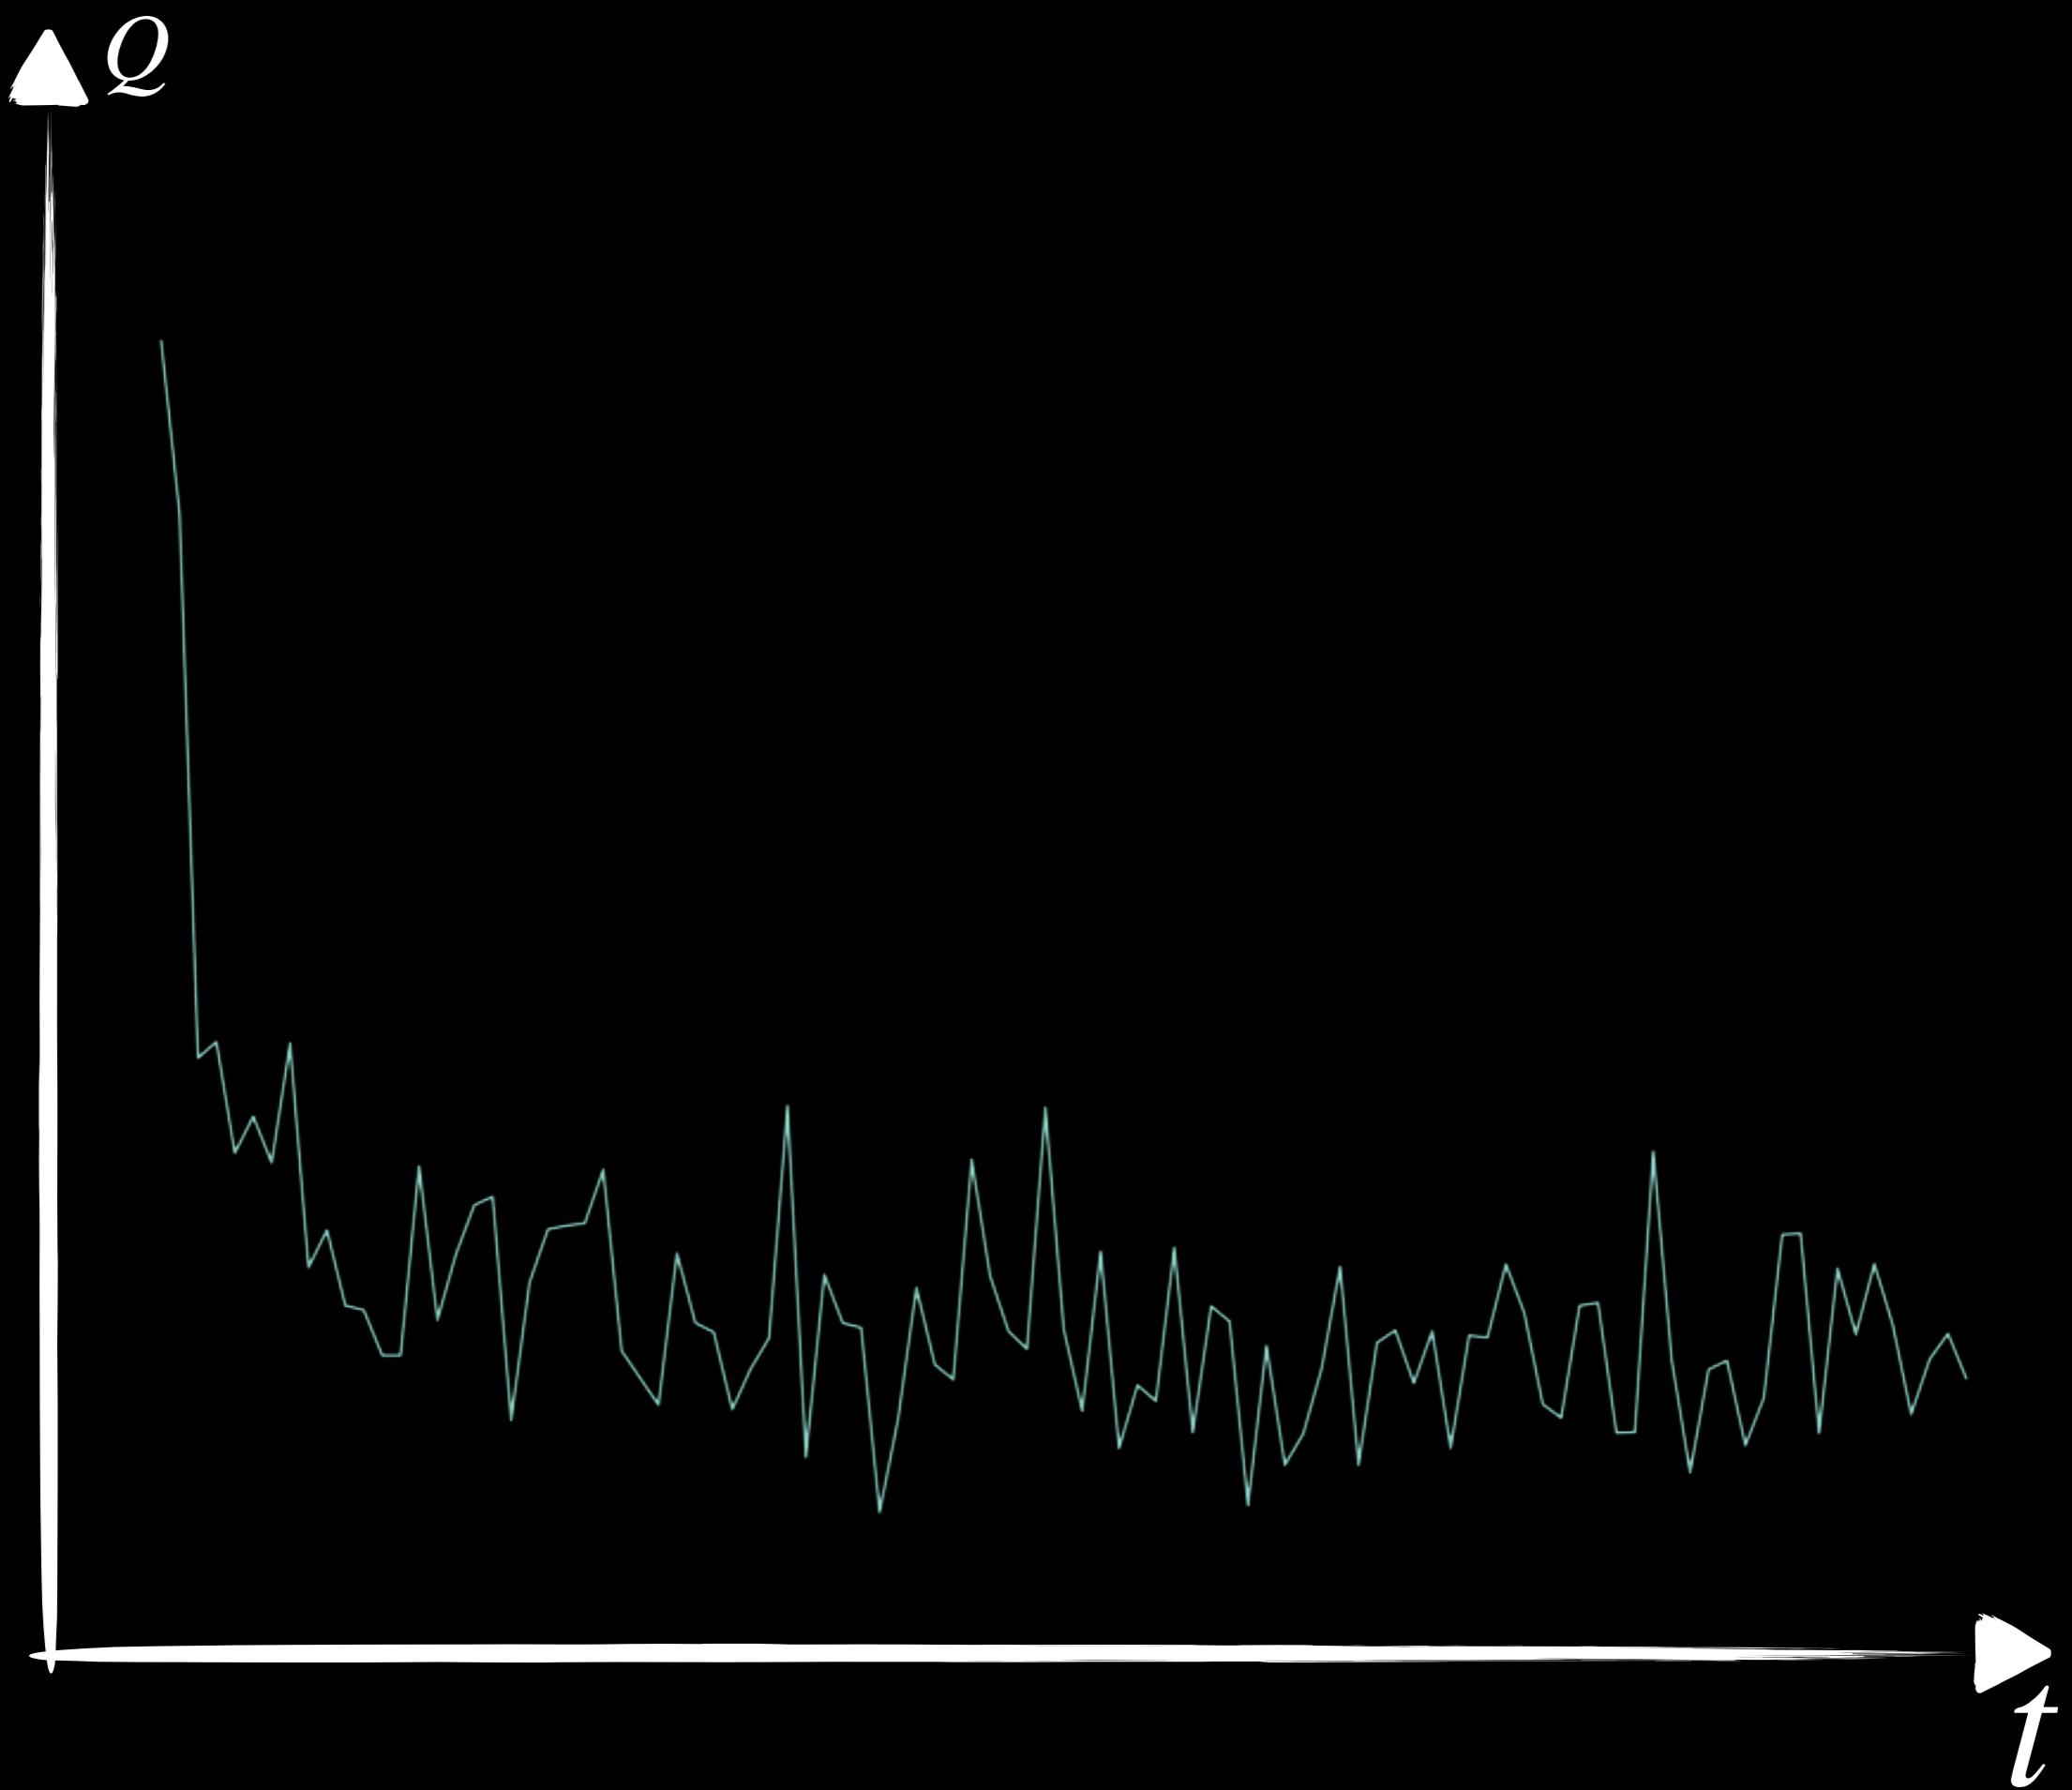
# Стохастический градиентный спуск

$$w^t = w^{t-1} - \eta_t \nabla Q(w^{t-1}, \{x_i\})$$

Кусок выборки



Берем  
случайные  
куски выборки



# Хорошие вещи

- Легко дообучить, если пришли новые данные;
- Достаточно быстро работает.

# Хорошие вещи

изначально  
учимся по кускам

- Легко дообучить, если пришли новые данные;
- Достаточно быстро работает.

# Классификация

# Бинарная классификация

# Постановка задачи

$Y \in \mathbb{R}$  Регрессия

# Постановка задачи

$\hat{Y} \in \mathbb{R}$  Регрессия

# Постановка задачи

$\underline{Y \in \mathbb{R}}$  Регрессия

$Y \in \{-1, 1\}$

Бинарная классификация

$Y \in \{0, 1\}$

# Пример



# Пример

1



0

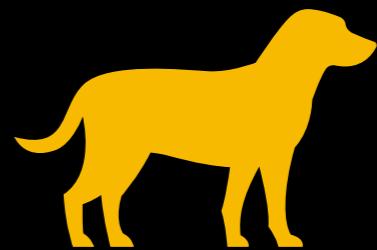
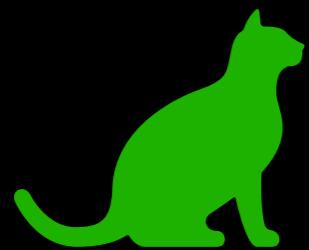


# Пример

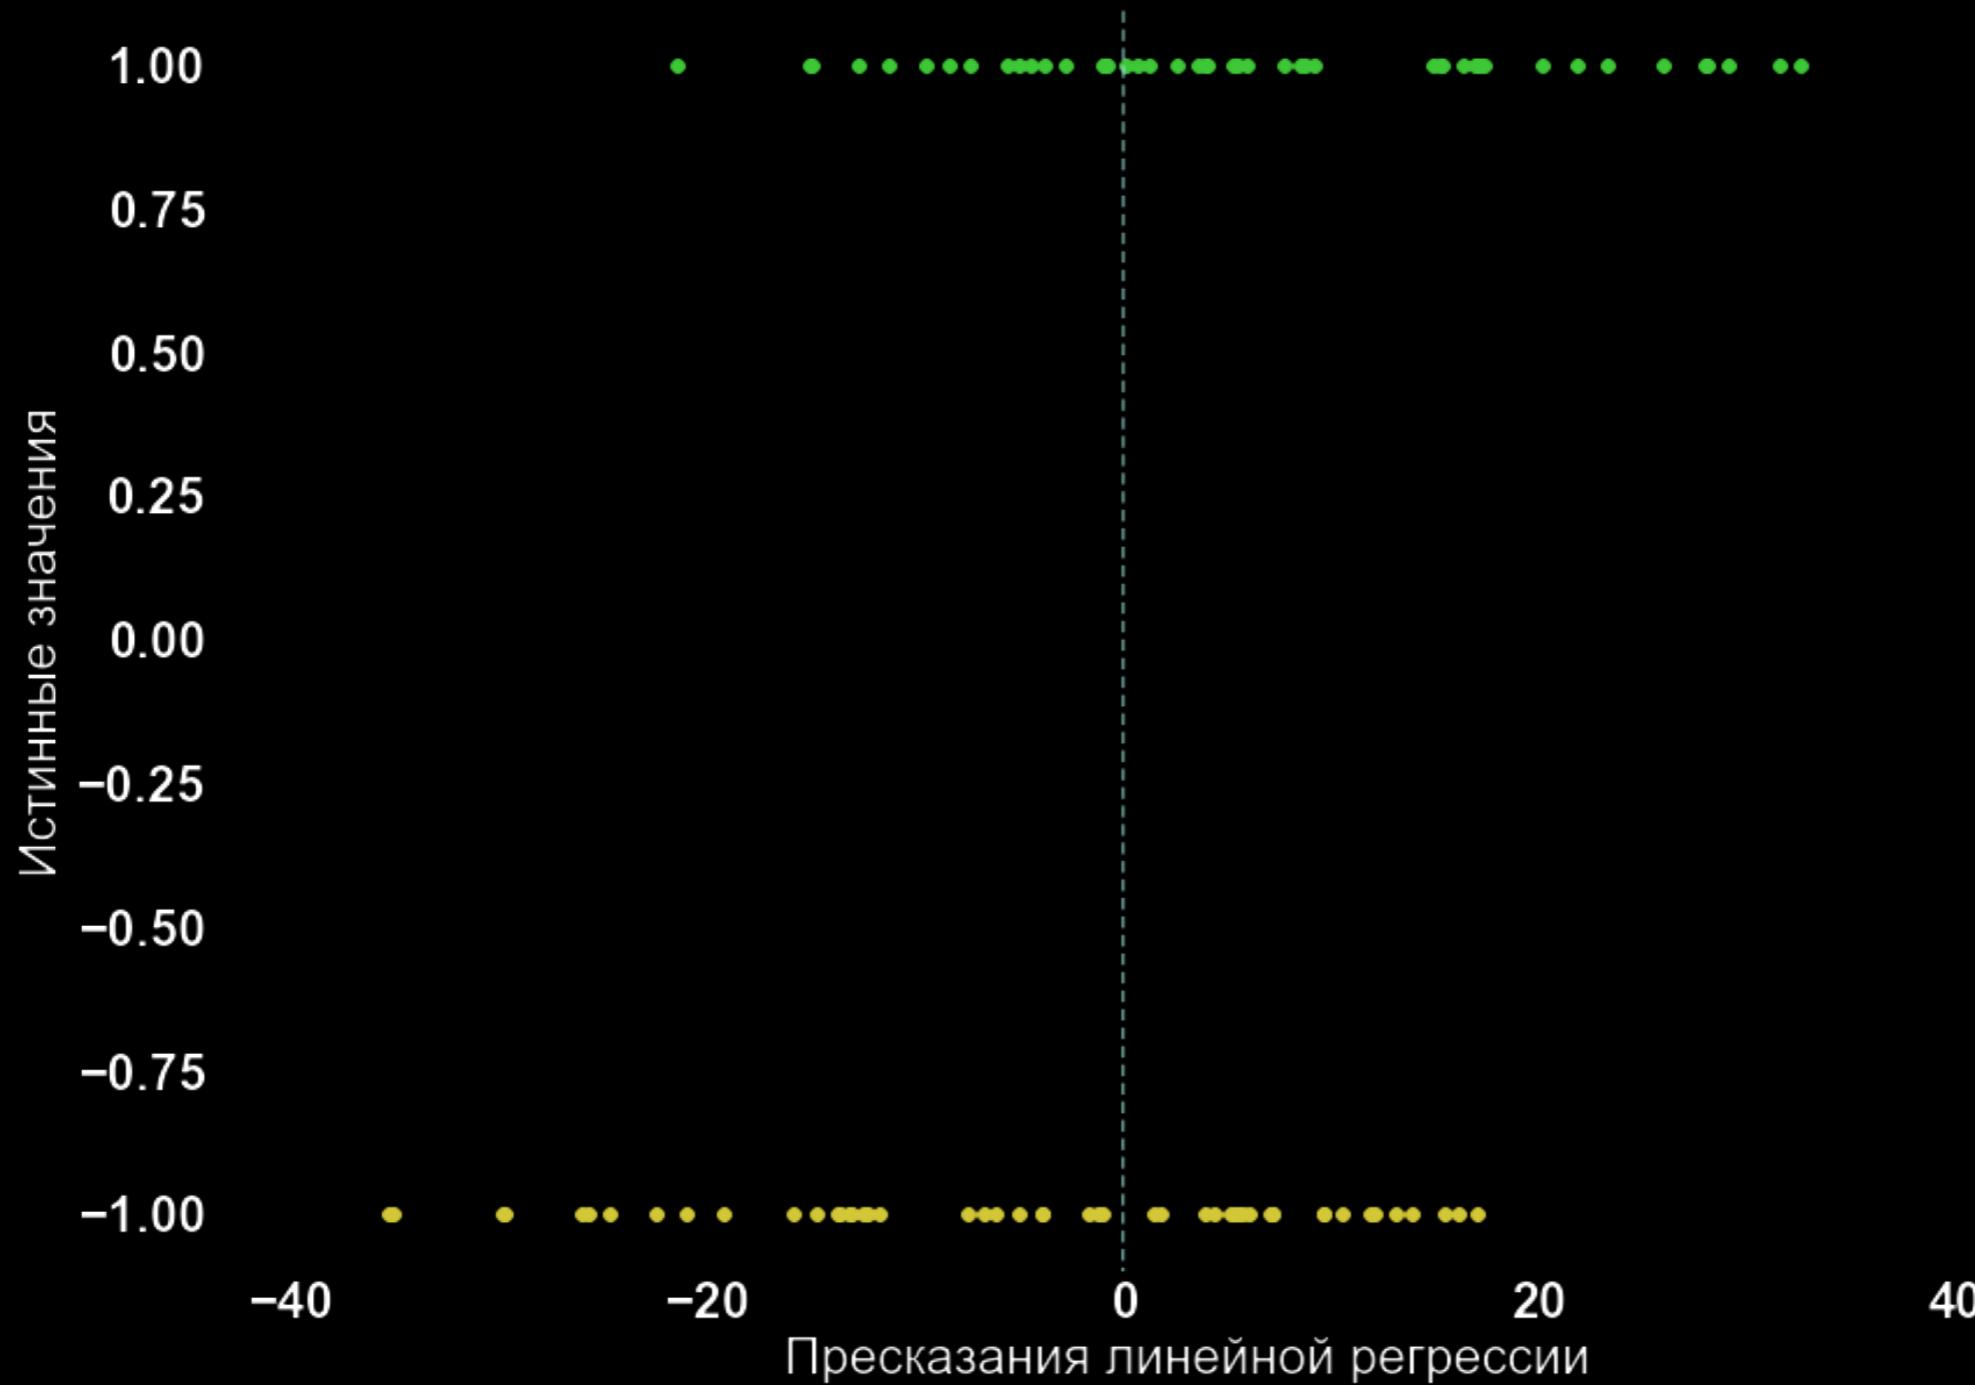
1



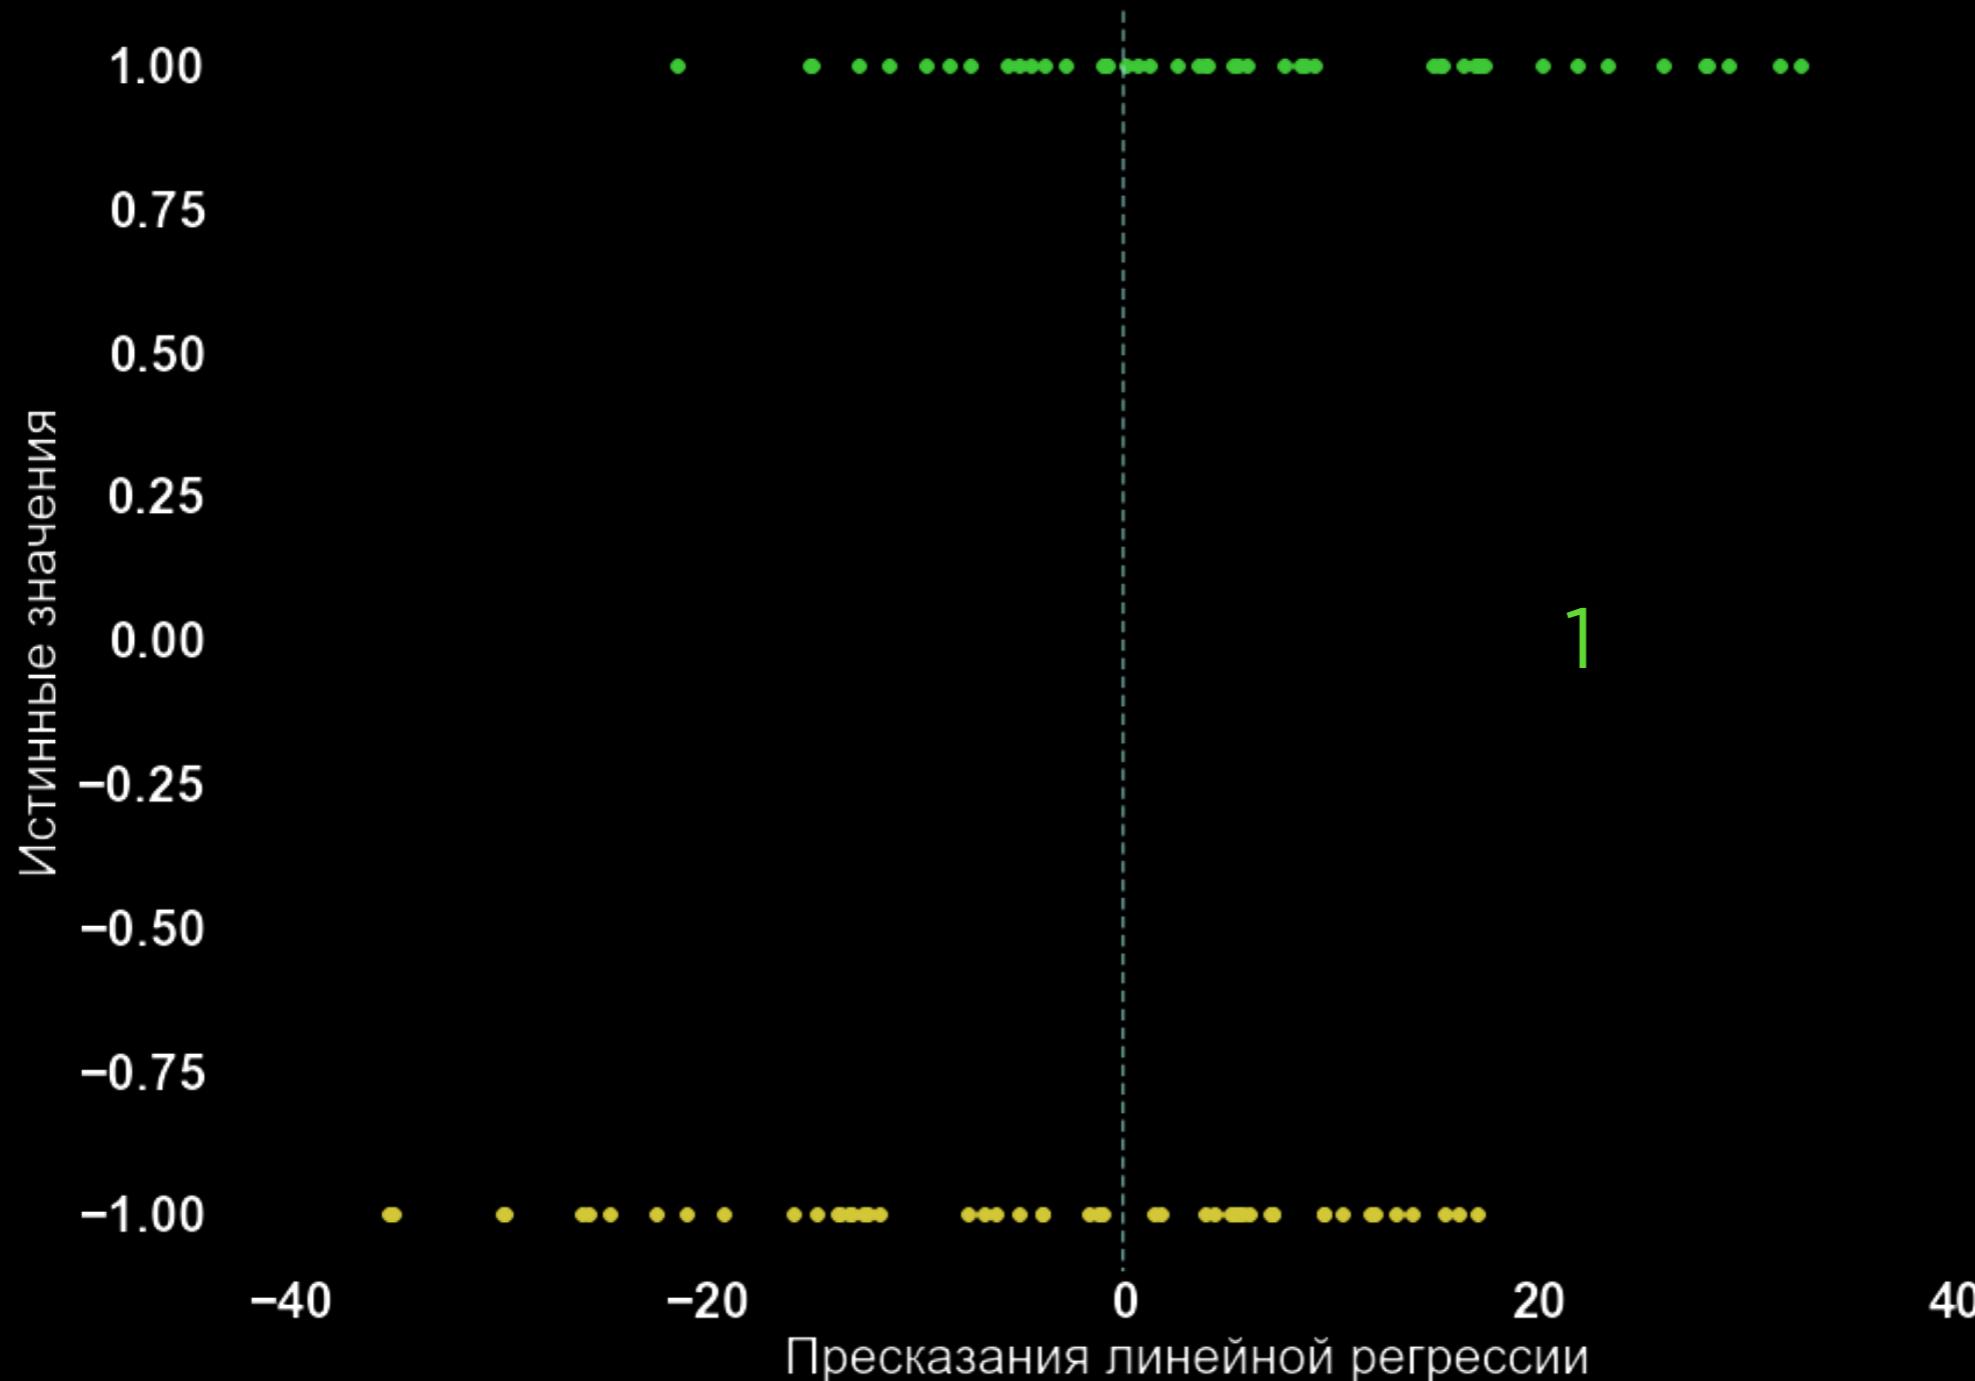
0



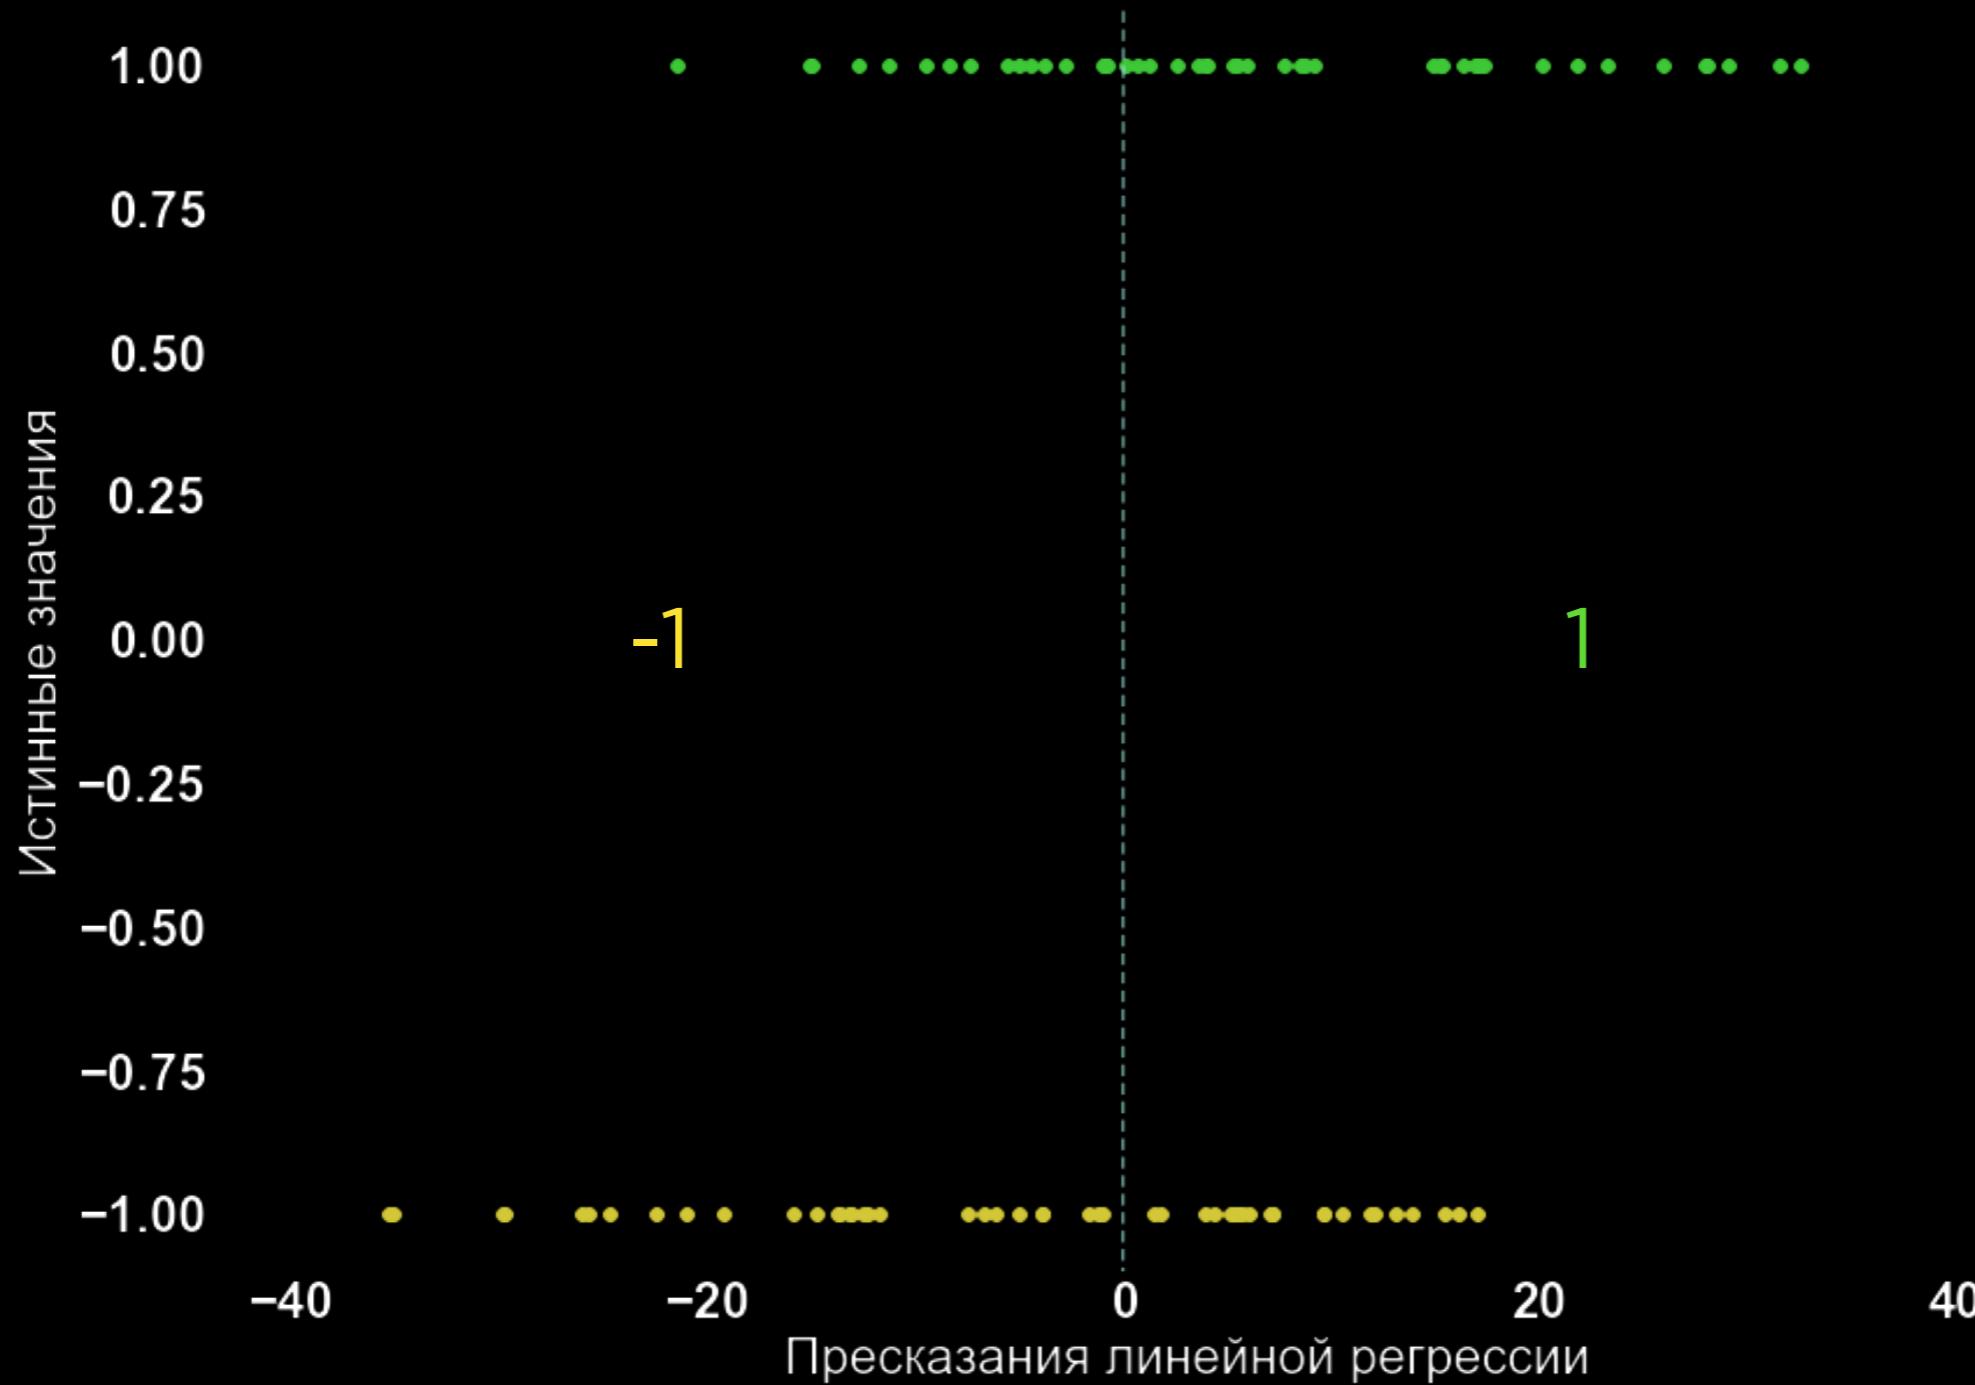
# Регрессия для классификации



# Регрессия для классификации



# Регрессия для классификации

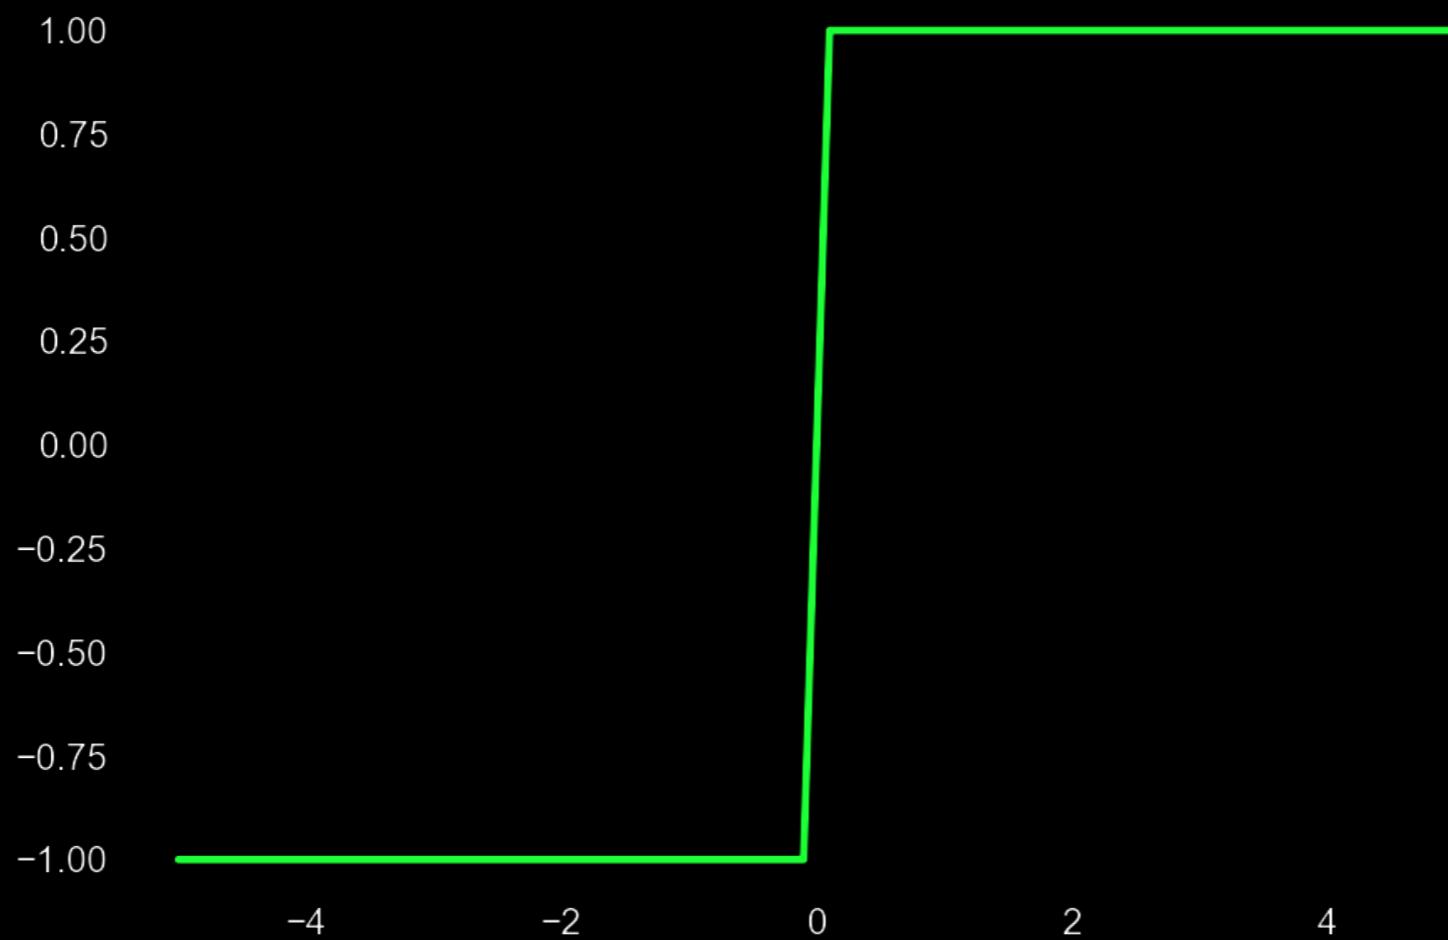


# От регрессии к классификации

$$Y = Xw + b$$

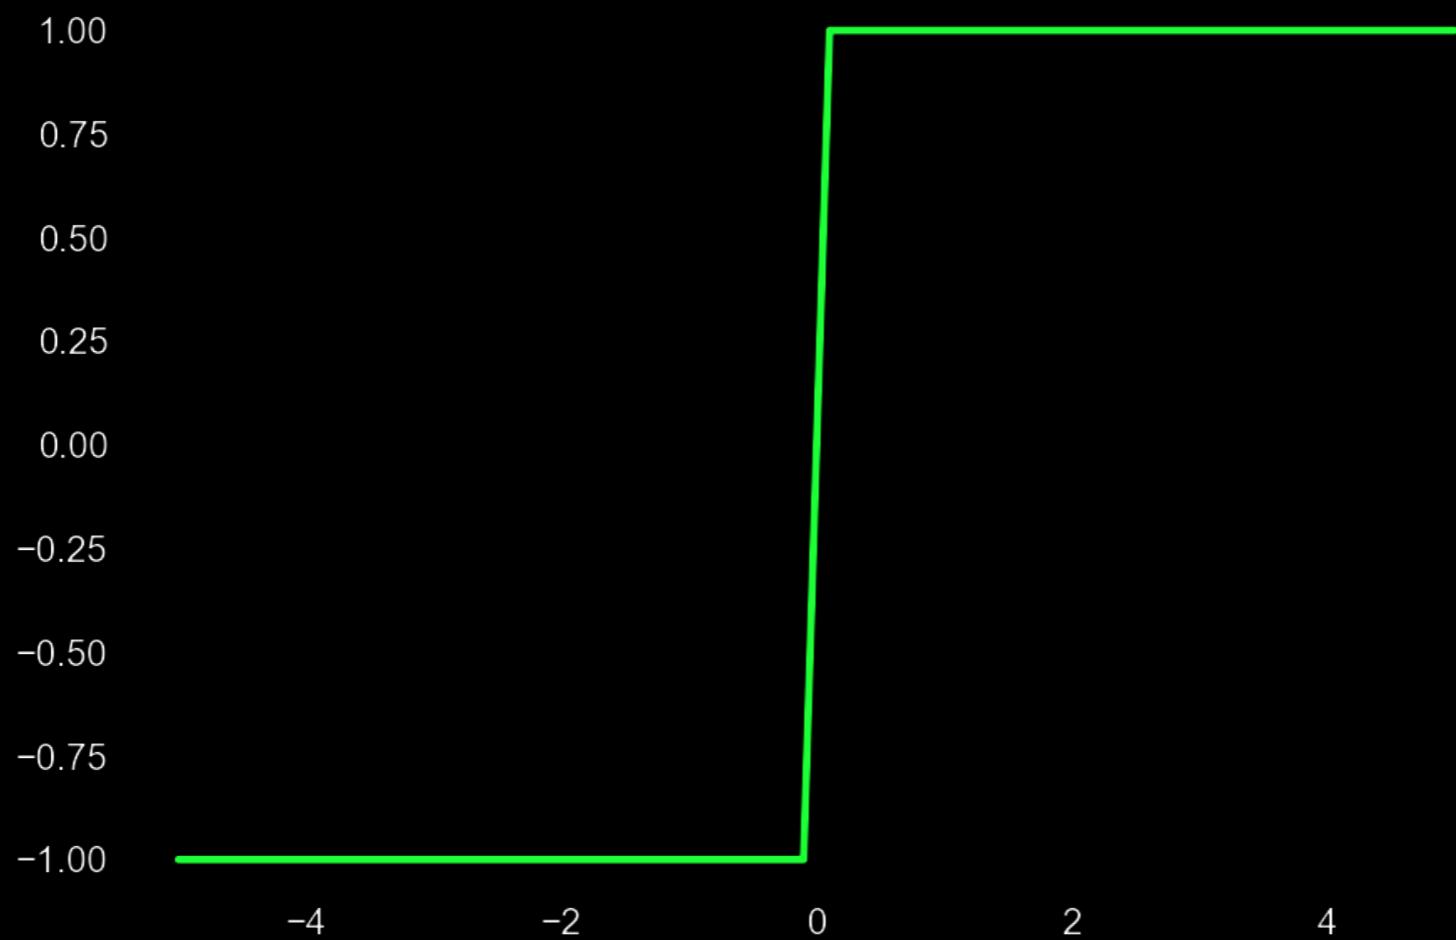
# От регрессии к классификации

$$Y = \text{sign}(Xw + b)$$

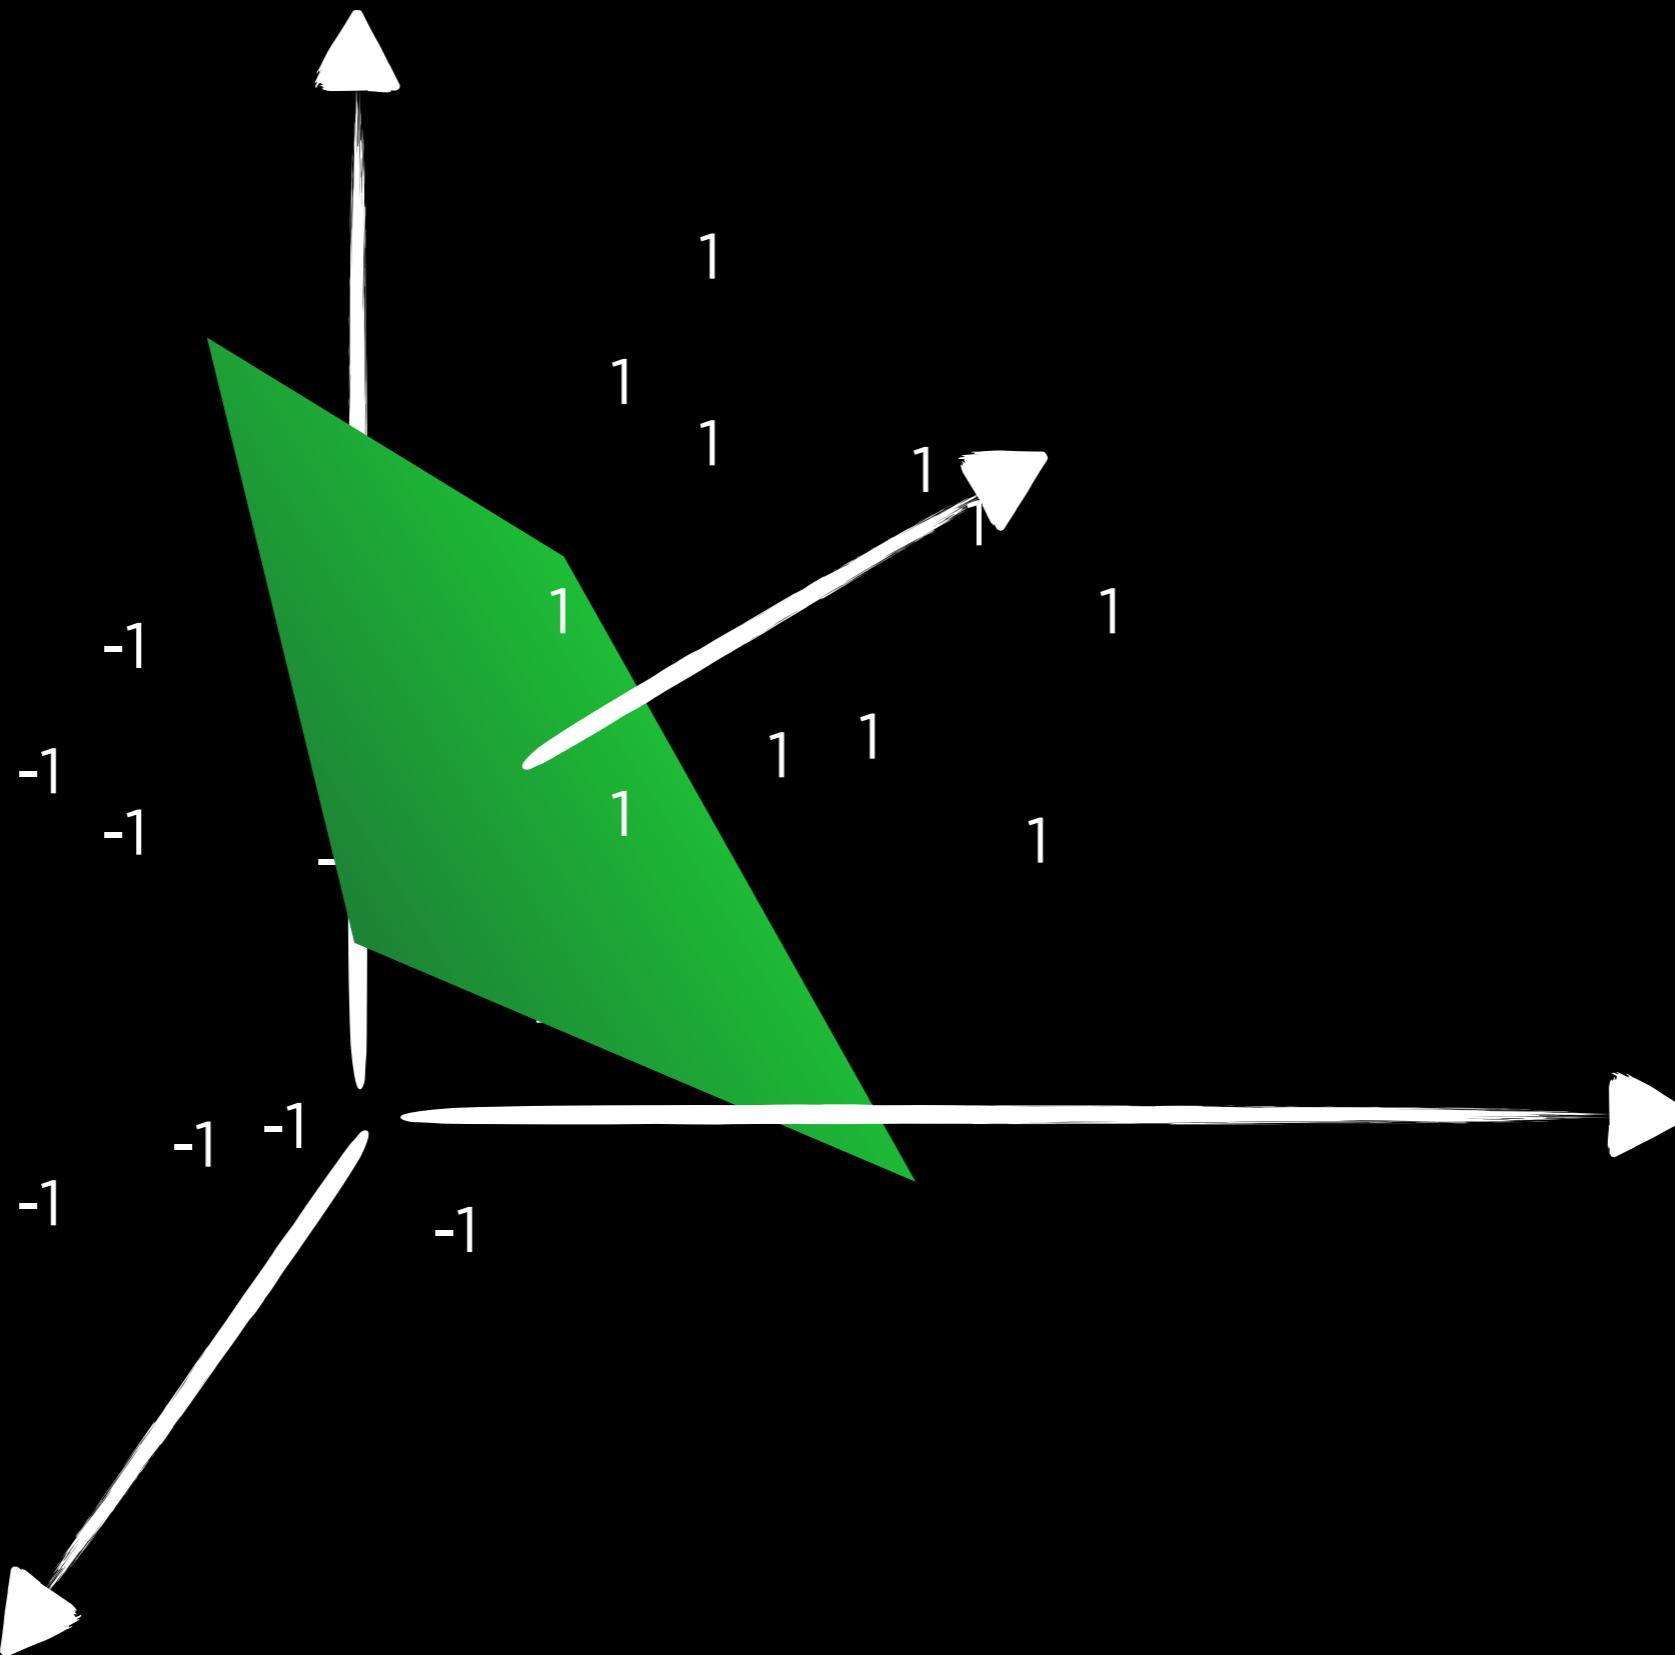


# От регрессии к классификации

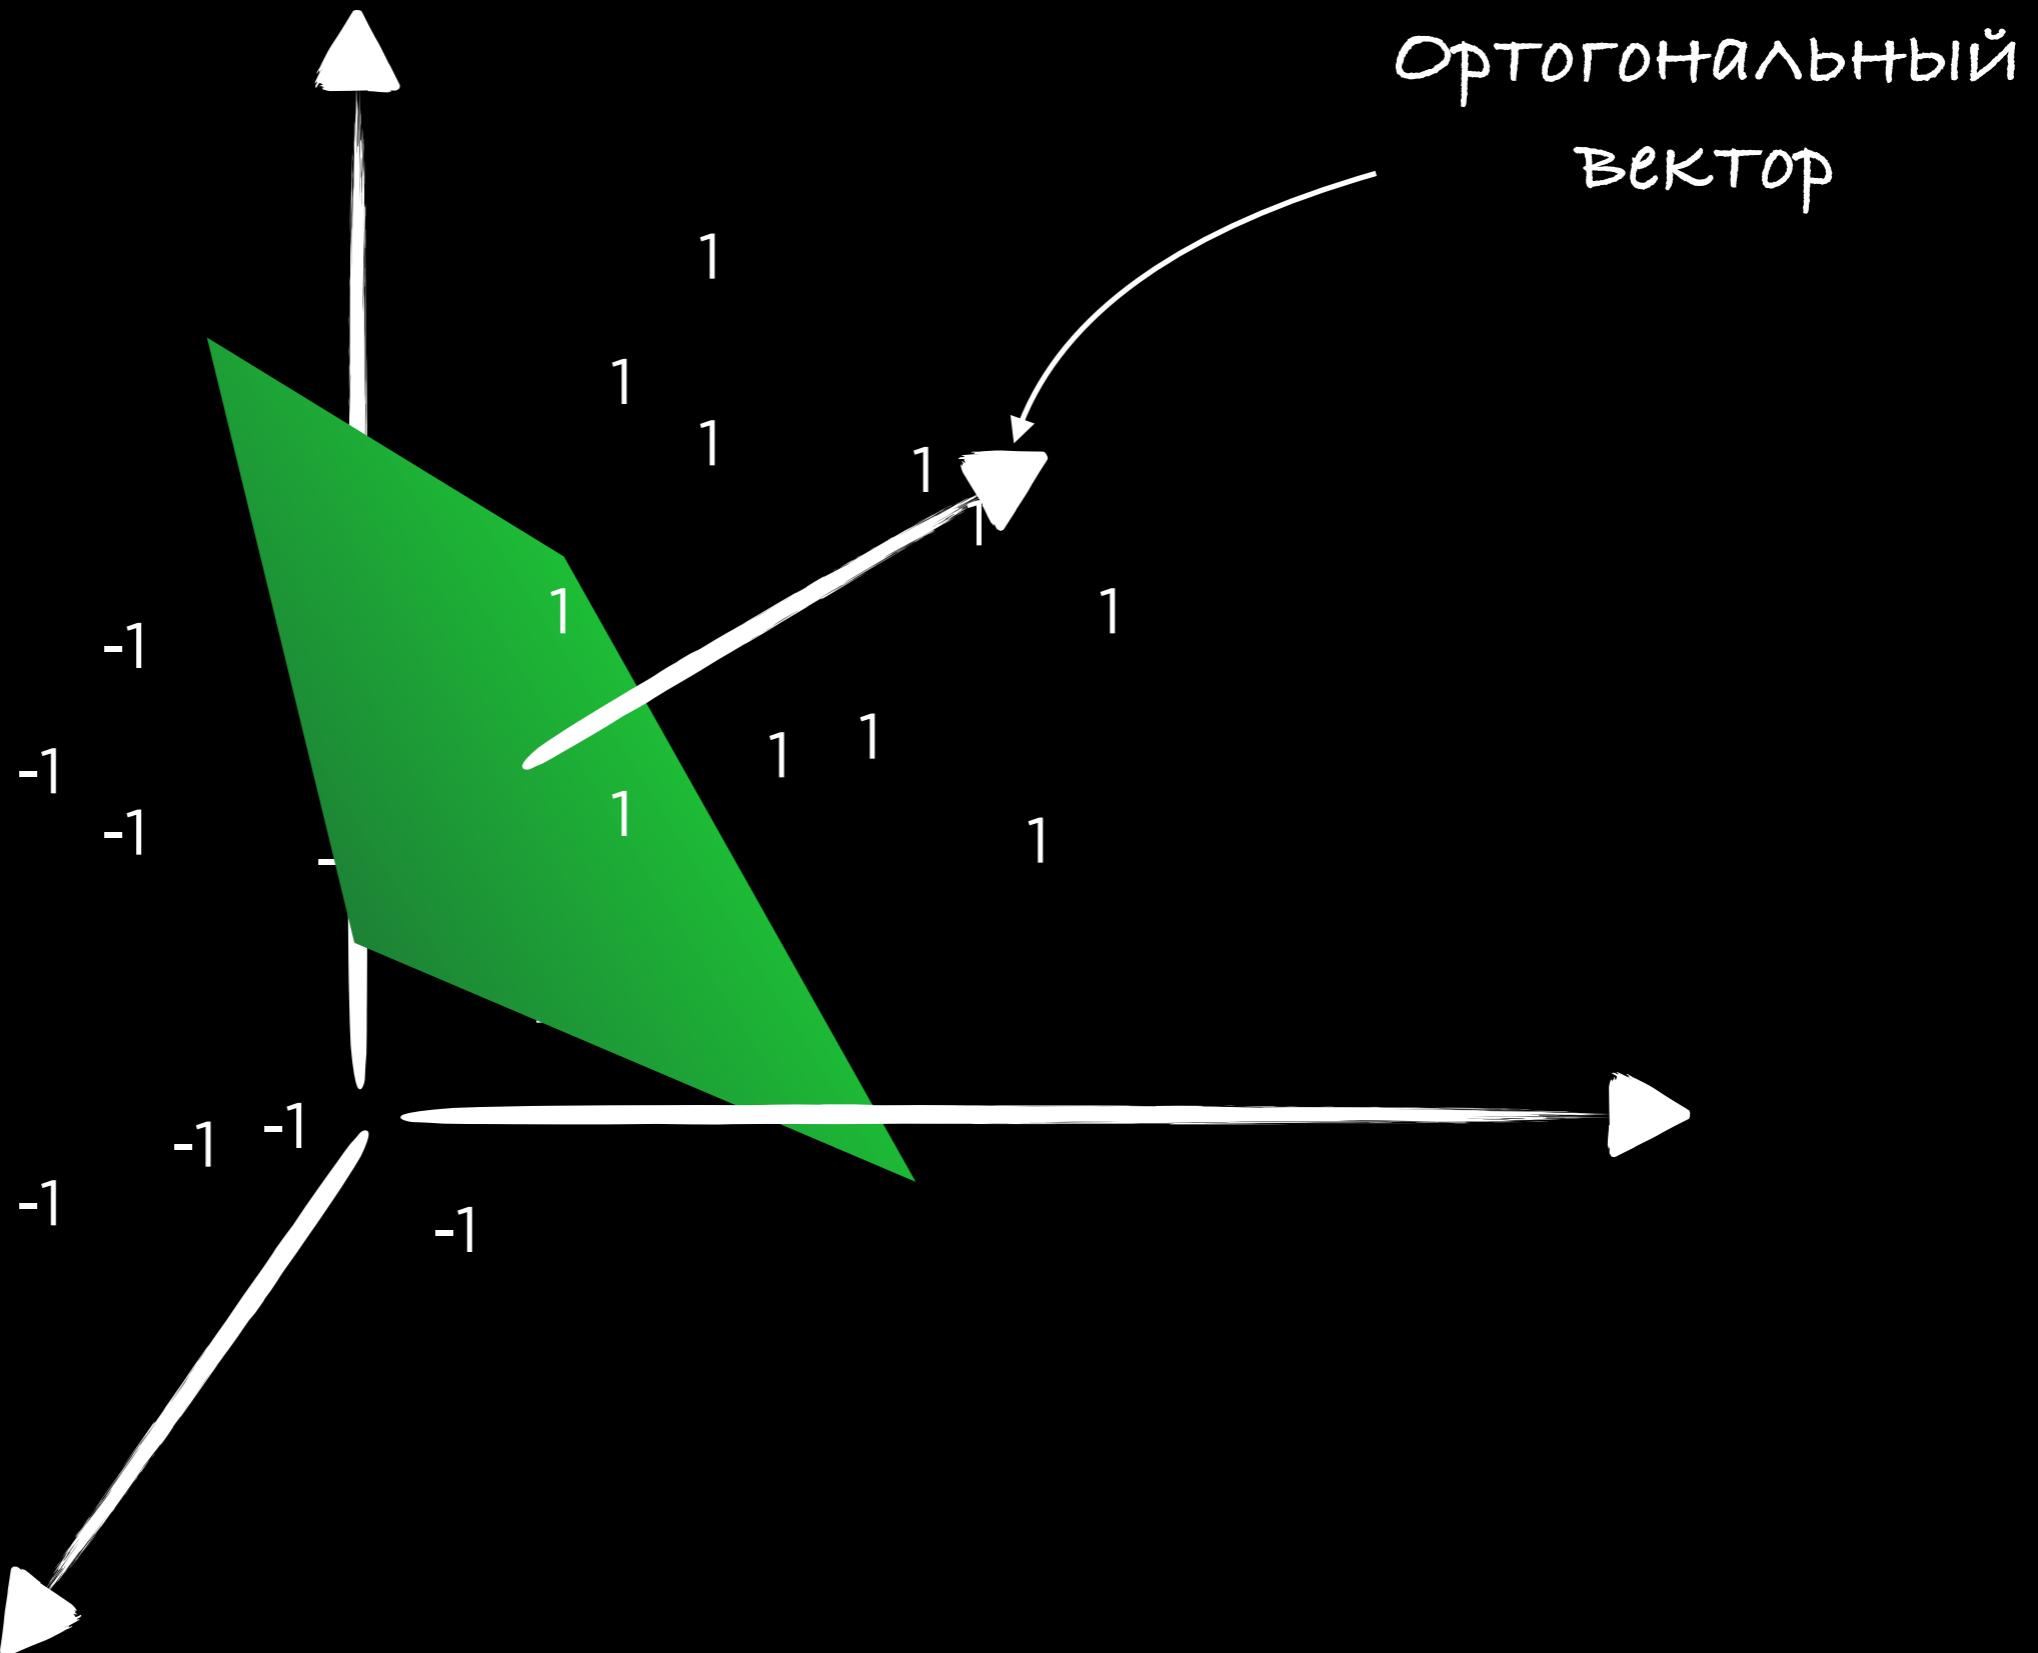
$$sign(x) = \begin{cases} 1 & if \ x > 0 \\ 0 & if \ x == 0 \\ -1 & if \ x < 0 \end{cases} \quad Y = sign(Xw + b)$$



# Почему?



# Почему?



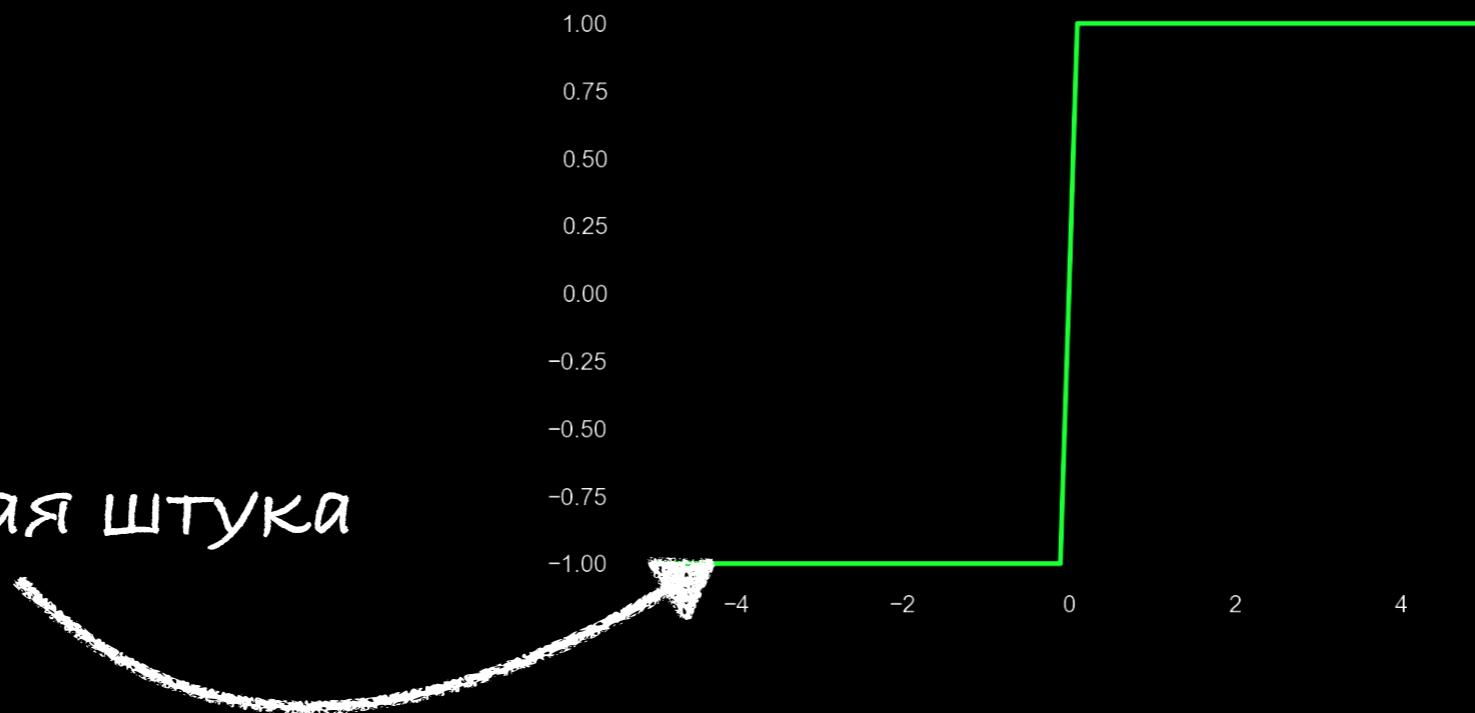
# Но

- Хотим использовать методы оптимизации, которые выше

# Но

- Хотим использовать методы оптимизации, которые выше

Нелинейная штука



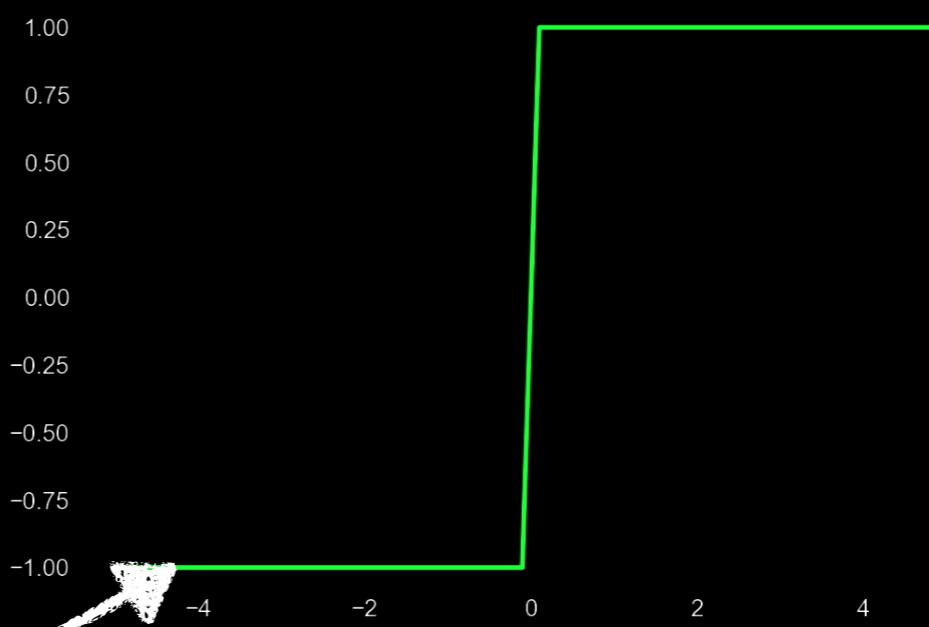
# Но

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# Но

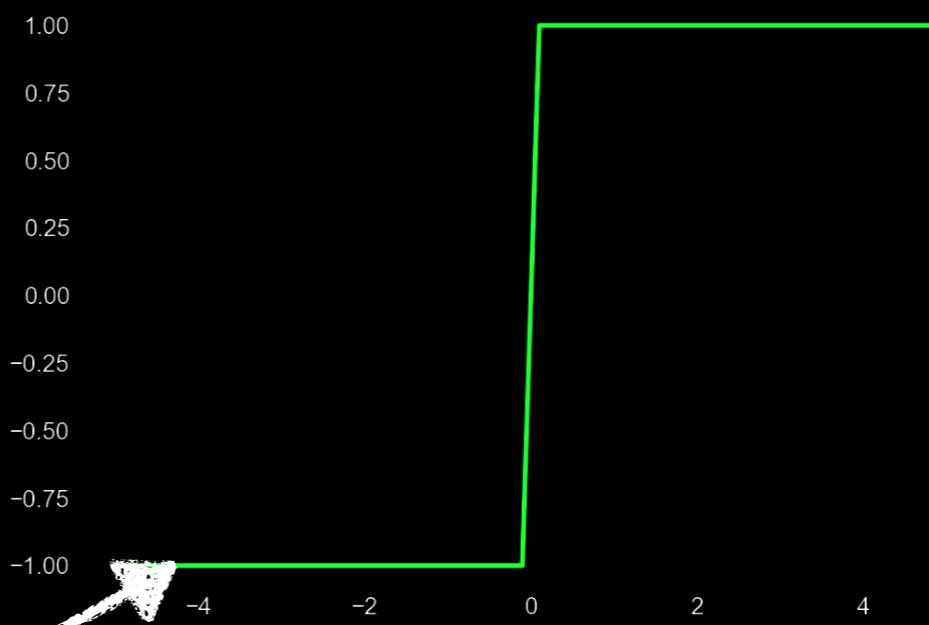
$$Y = f(X_1, \dots, X_l) + \epsilon$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# Но

$$Y = f(X_1, \dots, X_l) + \epsilon$$

Раньше

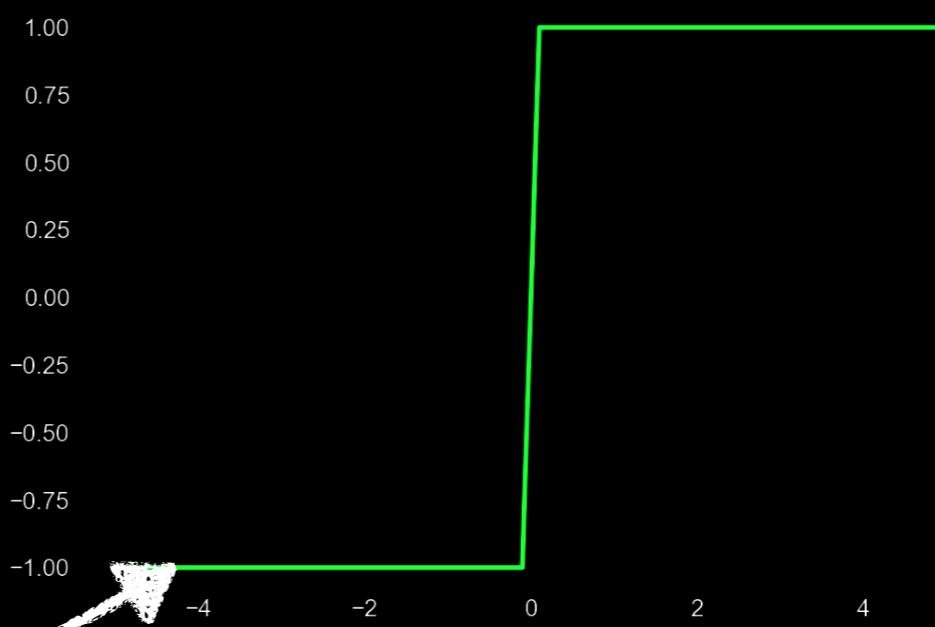
$$Xw + b$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# Но

Теперь

$$Y = f(X_1, \dots, X_l) + \epsilon$$

Раньше

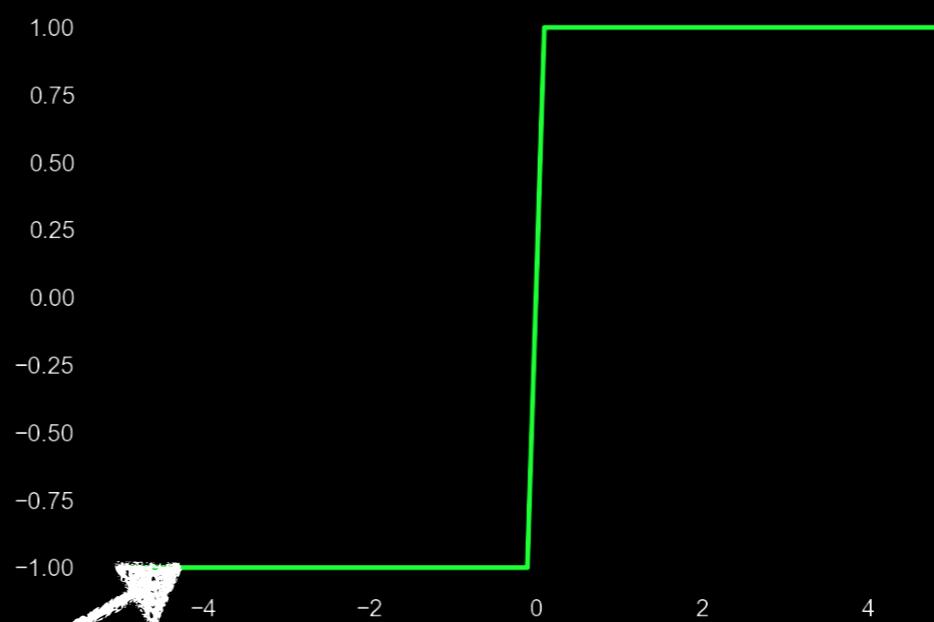
$$Xw + b$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# Но

Теперь

$$Y = f(X_1, \dots, X_l) + \epsilon$$

Раньше

$$Xw + b$$

$$\text{sign}(Xw + b)$$

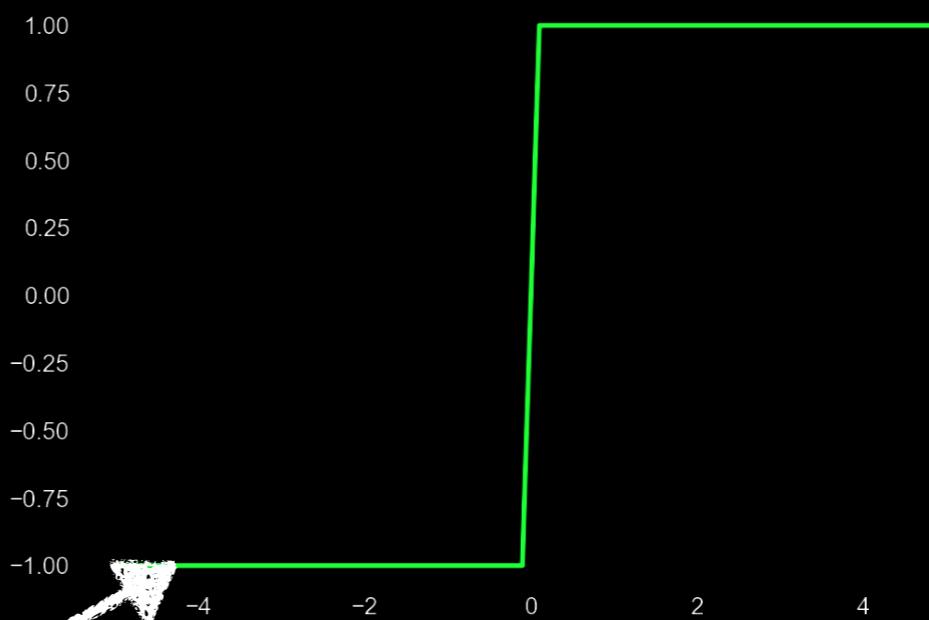
$$\nabla Q$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# НО

$$Q = \frac{1}{l} || sign(Xw + b) - y ||^2$$

$$Y = f(X_1, \dots, X_l) + \epsilon$$

Раньше

$$Xw + b$$

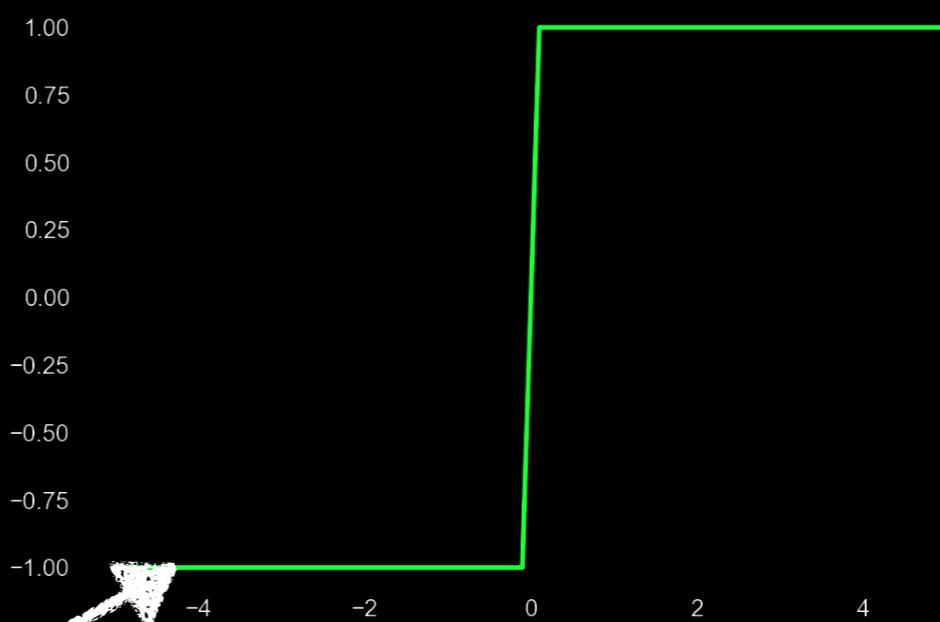
$$\nabla Q$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука



# НО

$$Q = \frac{1}{l} \| \underline{\text{sign}}(Xw + b) - y \| ^2$$

$$Y = f(X_1, \dots, X_l) + \epsilon$$

Раньше

$$Xw + b$$

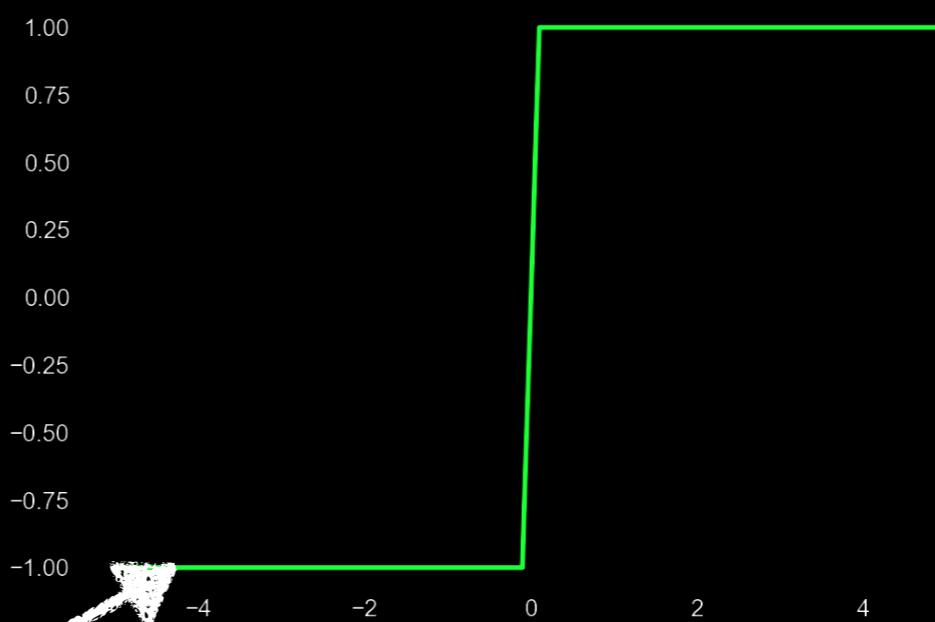
$$\nabla Q$$

- Хотим использовать методы оптимизации, которые выше

А нам нужны  
производные



Нелинейная штука

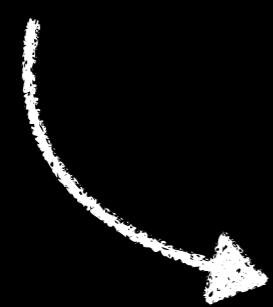


# Логистическая регрессия

# Логистическая регрессия

Logistic for logits

Logits



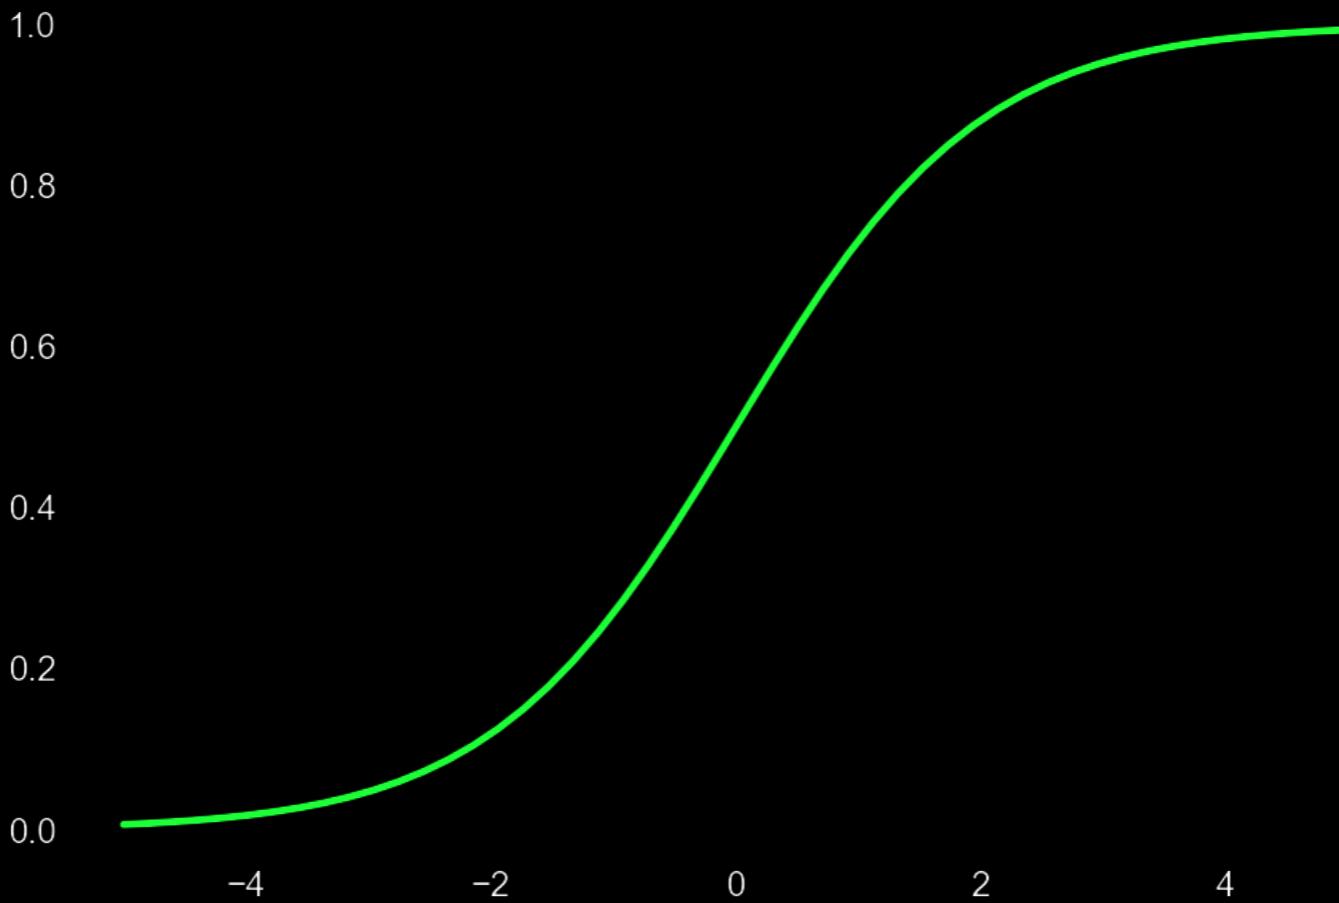
$$p = \text{sigmoid}(Xw + b)$$

# Что за сигмойда?

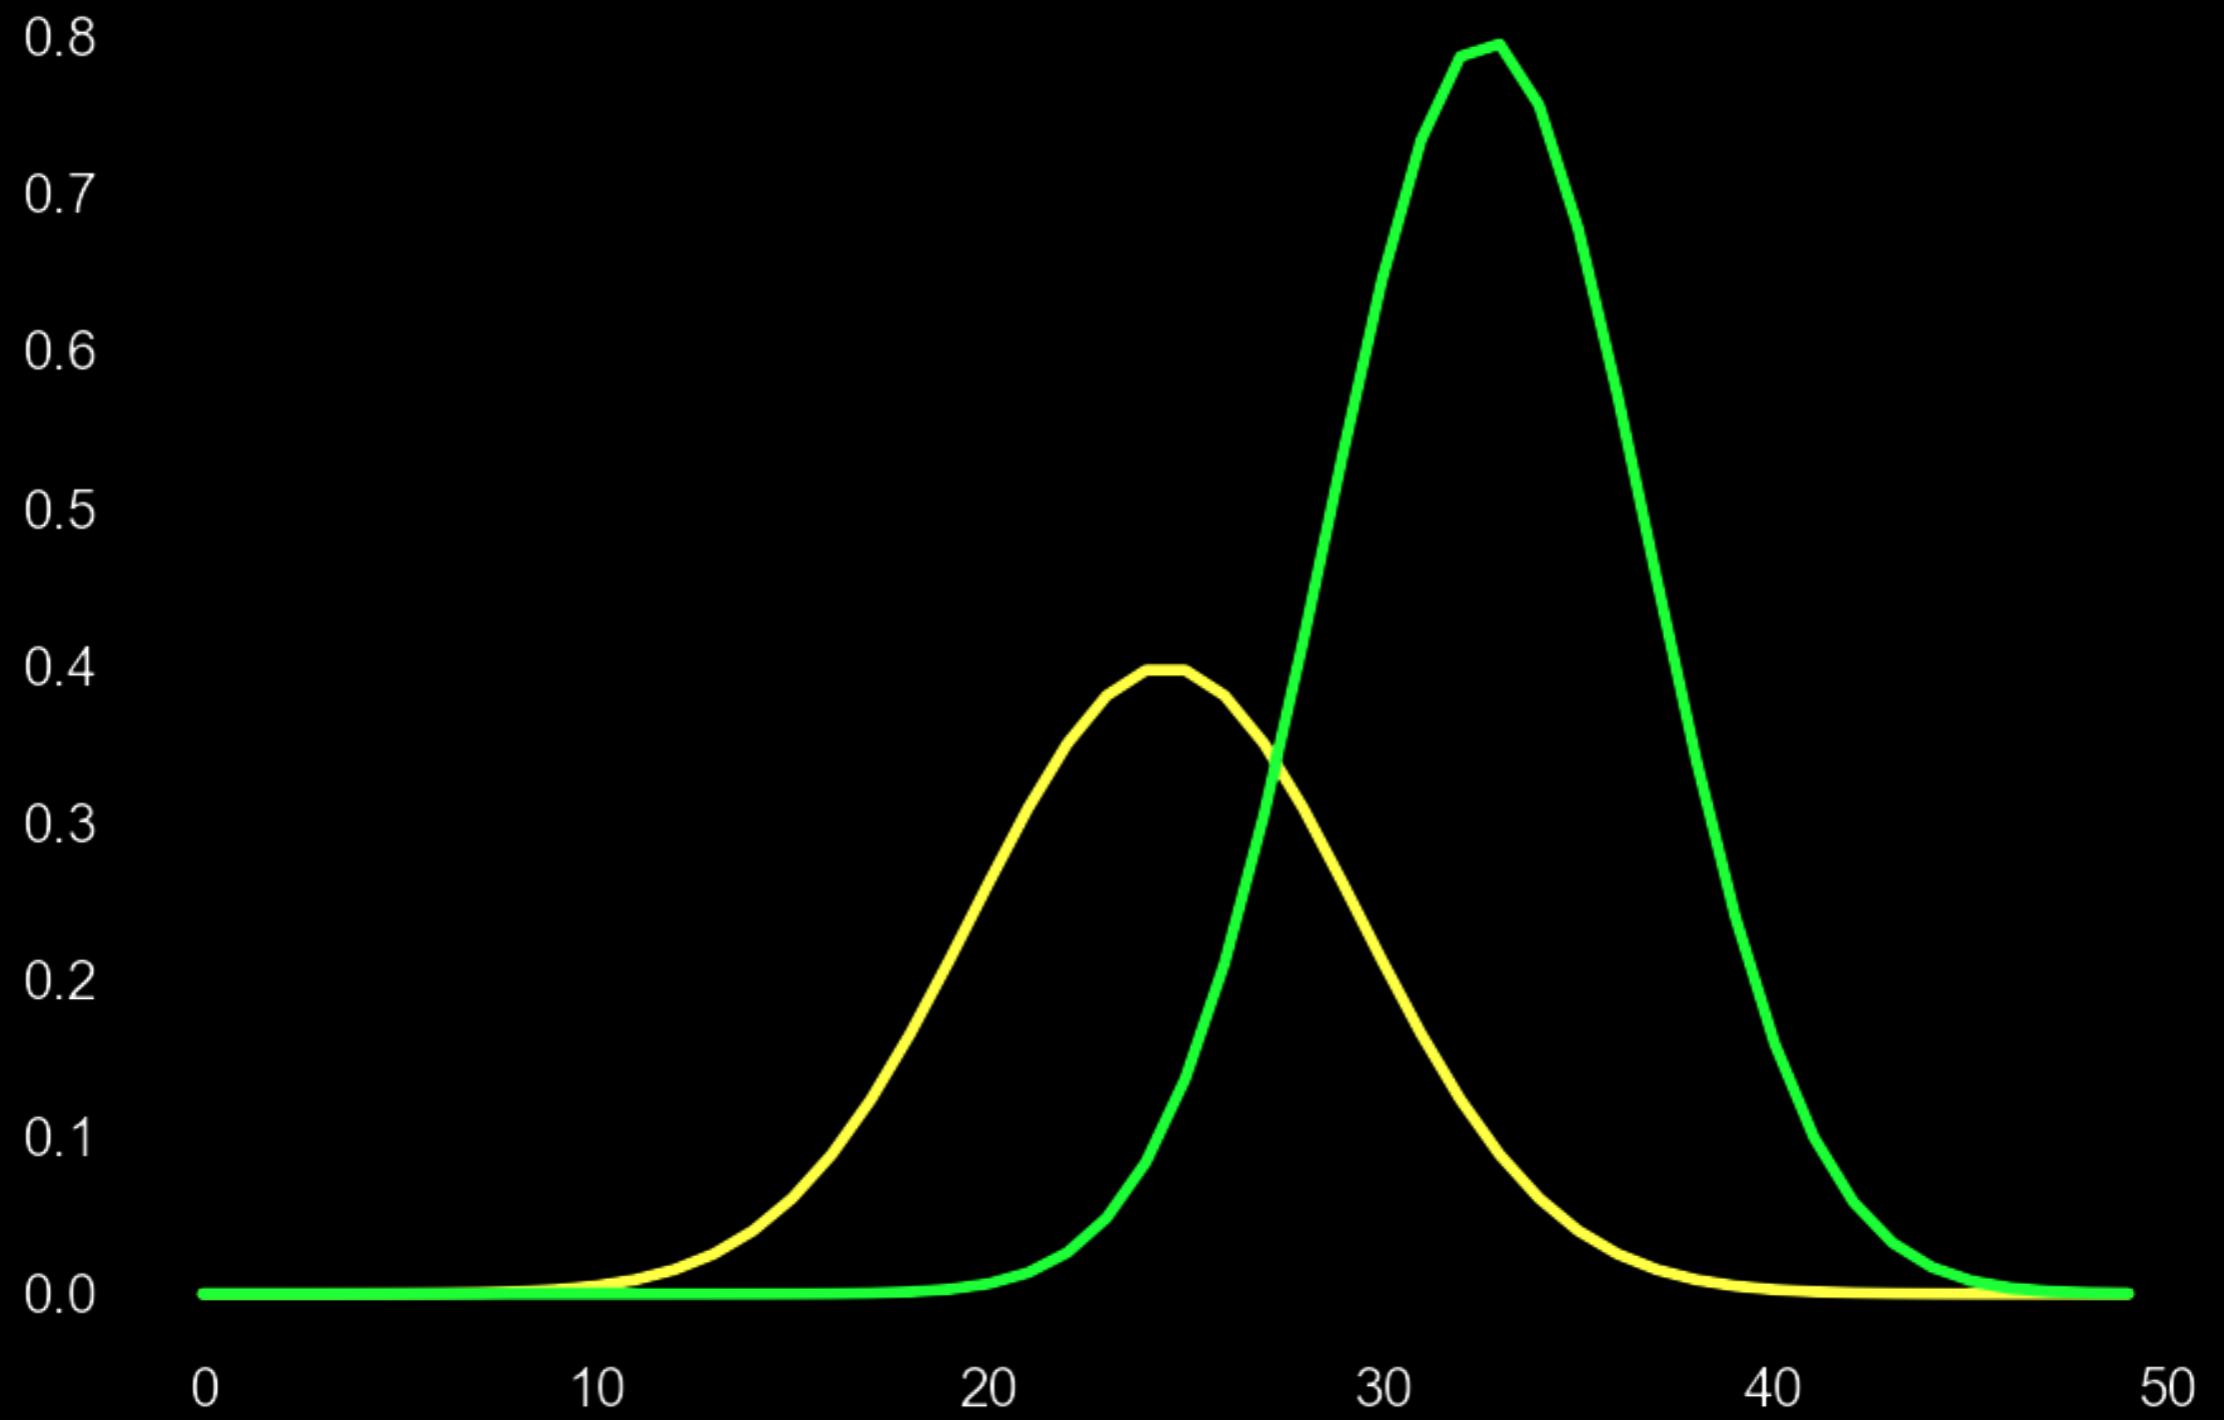
$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

# Что за си́гмойда?

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$



# Функция потерь



# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

Велико если неправильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1 \qquad \qquad \qquad y_i = 0$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

Велико если неправильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$y_i = 0$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(1 - p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

Велико если неправильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$y_i = 0$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(1 - p_i)$$

$p_i$  Как можно ближе к 1

$p_i$  Как можно ближе к 0

Мало если правильно

Велико если неправильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$y_i = 0$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

Велико если неправильно

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(1 - p_i)$$

$p_i$  Как можно ближе к 0

Мало если правильно

# Cross entropy

$$J(w) = -\frac{1}{N} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

$$y_i = 1$$

$$y_i = 0$$

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(p_i)$$

$p_i$  Как можно ближе к 1

Мало если правильно

Велико если неправильно

$$J(w) = -\frac{1}{N} \sum_{i=1}^l \log(1 - p_i)$$

$p_i$  Как можно ближе к 0

Мало если правильно

Велико если неправильно

# Градиент

# ФУНКЦИИ ОШИБКИ

# ФУНКЦИИ ОШИБКИ

$$Q(w, X) = \frac{1}{l} ||Xw - y||^2 \rightarrow \min_w$$

# ФУНКЦИИ ОШИБКИ

$$Q(w, X) = \frac{1}{l} ||Xw - y||^2 \rightarrow \min_w$$

$$J(w, X) = \frac{1}{l} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) \rightarrow \min_w$$

# ФУНКЦИИ ОШИБКИ

Раньше

$$Q(w, X) = \frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

$$J(w, X) = \frac{1}{l} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) \rightarrow \min_w$$

# ФУНКЦИИ ОШИБКИ

Раньше

$$Q(w, X) = \frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

$$J(w, X) = \frac{1}{l} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) \rightarrow \min_w$$



Теперь

# ФУНКЦИИ ОШИБКИ

Раньше

$$Q(w, X) = \frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

$$J(w, X) = \frac{1}{l} \sum_{i=1}^l (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) \rightarrow \min_w$$

Теперь

тут  $w$

# Объяснение, как считать

Как считается производная cross entropy

# Как теперь обновляем веса

$$dw = \frac{1}{l} X^T (A - y)$$

$$db = \frac{1}{l} \sum (A - y)$$

$$w_{new} = w - \eta_t dw$$

$$b_{new} = b - \eta_t db$$

# Литература

- Конспект лекций по линейным моделям
- Полезные видосы по логистической регрессии
- Как считается производная cross entropy

# Контакты

- Телеграмм для вопросов по заданиям: [@akuparez](https://t.me/akuparez)
- Телеграмм бот для сдачи заданий:  
[@dsmatmech2018\\_bot](https://t.me/dsmatmech2018_bot)

# Задания

<https://github.com/kuparez/data-science-101>

# Задания

- Либо реализовать алгоритмы (let's get hands dirty.ipynb);
  - 10 баллов
- Либо побить baseline решение Титаника (titanic\_predictions.ipynb)
  - 10 баллов
- Оба задания: 15 баллов

# Задания

- Мягкий дэдлайн: 17 ноября
  - После него будет даваться половина баллов
- Жесткий дедлайн: 24 ноября
  - После него 0 баллов

# Реализация алгоритмов

- Свои реализации надо отправлять в бот с названием файла “name\_surname\_n group\_1.html”
- Ожидается, что Ваши реализации будут вести себя сходно с тем, что написано в ноутбуке
- На вопросы, которые есть в ноутбуке отвечать необязательно, но мы с удовольствие почитаем.

# Титаник

- Требуется побить решение, предложенное нами.
- Надо отправлять решения на Kaggle с тэгом Your Name [mm\_ds\_course]
- Также Ваши решения ожидаются в телеграмм боте в виде html с названием файла:  
“name\_surname\_номер\_группы\_2.html”
- Более подробные правила расписаны в ноутбуке